베이지안 분류기 수학 발표

세미 나이브 베이즈, 베이지안 네트워크, EM

『단단한 머신러닝』 Chapter 7, 7.4-7.6 중심 · 발표자 강재성

조건부 독립으로 확률을 분해하고, 관측 데이터로 파라미터를 추정하며, 숨은 변수가 있으면 기대값을 이용해 학습한다.

목차

01. 기호와 출발식
02. ODE와 SPODE의 확률 분해
03. TAN과 조건부 상호정보량
04. AODE의 평균과 확률 추정
05. 베이지안 네트워크의 결합확률
06. 공통 부모와 연쇄 구조의 조건부 독립
07. 충돌 구조와 d-분리
08. 조건부 확률표의 최대우도 추정
09. 구조 학습과 MDL·AIC·BIC
10. 주변화와 깁스 샘플링
11. 잠재 변수와 EM의 목적함수
12. Jensen 부등식으로 EM 유도
13. EM의 로그우도가 감소하지 않는 이유
14. 기대 도수로 확률표 갱신
참고 자료

01. 기호와 출발식

기호	뜻
$\mathbf{x} = (x_1, \ldots, x_d), c$	관측한 특성 벡터와 클래스 값
D, N	학습 데이터와 표본 수
π_i	변수 X_i의 부모 변수 집합
$G, \theta, B = (G, \theta)$	그래프, 확률 파라미터, 베이지안 네트워크
$\hat{P}, \hat{\theta}$	데이터에서 추정한 확률과 파라미터
$\propto, \arg\max$	비례 관계, 함수를 최대로 만드는 인자

대문자는 확률변수, 소문자는 그 값이다. 확률표와 합을 사용하는 식은 이산 변수를 기준으로 하며, 연속 변수에서는 확률밀도와 적분을 사용한다.

베이즈 정리와 분류

$$P(c \mid \mathbf{x}) = \frac{P(c, \mathbf{x})}{\sum_{c'} P(c', \mathbf{x})} = \frac{P(c)P(\mathbf{x} \mid c)}{P(\mathbf{x})}$$

0-1 손실에서는 사후확률이 가장 큰 클래스를 선택한다.

$$\hat{c} = \arg\max_c P(c \mid \mathbf{x}) = \arg\max_c P(c)P(\mathbf{x} \mid c)$$

나이브 베이즈의 조건부 독립 가정

$$P(\mathbf{x} \mid c) = \prod_{i=1}^{d} P(x_i \mid c) \quad \Longrightarrow \quad \hat{c} = \arg\max_c P(c) \prod_{i=1}^{d} P(x_i \mid c)$$

> 클래스가 주어졌을 때 모든 특성이 서로 독립이라는 가정이 결합확률 계산을 단순하게 만든다.

02. ODE와 SPODE의 확률 분해

ODE: 클래스 외에 최대 한 개의 특성 부모를 허용

특성 X_i의 추가 부모를 $X_{p(i)}$라고 하자. 추가 연결도 순환을 만들지 않아야 한다.

$$P(c \mid \mathbf{x}) \propto P(c) \prod_{i=1}^{d} P(x_i \mid c, x_{p(i)})$$

추가 부모가 없는 항은 $P(x_i \mid c)$로 계산한다. 추가 부모를 모두 없애면 나이브 베이즈가 된다.

SPODE: 하나의 공통 부모 특성 선택

X_s를 공통 부모로 정하고, 나머지 특성들이 C, X_s를 조건으로 서로 독립이라고 가정한다.

$$\begin{aligned} P_s(c, \mathbf{x}) &= P(c) P(x_s \mid c) \prod_{i \neq s} P(x_i \mid c, x_s) \\ &= P(c, x_s) \prod_{i \neq s} P(x_i \mid c, x_s) \end{aligned}$$

분류할 때는 이 결합확률을 클래스별로 비교한다.

$$\hat{c} = \arg\max_{c} \hat{P}(c, x_s) \prod_{i \neq s} \hat{P}(x_i \mid c, x_s)$$

> ODE는 부모 수를 제한하고, SPODE는 모든 특성이 참조할 공통 부모까지 정한다.

03. TAN과 조건부 상호정보량

TAN은 특성 사이의 연결을 트리로 제한한다. 각 특성의 부모는 클래스와 최대 한 개의 다른 특성이다.

연결의 가중치

$$I(X_i; X_j \mid C) = \sum_{c, x_i, x_j} P(c, x_i, x_j) \log \frac{P(x_i, x_j \mid c)}{P(x_i \mid c) P(x_j \mid c)}$$

클래스를 알고도 남는 두 특성의 의존 정도를 나타낸다. 조건부 독립이면 분수는 1이고 해당 상호정보량은 0이다.

표본에서 추정한 값을 간선 가중치로 사용해 **최대 가중치 신장 트리**를 찾는다.

$$T^* = \arg\max_{T \in \mathcal{T}} \sum_{\{i,j\} \in E(T)} \hat{I}(X_i; X_j \mid C)$$

$\mathcal{T}$는 가능한 신장 트리의 집합이며, $E(T)$는 트리에 포함된 간선의 집합이다.

1. 모든 특성 쌍의 조건부 상호정보량을 계산한다.
2. 가중치 합이 가장 큰 신장 트리를 선택한다.
3. 루트 특성을 정하고 바깥 방향으로 간선의 방향을 정한다.
4. 클래스에서 모든 특성으로 향하는 간선을 추가한다.

완전 관측 이산 데이터에서 평활화하지 않은 최대우도 추정을 사용할 때, 트리 구조에 따른 로그우도는 다음과 같다.

$$LL(T) = \text{constant} + N \sum_{\{i,j\} \in E(T)} \hat{I}(X_i; X_j \mid C)$$

> 이 조건에서는 조건부 상호정보량의 합을 최대화하는 것이 TAN의 로그우도를 최대화하는 것과 같다. [1]

04. AODE의 평균과 확률 추정

AODE는 공통 부모를 달리한 여러 SPODE의 **결합확률 추정값을 평균**한다.

입력에서 관측된 특성값 x_s의 학습 빈도가 기준 τ 이상인 부모 후보를 사용한다.

$$S(\mathbf{x}) = \{s : N(X_s = x_s) \geq \tau\}$$

후보가 하나 이상일 때, 클래스별 점수를 다음과 같이 계산한다.

$$A_c(\mathbf{x}) = \frac{1}{|S(\mathbf{x})|} \sum_{s \in S(\mathbf{x})} \hat{P}(c, x_s) \prod_{i \neq s} \hat{P}(x_i \mid c, x_s)$$

$$\hat{P}_{\mathrm{AODE}}(c \mid \mathbf{x}) = \frac{A_c(\mathbf{x})}{\sum_{c'} A_{c'}(\mathbf{x})}, \qquad \hat{c} = \arg\max_c A_c(\mathbf{x})$$

평균의 분모는 클래스에 공통이므로 클래스 비교와 정규화에서 상쇄된다. 사용할 부모 후보가 없으면 나이브 베이즈 등으로 대체하는 규칙이 필요하다.

라플라스 평활화

$N(c, a)$는 $C = c, X_s = a$인 표본 수, $N(b, c, a)$는 여기에 $X_i = b$까지 만족하는 표본 수다. 클래스 수를 L, 특성의 상태 수를 r_s, r_i라고 하면,

$$\hat{P}(c, a) = \frac{N(c, a) + 1}{N + L r_s}, \qquad \hat{P}(b \mid c, a) = \frac{N(b, c, a) + 1}{N(c, a) + r_i}$$

교재의 도수 예시에서는,

$$\hat{P}(c, a) = \frac{6 + 1}{17 + 2 \cdot 3} = \frac{7}{23} \approx 0.304, \qquad \hat{P}(b \mid c, a) = \frac{3 + 1}{6 + 3} = \frac{4}{9} \approx 0.444$$

> 서로 다른 부모 선택을 종합하면 하나의 부모를 고르는 결정에 대한 의존을 줄일 수 있다. [2]

05. 베이지안 네트워크의 결합확률

베이지안 네트워크는 방향성 비순환 그래프와 조건부 확률로 이루어진다.

연쇄법칙에 조건부 독립을 적용

변수를 부모가 먼저 오는 순서로 나열하면,

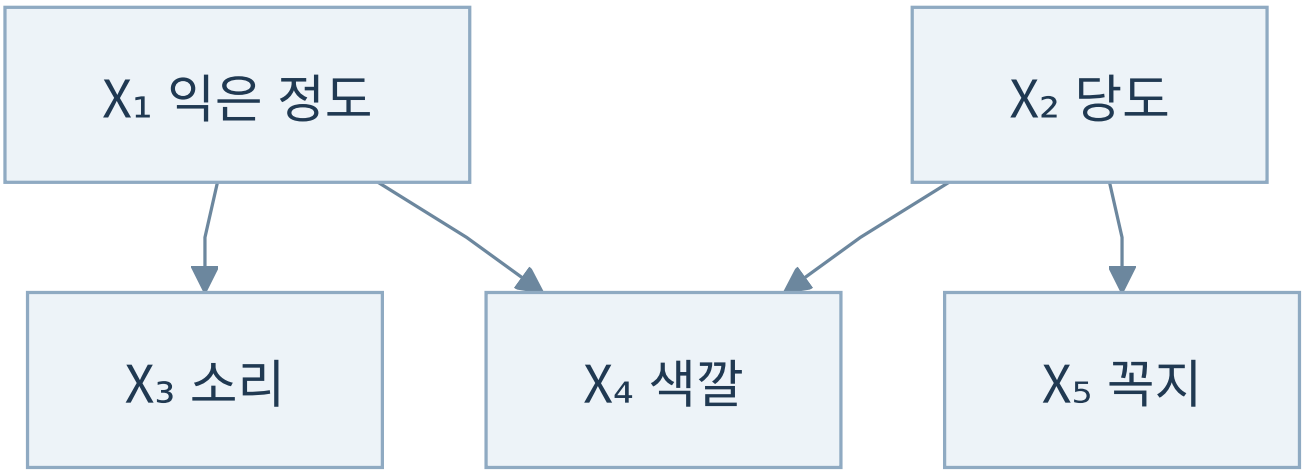
$$P(x_1, \ldots, x_d) = \prod_{i=1}^{d} P(x_i \mid x_1, \ldots, x_{i-1})$$

각 변수는 부모가 주어졌을 때 나머지 앞선 변수들과 조건부 독립이므로,

$$\boxed{P_B(x_1, \ldots, x_d) = \prod_{i=1}^{d} P(x_i \mid x_{\pi_i})}$$

x_{π_i}는 부모 변수들의 관측값이다. 부모가 없는 변수는 주변확률을 사용한다.

교재 수박 예제의 구조



$$P(x_1, x_2, x_3, x_4, x_5) = P(x_1)P(x_2)P(x_3 \mid x_1) \cdot P(x_4 \mid x_1, x_2)P(x_5 \mid x_2)$$

> 전체 결합분포를 각 변수와 부모 사이의 국소적인 확률표로 표현한다. 그래프의 화살표만으로 인과관계가 입증되는 것은 아니다.

06. 공통 부모와 연쇄 구조의 조건부 독립

아래 계산은 표시된 세 변수만 있는 구조를 기준으로 한다. 조건으로 사용하는 사건의 확률은 양수라고 가정한다.

공통 부모: $A \leftarrow B \rightarrow C$

$$P(a,b,c) = P(b)P(a \mid b)P(c \mid b)$$

$$\begin{aligned} P(a,c \mid b) &= \frac{P(a,b,c)}{P(b)} \\ &= P(a \mid b)P(c \mid b) \end{aligned} \qquad \Longrightarrow \quad A \perp C \mid B$$

연쇄 구조: $A \rightarrow B \rightarrow C$

$$\begin{aligned} P(a,c \mid b) &= \frac{P(a)P(b \mid a)P(c \mid b)}{P(b)} \\ &= P(a \mid b)P(c \mid b) \end{aligned} \qquad \Longrightarrow \quad A \perp C \mid B$$

두 번째 등식에서는 $P(a)P(b \mid a)/P(b) = P(a \mid b)$를 사용했다.

> 공통 부모와 연쇄 구조에서는 가운데 변수를 알면 양 끝 변수 사이의 경로가 차단된다.

07. 충돌 구조와 d-분리

공통 자식: $A \to B \leftarrow C$

이 구조의 결합확률은,

$$P(a,b,c) = P(a)P(c)P(b \mid a,c)$$

자식 B를 관측하지 않고 합으로 제거하면,

$$\begin{aligned} P(a,c) &= P(a)P(c)\sum_{b} P(b \mid a,c) \\ &= P(a)P(c) \end{aligned} \qquad \Longrightarrow \quad A \perp C$$

반대로 $B = b$를 관측하면,

$$P(a,c \mid b) = \frac{P(a)P(c)P(b \mid a,c)}{P(b)}$$

일반적으로 위 식은 $P(a \mid b)P(c \mid b)$로 분리되지 않는다. 공통 결과를 관측하면서 부모 사이에 의존 관계가 생길 수 있다.

d-분리의 경로 차단 조건

관측 변수 집합을 Z라고 하자. 경로 위에서 다음 중 하나가 성립하면 그 경로는 차단된다.

- 충돌점이 아닌 중간 변수가 Z에 포함된다.
- 충돌점과 그 후손이 모두 Z에 포함되지 않는다.

두 변수 집합 사이의 모든 경로가 차단되면, 해당 그래프로 분해되는 분포에서 조건부 독립을 보장한다. 경로가 열려 있다는 사실만으로 모든 파라미터에서 의존한다고 단정할 수는 없다.

모럴 그래프로 확인하는 순서

1. 질의 변수와 관측 변수, 그리고 그 조상들만 남긴다.
2. 공통 자식을 가진 부모끼리 연결하고 모든 화살표의 방향을 없앤다.
3. 관측 변수들을 제거한 뒤 질의 변수 집합 사이의 연결 여부를 확인한다.

> d-분리 판정에 모럴 그래프를 사용할 때는 먼저 관련 조상 그래프를 만드는 단계가 필요하다. [3]

08. 조건부 확률표의 최대우도 추정

구조가 고정되어 있고, 모든 변수를 관측한 이산 데이터를 가정한다.

X_i의 상태를 k, 부모의 값 조합을 j라고 두면,

$$\theta_{ijk} = P(X_i = k \mid \pi_i = j), \qquad N_{ij} = \sum_k N_{ijk}$$

N_{ijk}는 해당 조건을 만족하는 표본 수다. 확률표의 각 행은 합이 1이어야 한다.

$$LL(\theta; D) = \sum_{i,j,k} N_{ijk} \log \theta_{ijk}, \qquad \sum_k \theta_{ijk} = 1$$

한 행에 대한 라그랑주 승수법

$$\mathcal{L} = \sum_k N_{ijk} \log \theta_{ijk} + \lambda_{ij} \left(1 - \sum_k \theta_{ijk}\right)$$

양의 도수를 가진 항을 미분하면,

$$\frac{\partial \mathcal{L}}{\partial \theta_{ijk}} = \frac{N_{ijk}}{\theta_{ijk}} - \lambda_{ij} = 0 \quad \Longrightarrow \quad \theta_{ijk} = \frac{N_{ijk}}{\lambda_{ij}}$$

정규화 조건을 적용하면 $\lambda_{ij} = N_{ij}$이므로,

$$\boxed{\hat{\theta}_{ijk} = \frac{N_{ijk}}{N_{ij}}}$$

$N_{ij} > 0$인 행에서 성립하며, 도수가 0인 상태는 경계에서 확률 0을 갖는다. $N_{ij} = 0$인 행은 데이터만으로 정할 수 없으므로 평활화나 사전분포를 사용한다.

> 조건부 확률의 빈도 추정은 합이 1이라는 제약 아래 로그우도를 최대화한 결과다.

09. 구조 학습과 MDL·AIC·BIC

연결을 추가하면 표현력과 함께 추정해야 할 파라미터 수도 증가한다.

X_i의 상태 수가 r_i, 부모의 값 조합 수가 q_i라면 자유 파라미터 수는,

$$K = \sum_{i=1}^{d} q_i(r_i - 1), \qquad q_i = \prod_{X_j \in \pi_i} r_j$$

부모가 없는 변수는 $q_i = 1$이다. 한 확률표 행에서 마지막 확률은 나머지 확률의 합으로 결정되므로 $r_i - 1$개만 자유롭다.

kDE의 확장 비용

kDE는 클래스 외에 최대 k개의 특성 부모를 허용한다. 특성들이 각각 r개 상태, 클래스가 L개 상태라면, 부모 특성이 k개인 한 특성의 확률표에는 다음 수의 자유 파라미터가 필요하다.

$$K_i = Lr^k(r-1)$$

추가 부모 수에 따라 확률표의 크기가 지수적으로 증가할 수 있다.

최대우도와 복잡성의 균형

$$LL(B; D) = \sum_{n=1}^{N} \log P_B(\mathbf{x}^{(n)})$$

$$\mathrm{Score}(B; D) = \mathrm{Penalty}(K, N) - LL(B; D)$$

교재의 척도로 쓰면,

$$\mathrm{AIC}_{\mathrm{book}} = K - LL$$
$$\mathrm{BIC}_{\mathrm{book}} = \frac{K \log N}{2} - LL$$

점수가 작을수록 선호한다. 일반적인 AIC와 BIC 표기는 위 식의 2배이며 모델 순위는 같다.

MDL은 모델 자체의 설명 길이와 모델로 데이터를 설명하는 길이를 함께 줄이는 관점이다. 구조 탐색에서는 간선 추가·삭제·반전을 비교하며 DAG 조건을 유지한다.

> 부모 수가 증가하면 조건별 데이터가 더 잘게 나뉜다. 복잡한 구조의 이점과 확률 추정의 불안정성을 함께 고려해야 한다.

10. 주변화와 깁스 샘플링

질의 변수 집합을 Q, 관측된 증거를 $E = e$, 나머지 미관측 변수를 H라고 하자.

$$P(Q = q \mid E = e) = \frac{\sum_{h} P(Q = q, E = e, H = h)}{\sum_{q', h} P(Q = q', E = e, H = h)}$$

미관측 변수가 많으면 이 합의 항 수가 크게 늘어난다. 깁스 샘플링은 **증거를 고정하고 비증거 변수를 하나씩 다시 추출**해 사후확률을 근사한다.

비증거 변수 전체 $V = Q \cup H$를 갱신한다. 변수 V_i의 한 번 갱신은,

$$v_i^{(t+1)} \sim P\Big(V_i \mid \mathbf{v}_{<i}^{(t+1)}, \mathbf{v}_{>i}^{(t)}, E = e\Big)$$

앞에서 갱신한 변수는 새 값을, 뒤에서 갱신할 변수는 현재 값을 사용한다.

초기 B_0회 표본을 제외하고 T개 상태를 사용하면,

$$\hat{P}(Q = q \mid E = e) = \frac{1}{T} \sum_{t=B_0+1}^{B_0+T} \mathbf{1}\{Q^{(t)} = q\}$$

$\mathbf{1}$은 조건이 맞으면 1, 아니면 0인 지시함수다.

> 증거와 일치하는 상태 공간을 충분히 탐색해야 한다. 수렴은 적절한 조건 아래 성립하며, 유한 횟수의 반복만으로 정확성이 보장되지는 않는다.

11. 잠재 변수와 EM의 목적함수

이 절부터 X는 관측 데이터 전체, Z는 잠재 변수 전체를 뜻한다.

잠재 변수까지 모두 알면 완전 데이터 로그우도를 사용할 수 있다.

$$\ell_c(\theta; X, Z) = \log P(X, Z \mid \theta)$$

실제로는 Z를 모르므로 가능한 값을 모두 합친 관측 데이터 로그우도를 최대화한다.

$$\boxed{\ell(\theta; X) = \log P(X \mid \theta) = \log \sum_z P(X, z \mid \theta)}$$

로그 안에 합이 있기 때문에 직접 최적화가 어려울 수 있다.

E 단계: 현재 파라미터에서 잠재 변수의 사후분포 계산

$$q_t(z) = P(z \mid X, \theta^{(t)})$$

$$Q(\theta \mid \theta^{(t)}) = \sum_z q_t(z) \log P(X, z \mid \theta)$$

M 단계: 기대 완전 데이터 로그우도 최대화

$$\theta^{(t+1)} = \arg\max_\theta Q(\theta \mid \theta^{(t)})$$

$q_t(z)$는 E 단계에서 구한 뒤 M 단계에서는 고정한다. 여기서 $Q(\theta \mid \theta^{(t)})$는 앞 절의 질의 변수 집합 Q와 다른 기호다.

> E 단계는 잠재 변수의 불확실성을 확률분포로 반영하고, M 단계는 그 분포로 가중한 로그우도를 최적화한다.

12. Jensen 부등식으로 EM 유도

로그 함수는 오목하므로, 가중 평균에 대해 다음 부등식이 성립한다.

$$\log\left(\sum_z q(z)a_z\right) \geq \sum_z q(z)\log a_z, \qquad q(z)\geq 0, \quad \sum_z q(z)=1$$

필요한 지지집합에서 양수인 보조분포 $q(z)$를 도입하면,

$$\begin{aligned}\ell(\theta;X) &= \log\sum_z q(z)\frac{P(X,z\mid\theta)}{q(z)}\\ &\geq \sum_z q(z)\log\frac{P(X,z\mid\theta)}{q(z)}\\ &= \underbrace{\sum_z q(z)\log P(X,z\mid\theta) - \sum_z q(z)\log q(z)}_{\mathcal{F}(q,\theta)}\end{aligned}$$

$\mathcal{F}(q,\theta)$는 관측 로그우도의 하한이다. 이를 ELBO라고 부른다.

현재 파라미터에서 $q_t(z)=P(z\mid X,\theta^{(t)})$로 정하면,

$$\frac{P(X,z\mid\theta^{(t)})}{q_t(z)} = P(X\mid\theta^{(t)})$$

비율이 z와 무관한 상수가 되어 Jensen 부등식의 등호가 성립한다.

$$\mathcal{F}(q_t,\theta^{(t)}) = \ell(\theta^{(t)};X)$$

M 단계에서는 q_t가 고정되어 엔트로피 항도 상수다. 따라서 하한을 최대화하는 것은 $Q(\theta\mid\theta^{(t)})$를 최대화하는 것과 같다.

> E 단계는 현재 위치에서 하한을 로그우도에 맞추고, M 단계는 그 하한을 높인다. [4]

13. EM의 로그우도가 감소하지 않는 이유

앞 절의 하한과 E·M 단계의 성질을 연결하면,

$$\begin{aligned}\ell(\theta^{(t+1)}; X) &\geq \mathcal{F}(q_t, \theta^{(t+1)}) \\ &\geq \mathcal{F}(q_t, \theta^{(t)}) \\ &= \ell(\theta^{(t)}; X)\end{aligned}$$

단계	근거
첫 번째 부등식	$\mathcal{F}$는 로그우도의 하한이다.
두 번째 부등식	M 단계가 고정된 q_t에서 하한을 높인다.
마지막 등식	E 단계가 현재 파라미터에서 하한을 정확히 맞춘다.

따라서 정확한 E 단계와 Q 함수를 감소시키지 않는 M 단계에서는,

$$\boxed{\ell(\theta^{(t+1)}; X) \geq \ell(\theta^{(t)}; X)}$$

증명에서 보장하는 것은 **로그우도의 비감소**다. 초기값에 따라 다른 해에 도달할 수 있으며 전역 최적해는 보장하지 않는다. 유한한 값으로의 수렴에는 로그우도의 상한 등 추가 조건이 필요하다.

변화량을 이용한 종료 기준의 예시는,

$$|\ell(\theta^{(t+1)}; X) - \ell(\theta^{(t)}; X)| < \varepsilon$$

이다. 종료 기준을 만족했다는 사실만으로 전역 최적해를 얻었다고 판단할 수는 없다.

14. 기대 도수로 확률표 갱신

EM을 베이지안 네트워크의 확률표 학습에 적용하면, 완전 데이터의 도수를 **기대 도수**로 바꿔 해석할 수 있다.

완전 관측 데이터의 최대우도 추정은,

$$\hat{\theta}_{ijk} = \frac{N_{ijk}}{\sum_{k'} N_{ijk'}}$$

일부 값이 관측되지 않으면 현재 모델을 이용해 각 표본의 기여도를 확률로 계산한다.

$$\bar{N}_{ijk}^{(t)} = \sum_{n=1}^{N} P\left(X_i = k, \pi_i = j \mid x_{\text{obs}}^{(n)}, \theta^{(t)}\right)$$

$x_{\text{obs}}^{(n)}$는 n번째 표본에서 관측한 부분이다.

E 단계에서 기대 도수를 계산하고, M 단계에서 정규화한다.

$$\boxed{\theta_{ijk}^{(t+1)} = \frac{\bar{N}_{ijk}^{(t)}}{\sum_{k'} \bar{N}_{ijk'}^{(t)}}}$$

고정된 이산 네트워크의 비제약 확률표를 최대우도로 갱신하는 식이며, 분모가 양수인 행에 적용한다.

설명을 위한 예로 특정 부모 조건에서 두 상태의 기대 도수가 7.2와 2.8이면,

$$\theta_1^{(t+1)} = \frac{7.2}{10} = 0.72, \qquad \theta_2^{(t+1)} = \frac{2.8}{10} = 0.28$$

기대 도수는 실제 표본 개수를 확률로 가중해 더하므로 정수가 아닐 수 있다.

> 완전 데이터에서는 실제 도수를 세고, 잠재 변수가 있으면 현재 모델이 계산한 기대 도수를 사용한다.

참고 자료

주 자료: 『단단한 머신러닝』 Chapter 7, 7.4-7.6 및 7.7의 관련 설명.

TAN의 구조 선택, d-분리의 조상 그래프 조건, EM 하한 유도는 아래 자료를 함께 참고했다.

1. Friedman, Geiger, Goldszmidt (1997), Bayesian Network Classifiers. TAN과 조건부 상호정보량.
2. Webb, Boughton, Wang (2005), Not So Naive Bayes: Aggregating One-Dependence Estimators. 저자 연구 목록과 논문 정보.
3. Carnegie Mellon University, 10-708 Lecture 2: Bayesian Networks. d-분리와 모럴 조상 그래프.
4. Andrew Ng, Stanford CS229, The EM Algorithm. Jensen 부등식, EM 하한, 로그우도 비감소.