11주차 _ Bayes 분석

상태	시작 전
날짜	2026년 10월 2일

신용평가 도메인

신용카드 연체 예측 베이지안 네트워크 분석

1. 분석 목적 및 문제 정의

▼ 배경

신용카드 연체는 금융기관에 심각한 손실을 야기하고, 개인의 신용도에 직결되는 중요한 문제이다. 기존의 신용평가 시스템은 정해진 기준에 따라 기계적으로 판단하지만, 다양한 변수 간의 **인과관계**를 종합적으로 고려하지 못한다. 특히 과거 상환 이력, 청구액, 납부액 등이 연체에 미치는 영향을 동시에 파악하면서도 새로운 정보가 들어올 때 확률을 갱신할 수 있는 모델이 필요하다.

▼ 분석 목적

본 분석은 신용카드 고객 데이터(30,000명)를 활용하여, 개인 특성(나이, 성별, 결혼 상태), 신용 정보(한도), 과거 상환 이력(6개월), 청구 및 납부 현황이 **다음 달 채무 불이행(Default)**에 어떤 인과관계로 영향을 미치는지 파악하고, 이를 베이지안 네트워크로 모델링하여 연체 위험도를 예측하는 것을 목적으로 한다.

▼ 연구 문제

1. 개인 특성, 신용 정보, 상환 이력, 재무 지표 중 다음 달 연체에 가장 직결되는 변수(군)는 무엇인가?
2. 이들 변수 간의 인과관계를 베이지안 네트워크로 구조화했을 때, 모델의 예측 정확도는 어느 정도인가?
3. 특정 고객의 프로필이 주어졌을 때, 연체 확률을 얼마나 정확하게 추정할 수 있는가?

---

2. 개요

항목	내용
데이터 크기	N = 30,000 (개인 고객)
목표변수	default.payment.next.month (1=연체, 0=정상)
주요 특성	개인정보, 신용정보, 6개월 상환 이력, 청구/납부 정보

변수

N: 30,000

Client Information

- Num
  - `ID`
- Cat
  - 없음

Demographics

- Num
  - `AGE`
- Cat

- `SEX`, `EDUCATION`, `MARRIAGE`

Credit Information

- Num
  - `LIMIT_BAL`

Repayment Status

- Cat
  - `PAY_0`, `PAY_2`, `PAY_3`, `PAY_4`, `PAY_5`, `PAY_6`

Bill Statement Amount

- Num
  - `BILL_AMT1`, `BILL_AMT2`, `BILL_AMT3`, `BILL_AMT4`, `BILL_AMT5`, `BILL_AMT6`

Previous Payment Amount

- Num
  - `PAY_AMT1`, `PAY_AMT2`, `PAY_AMT3`, `PAY_AMT4`, `PAY_AMT5`, `PAY_AMT6`

Default Payment

- Cat
  - `default.payment.next.month`

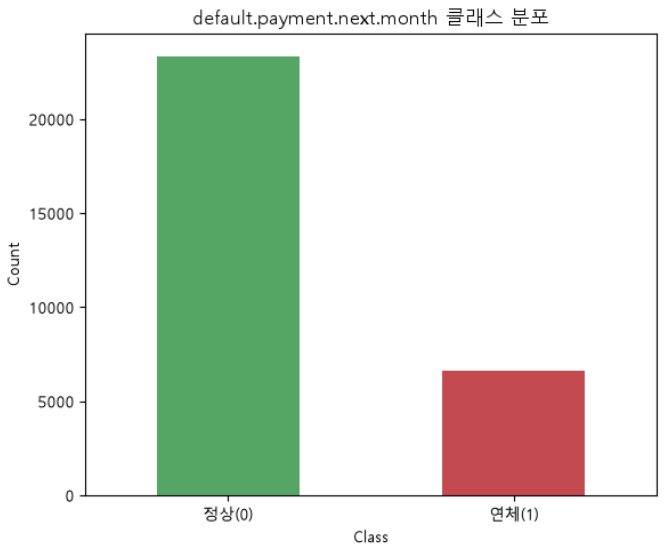
---

3. 데이터 전처리

▼ 1) 변수 제외

- `ID` : 식별자, 분석 의미 없음
- `PAY_0` : 정보 누수 가능성을 고려하여 제외
- `BILL_AMT1`, `PAY_AMT1` : PAY_0과 동일 시점이므로 함께 제외

▼ 2) Target



분포 불균형 → Train/Test 시 **stratify** 적용

▼ 3) Nomial Feature

a. **EDUCATION**

- (1=graduate school, 2=university, 3=high school, 4=others, 5=unknown, 6=unknown)
- 명시되지 않은 값 0 존재, 5, 6의 값은 "알 수 없음"
- **4(others)**로 통합

b. **MARRIAGE**

- Marital status (1=married, 2=single, 3=others)
- 명시되지 않은 값 0 존재
- **3(others)**로 통합

c. **PAY_2 - PAY_6**

- (-1=pay duly, 1=payment delay for one month, 2=payment delay for two months, … 8=payment delay for eight months, 9=payment delay for nine months and above)
- 명시되지 않은 값 0, -2 존재
- 검증
  - 검증 원리

    같은 월의 청구액·납부액·연체율을 비교해, 각 값이 가정한 금액 패턴(청구 없음, 리볼빙)과 일치하는지 대조
  - 결론

-2	• 청구액 0 이하 56~71% • 29~44%는 청구액 양수 • 평균 청구액(2,467~5,138) → **청구 없음/소액**
0	• 청구액 0 이하 비율 0.018~0.038 • 평균 청구액 58,249~74,629 • payamt/bill 0.071~0.091 (청구액의 7~9%만 납부) → **리볼빙(최소 금액만 납부)**

▼ 4) Train/Test

a. **ratio**

train/test (0.7/0.3)

b. **target**

`target` 기준 stratify 적용

	train_count	train_ratio	test_count	test_ratio
정상(0)	16355	0.7788	7009	0.7788
연체(1)	4645	0.2212	1991	0.2212

▼ 5) Numeric Feature

a. **파생 변수 생성**

- BILL_AMT2~6, PAY_AMT2~6 → AVG_BILL_AMT, AVG_PAY_AMT
- UTILIZATION = AVG_BILL_AMT / LIMIT_BAL
- PAYMENT_RATE = AVG_PAY_AMT / AVG_BILL_AMT
- BALANCE_RATE = (AVG_BILL_AMT − AVG_PAY_AMT) / LIMIT_BAL (PAYMENT_RATE 비교 후보)
- AVG_BILL_AMT 0 이하 → UTILIZATION, PAYMENT_RATE를 NaN 처리 (Train 1,046건, Test 466건)

- 음수 청구액 → 초과 납부 가능성, 삭제하지 않고 평균에 반영

b. **이상치 확인**

- 검증 원리

  Train 기준 IQR 경계로 이상치 개수를 산출하고, 이상치 포함 여부별 연체율을 비교

- 결론

구분	결과
이상치 포함 행	Train 7,198건 (34.28%)
연체율	이상치 없음 0.255 / 있음 0.157
금액 변수 이상치	7.9~10.1%

→ 제거 시 표본 34% 손실, 연체율이 낮은 그룹이므로 제거하지 않고 유지

c. **이산화 (Train 기준 분위수 경계)**

- AGE → 도메인 기반 4구간 (20대, 30대, 40대, 50대 이상)
- LIMIT_BAL, BALANCE_RATE → 분위수 4구간
- UTILIZATION → U0(NaN) + 분위수 3구간
- PAYMENT_RATE → R0(NaN) + 분위수 3구간
- NaN → 삭제·대체 없이 U0, R0 범주로 보존
- 극단값 → 분위수 기반이므로 최상위 구간에 포함

4. 네트워크 구조 설계

▼ 1) 전문가 지식 기반 구조

```
=== 1) 전문가 지식 기반 구조 검증 ===
```

	구조	노드 수	간선 수	사이클 없음	시간 역행 간선 수	개인 특성 유입 간선 수	목표변수 자식 노드 수
0	전문가(PAYMENT_RATE)	13	17	True	0	0	0
1	전문가(BALANCE_RATE)	13	17	True	0	0	0

- 개인 특성(SEX, EDUCATION, MARRIAGE, AGE_BIN) → LIMIT_BAL_BIN
- LIMIT_BAL_BIN → PAY_6 → PAY_5 → PAY_4 → PAY_3 → PAY_2 (시간 순서)
- PAY_2, LIMIT_BAL_BIN → UTILIZATION_BIN, PAYMENT_RATE_BIN
- PAY_2, UTILIZATION_BIN, PAYMENT_RATE_BIN, LIMIT_BAL_BIN → default.payment.next.month
- 노드 13개, 간선 17개 (정의 기준)
- 비교 후보 → PAYMENT_RATE_BIN을 BALANCE_RATE_BIN으로 대체한 구조

▼ 2) 데이터 기반 구조 (Hill Climbing, Train만 사용)

```
=== 2) 데이터 기반 학습 구조 검증 ===
```

	구조	노드 수	간선 수	사이클 없음	시간 역행 간선 수	개인 특성 유입 간선 수	목표변수 자식 노드 수
0	학습(BIC)	11	14	True	0	0	0
1	학습(K2)	13	56	True	0	0	0

- 구조 제약 조건
  - 목표 변수는 자식 노드를 갖지 않음
  - PAY 변수 간 시간 역행 간선 금지

    - 개인 특성은 외생 변수로 취급 (유입 간선 금지)
- 검증 원리
  Hill Climbing 탐색 후 사이클, 시간 역행, 개인 특성 유입, 목표변수 자식 노드 여부를 검사

→ 제약 조건 모두 충족

→ BIC는 간선이 적어 간결한 구조 (그래프에 SEX, MARRIAGE 미표시, 간선 없음으로 판단), K2는 간선 56개로 복잡한 구조

▼ 3) 비교 모델

- Naive Bayes (기준선), 전문가 구조 2종(PAYMENT_RATE / BALANCE_RATE), 학습 구조 2종(BIC / K2)
- 파라미터 추정 → MLE vs 라플라스 평활 (Dirichlet, pseudo_counts=1)

	간선 수	전문가 구조와 공통	해당 구조에만 존재	목표변수 부모 노드
전문가	17	17	0	[LIMIT_BAL_BIN, PAYMENT_RATE_BIN, PAY_2, UTILI...
학습(BIC)	14	8	6	[LIMIT_BAL_BIN, PAY_2]
학습(K2)	56	12	44	[PAY_2, PAY_4, UTILIZATION_BIN]

