Chapter 7. 베이지안 분류기.

7.1 베이지안 결정이론.

: 확률 기반, 오류로 인한 손실을 최소화하는 최적의 분류 문제 해결

① 조건부 기대손실

$$R(c_i|x) = \sum \lambda_{ij} P(c_j|x)$$

: 주어진 샘플 x가 주어졌을 때 클래스를 오판할 확률(기대측도)

λ_{ij} (손실) × $P_e(c_j|x)$ (오판확률) 의 합

= 기대 손실

② 목적함수

: 기대손실을 최소화하는 판별기준 $h : x \to y$ 찾기.

$$h^*(x) = \cancel{\text{argmax}} \ \text{argmin} \ R(c|x)$$

$h^*(x)$: '베이즈최적 분류기'

$R(h^*)$: h^* 최적 분류기에서의 기대손실

= 분류기의 도달 가능한 최적 성능

= 이론적 최대 정확도

= '베이즈리스크'

③ 손실 λ_{ij}

$$\lambda_{ij} \begin{cases} 0 & \text{if } i=j \quad (\text{정확}) \\ 1 & \text{else} \quad (\text{오류}) \end{cases}$$

2 정의 (분류문제)

: 정확하면 손실 = 0

오류면 손실 = 1

morning glory

DATE. NO.

$R(c|x_0) = 1 - P(c|x)$

이때 $R(c|x)$는 리스크라 한다.

모두 맞출때 $\lambda_i = 0$ 이고 $R(c|x) = 1$.

모두 X일때 $\lambda_i = 1$ 이고 $R(c|x) = 0$

∴ 목적함수 $h^*(x) = \underset{c \in y}{\operatorname{argmax}}\, P(c|x)$.

: 사후확률 $P(y|x)$의 최대라 문제

---

④ 생성 모델과 '우도' (Likelihood)

~~생성 모델들~~

- 베이즈 결정 이론의 핵심 : $P(c|x)$ 구하기

  즉, 데이터 샘플(x)가 주어졌을 때 c의 확률 (사후확률)

- $P(c|x)$는 현실적으로 구하기 힘듦.

  ! 추정. 모델링 필요

- $P(c|x)$ 모델링
  - 판별모델 : Tree, BP 신경망, SVM
  - 생성모델 : Bayes, Naive Bayes

DATE. NO.

- 판별 모델

: 직접 $P(C|x)$를 모델링 후 C예측

- 생성 모델

: '결합확률분포' 모델링 후 $P(C|x)$ 구하고 C예측

↓

$P(x|C)$

: 각각 C에 속할 때, 그 확률분포를 확률적으로 모델링

ex) 귀의 모양이 고양이에 속할 확률 / 강아지에 속할 확률

- 우도

이때 $P(x|C)$를 '우도', '가능도'라고 함

$P(C)$: 사전확률 (X관측전 C에 대한 믿음)

$P(C|x)$: 사후확률 (X관측후 C에 대한 믿음)

$P(x|C)$: 가능도, 우도 (C가 주어졌을 때 해당 확률분포에서 x의 확률)

$$P(C|x) = \frac{P(C) \times P(x|C)}{P(x)}$$ (베이지안 정리)

$P(x)$: 증거팩터 (모든 클래스에 대해 동일)

$P(x|C)$: 출현빈도 계산 어려움 → MLE, 나이브베이즈

$P(C)$: 샘플공간에서 클래스가 차지하는 비율

(단 큰수 + 샘플의 독립항등분포 가정)

DATE. NO.

7.2 MLE 최대우도 추정 vs 속성조건 독립가설 (Naive Bayes)

① 공통문제

: 빈도 기반 추정이 어려운 우도 ($P(x|c)$)

$P(x_i|c)$.

- 이유?

속성이 d개, 샘플개수 i개 일때, 이전값

C의 공간크기: d^2) 현격한 차이

샘플 x_i의 공간크기: i

$\frac{|x_i|}{|c|} \approx 0$.

② MLE (최대우도 추정)

-가정 : 우도는 정해진 형식 + 파라미터 θ에 의존

ex) X는 특정한 분포를 따르고 이분포는 θ에만 의존

$\Rightarrow X \sim N(\mu, \sigma^2)$

분포 θ

$\Rightarrow P(x|c) \Rightarrow P(x|\theta_c)$

- 확장 (샘플공간)

$$P(D_c|\theta_c) = \prod_{x \in D_c} P(x|\theta_c)$$

$\because x_i \in D_c$는 서로 독립 항등분포

$P(x_i, x_j) = P(x_i) \times P(x_j)$

DATE. NO.

$$LL(\theta_c) = \log P(D_c|\theta_c)$$
$$= \sum_{x \in D_c} \log P(x|\theta_c)$$

: 로그우도를 활용한 MLE의 수도식

- 왜 log 사용?

언더플로 문제

ex) $P(x|\theta_c) = 0.1$로 동일 가정

$P(D_c|\theta_c) = \prod P(x|\theta_c)$

$= 0.1 \times 0.1 \times 0.1 \cdots$

$= 0.1^{n}$ 꽉 0.

$\Rightarrow \log(ab) = \log(a) + \log(b)$ 이용,

곱 문제를 합 문제로 전환

- MLE의 목적함수

$$LL(\theta_c) = \log P(D_c|\theta_c)$$
$$= \sum \log(P(x|\theta_c)$$

$$\hat{\theta}_c = \arg\max \sum P(x|\theta_c)$$
$$= \arg\max \not{\Sigma} L(\theta_c)$$

: θ_c가 주어졌을 때 샘플의 확률 (가능도) 최대화

DATE. NO.

- 단점.

: 확률분포 가정에 의존,

가정 오류시 무의미한 결론

(ex) $X \sim N$ 이 아닌 분포를 따를 때?

③ 나이브베이즈 분류기

: $P(x|c)$를 구함에 있어 빈도문제를 '속성 조건독립 가설' 이용,

속성들의 결합확률로 추정

- 속성 조건 독립 가설

: 모든의 클래스에 대해

각 속성은 서로 독립적

: 속성이 각각 독립적으로 분류결과에 영향

$$- P(c|x) = \frac{P(c) \times P(x|c)}{P(x)} = \frac{P(c)}{P(x)} \times \prod_{i=1} P(x_i|c)$$

x_i : i번째 속성 상에서 x의 값

$$h_{nb}(x) = \arg\max P(c) \prod P(x_i|c)$$

$$P(c) = \frac{|D_c|}{|D|}$$

$$P(x_i|c) = \frac{|D_{c,x_i}|}{|D_c|} = \frac{1}{\sqrt{2\pi}\sigma_{ci}} \exp\left(\frac{(x_i - u_{ci})^2}{-2\sigma_{ci}^2}\right)$$

DATE. NO.

- 라플라시안 보정 (평활화)

특정 값의 비관측으로 모든 특정값 조합의 $P(x_i|c) = 0$ 이됨.

$$\hat{P}(c) = \frac{|D_c|+1}{|D|+N}, \quad \hat{P}(x_i|c) = \frac{|D_{c,x_i}|+1}{D_c+N_i}$$

N: 클래스 개수

N_i: i번째 속성의 가능한 값

DATE. NO.

- 라플라시안 보정 (평활화)

특정 값의 의관측으로 모든 특정값 조합의 $P(x_i|c) = 0$ 이됨.

$$\hat{P}(c) = \frac{|D_c|+1}{|D|+N}, \quad \hat{P}(x_i|c) = \frac{|D_{c,x_i}|+1}{D_c+N_i}$$

N: 클래스 개수

N_i: i번째 속성의 가능한 값

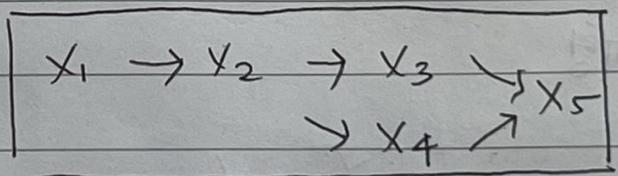
7.5 베이지안 네트워크 Bayesian network

① DAG와 CPT로 구성

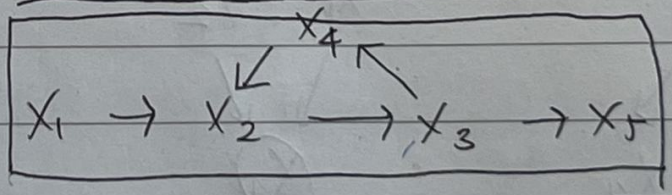
- DAG란?

*Acyclic을 쓰는 이유?
순환구조 일때
A→B→C→A에서
B를 알기위해 A,
C를알기위해 B,
A를 알기위해 C를
순환적으로,
전체확률을 알지못함.

Directed Acyclic Graph.
변수 간 의존관계(→) 그래프구조
순환 관계X



→ DAG



→ DAG X

- CPT: 결합확률분포를 조건부 확률표로 나타냄.

	Y_1	Y_2
X_1	0.1	0.9
X_2	0.4	0.6

$P(X_1, Y_1) = 0.1$

DATE NO.

② BN의 정의요소

$B = \langle G, \theta \rangle$

G: 구조 θ: 의존관계 정량화 파라미터.

$P_B(x_i | \pi_i)$ 포함.

ex) $X_1 \rightarrow X_2 \rightarrow X_3$

전체확률 P = $P(X_1) \times P(X_2|X_1) \times P(X_3|X_2)$

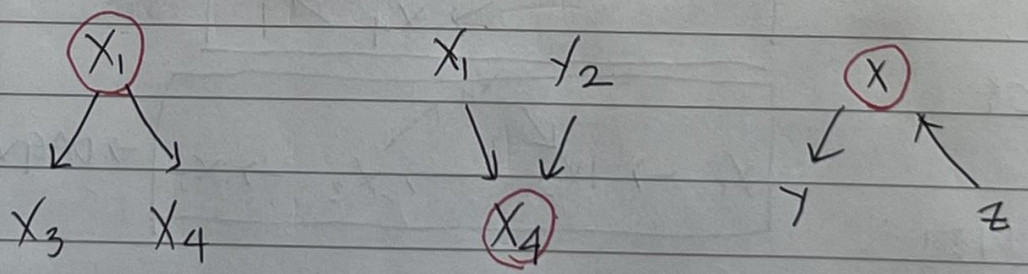
③ 구조

: 변수 간 조건 독립성 표현 용이

$$P_B(x_1, x_2, \cdots x_n) = \prod_{i=1}^{d} P_B(x_i | \pi_i)$$

부모속성

- 의존관계 유형



$X_3 \perp X_4 | X_1$ $X_1 \perp\!\!\!\perp X_2 | \sim X_4$ $Y \perp Z | X$

X_1을 알 때 X_4를 모를 때 X를 알 때

X_3과 X_4는 C.I X_1과 X_2는 주변독립 Y, Z. C.I

DATE NO.

④ 학습

: 네트워크 구조 정하기 → 각 노드별 조건 확률 계산

↓

- 스코어 탐색 방법 : 정보이론 규범 (MDL 규범)

코드비트수와 코드저장 최소화

↓

- 스코어 함수 (최소화 목적)

$$s(B|D) = f(\theta)\cdot|B| - LL(B|D)$$

- $f(\theta)$: 코드 저장소
- $|B|$: 파라미터 개수 → 구조적 위험
- $LL(B|D)$: D에 대한 B의 가능도 → 경험적 위험.

$f(\theta)$ = 1 : AIC func $|B| - LL(B|D)$

$\frac{1}{2}\log m$: BIC func $\frac{1}{2}\log m|B| - LL(B|D)$

0 : MLE

고정 G를 알때, $f(\theta)\cdot|B|$는 상수 → $s(B|D) = a - LL(B|D)$

→ θ의 MLE 문제.

DATE. NO.

⑤ 추론.

- BN → 학습 → (쿼리) 정답

승거. 주론

주어진 값 알고싶은 정보

$P(Q \mid E)$를 결합확률 분포로 '정확추론'

$\begin{cases} Q = \{Q_1 \sim Q_n\} \\ E = \{E_1 \sim E_k\} \end{cases}$

NP-HARD: 정확추론 π_1 可.

- 깁스 샘플링 Gibbs sampling. — 근사추론

초기 증거 변수 고정후 관측값을 달리하여 샘플링

$$P(Q=q \mid E=e) \simeq \frac{n_q}{T}$$

n_q: T번 샘플링 中 q와 일치하는 경우 수

(ex) Q = 비, E = 우산

우산 고정 → Q로 B 안에서 샘플링

→ 비, ~비, ~비, 비 .... (T번)

$$P(Q=\text{비}, E=\text{우산}) = \frac{n_{q,}}{T}$$

DATE NO.

- 랜덤워크 & 마르코프 연쇄 → 정상분포 수렴

랜덤워크 : 무작위 추출

마르코프 연쇄 : 다음 상태는 현재 값에만 의존

정상분포 : 각 상태 비율은 일정한 분포로 안정적

7.6 EM 알고리즘

: 불완전 훈련 샘플 상황에서 *파라미터

$$LL(\theta \mid X, Z) = \ln p(X, Z \mid \theta) \Rightarrow \ln \sum_Z p(X, Z \mid \theta)$$

X : 관측, Z : 은닉(미관측)

- 주변우도 최대화.

: : 조기댓값 계산,

관측 데이터의 주변 우도를 최대화.

- EM 알고리즘

E step : $\theta^{known}, X \rightarrow {}^{*}Z$

M step : $Z^{known} \rightarrow$ MLE

$\theta^t \rightarrow E(Z) = Z^t$ ($\hat{Z}$) → $X, Z^t \rightarrow \theta^{t+1}$ MLE