

7.1 베이즈 결정론.

: 작을 개념 | 다양한 손익을 포함하는 최적의 분류 문제 해결

① 조건부 기대손익

$$R(c|x) = \sum \lambda_{ij} P(c_j|x)$$

: 어떤 샘플 x 가 주어졌을 때 클래스를 포함한 확률(기대손익)

$$\lambda_{ij} (\text{손익}) \times p_{ij}(c_j|x) (\text{확률}) \text{ 이 곱}$$

$$= \text{기대 손익}$$

② 목적함수

: 기대손익을 최대화하는 패배자 $h: X \rightarrow Y$ 찾기.

$$h^*(x) = \underset{c \in Y}{\operatorname{argmin}} R(c|x)$$

$h^*(x)$: '베이즈 최적 분류기'

$R(h^*)$: h^* 최적 분류기에서의 기대손익

= 분류기의 손익 가능한 최적 손익

= 이론적 최대 정확도

= '베이즈 리스크'

③ 손익 λ_{ij}

$$\lambda_{ij} = \begin{cases} 0 & \text{if } i=j \text{ (정확)} \\ 1 & \text{else (오류)} \end{cases} \quad \begin{matrix} \text{2 개의} \\ \text{분류 문제} \end{matrix}$$

정확하면 손익 = 0

오류면 손익 = 1

$$R(c|x_0) = 1 - P(c|x)$$

이때 $R(c|x)$ 는 리스크라 다름.

모두 맞출때 $\lambda_{ij} = 0$ 이므로 $R(c|x) = 1$.

모두 틀릴때 $\lambda_{ij} = 1$ 이므로 $R(c|x) = 0$

∴ 목적함수 $h^*(x) = \underset{c \in Y}{\operatorname{argmax}} P(c|x)$

: 사후 확률 $P(y|x)$ 의 최대화 문제

④ 생성 모델과 '우도' (Likelihood)

생성 모델

- 베이즈 결정 이론의 핵심: $P(c|x)$ 구하기

즉, 데이터 샘플(x)과 주어진 c 의 확률 (사후 확률)

- $P(c|x)$ 는 현실적으로 구하기 힘들.

! 추정, 모델링 필요

$P(c|x)$ 모델링

- 판별 모델: Tree, BP 신경망, SVM
- 생성 모델: Bayes, Naive Bayes

- 판별 모델

: 확률 $P(c|x)$ 를 모델링 후 c 예측

- 생성 모델

: '확률 분포' 모델링 후 $P(c|x)$ 구하고 c 예측

↓

$$P(x|c)$$

: x 가 c 에 속할 때, 그 확률 분포를 확률적(확률) 모델링

(x) 구의 모양이 모양에 속할 확률 / 강하게 속할 확률

- 우도

이때 $P(x|c)$ 를 '우도', '가능도'라고 함

$P(c)$: 사전 확률 (X 관측전 (예) 대한 믿음)

$P(c|x)$: 사후 확률 (X 관측후 (예) 대한 믿음)

$P(x|c)$: 가능도. 우도 (c 가 주어졌을 때 해당 확률 분포에서 x 의 확률)

$$P(c|x) = \frac{P(c) \times P(x|c)}{P(x)} \quad (\text{베이즈의 정리})$$

$P(x)$: 증거 팩터 (오류 가능성에 대해 믿음)

$P(x|c)$: 훈련 데이터로 계산 어려움 → MLE, 나이브 베이즈

$P(c)$: 샘플 공간에서 클래스가 차지하는 비율

(단 쿼리 + 샘플의 독립함 분포 가정)

MLE

7.2 최대 우도 추정 VS 독립 조건 독립 가정 (Naive Bayes)

① 공통 문제

: 빈도 기반 추정이 어려운 우도 $P(x|c)$

$$P(x|c)$$

- 이유?

샘플이 1개, 샘플 개수 n 가 클 때, 이진 값

c 의 공간 크기: 2^n (현실적으로)

샘플 x 의 공간 크기: n

$$\frac{|x|}{|c|} \approx 0$$

② MLE (최대 우도 추정)

가정: 우도는 정해진 형식 + 파라미터 θ 에 의존

(x) X 는 특정한 분포를 따르고 이분포는 θ 에만 의존

$$\Rightarrow X \sim N(\mu, \sigma^2)$$

↑
분포 θ

$$\Rightarrow P(x|c) \Rightarrow P(x|\theta_c)$$

- 확장 (샘플 공간)

$$P(D_c|\theta_c) = \prod_{x \in D_c} P(x|\theta_c)$$

∴ $x_i \in D_c$ 는 서로 독립함 분포

$$P(x_i, x_j) = P(x_i) \times P(x_j)$$

$$LL(\theta_c) = \log P(D_c|\theta_c)$$

$$= \sum_{x \in D_c} \log P(x|\theta_c)$$

: 로그우도를 확장한 MLE의 유도

- 대 $\log$ 사용?

연산 용이 문제

(x) $P(x|\theta_c) = 0.1$ 로 동일 가정

$$P(D_c|\theta_c) = \prod P(x|\theta_c)$$

$$= 0.1 \times 0.1 \times 0.1 \dots$$

$$= 0.1^n \approx 0$$

$$\Rightarrow \log(ab) = \log(a) + \log(b) \text{ 이용}$$

곱 문제를 합 문제로 전환

- MLE의 목적함수

$$LL(\theta_c) = \log P(D_c|\theta_c)$$

$$= \sum \log P(x|\theta_c)$$

$$\hat{\theta}_c = \underset{\theta_c}{\operatorname{argmax}} \sum P(x|\theta_c)$$

$$= \underset{\theta_c}{\operatorname{argmax}} LL(\theta_c)$$

: θ_c 가 주어졌을 때 샘플의 확률 (가정) 최대화

- 단점.

: 확률 분포 가정에 의존,

가정 옳지 않으면 잘못된 결과

(x) $X \sim N$ 이 아닌 분포를 따른 때?

③ 나이브 베이즈 분류기

: $P(x|c)$ 를 구함에 있어 빈도 문제를

'독립 조건 독립 가정' 이용,

독립 조건 독립 가정으로 추정

- 독립 조건 독립 가정

: 속성의 출현에 대해

각 속성은 서로 독립적

: 속성이 각각 독립적으로 분포 확률에 영향

$$P(c|x) = \frac{P(c) \times P(x|c)}{P(x)} = \frac{P(c)}{P(x)} \times \prod_{i=1}^n P(x_i|c)$$

x_i : i 번째 속성에서 차지 값

$$h_{nb}(x) = \underset{c}{\operatorname{argmax}} P(c) \prod P(x_i|c)$$

$$P(c) = \frac{|D_c|}{|D|}$$

$$P(x_i|c) = \frac{|D_{c,x_i}|}{|D_c|} = \frac{1}{\sqrt{2\pi}\sigma_c} \exp\left(-\frac{(x_i - \mu_c)^2}{2\sigma_c^2}\right)$$

- 라플라스 보정 (평활화)

특정 값이 빈도값으로 0을 출력할 확률의 $P(x_i|c) = 0$ 이됨.

$$\hat{P}(c) = \frac{|D_c| + 1}{|D| + N}, \quad \hat{P}(x_i|c) = \frac{|D_{c,x_i}| + 1}{|D_c| + N_i}$$

N : 클래스 개수

N_i : i 번째 속성의 가능한 값