CHAPTER

07 베이지안 분류기

7.1 베이지안 결정 이론

베이지안 결정 이론Bayesian decision theory은 확률 프레임하에서 의사결정을 실행하는 기본 방법입니다. 분류 문제에서 관련 확률을 모두 알 수 있다는 이상적인 상황에서 베이지안 결정 이론은 어떻게 이런 확률들과 오판으로 인한 손실에 기반해 최적의 분류를 할 수 있을까를 고민합니다. 우리는 다중 분류를 예로 베이지안 결정 이론의 기본 원리를 살펴보겠습니다.

'기대 손실'은 '위험(risk)'이다.

먼저, N개의 분류 레이블 $\mathcal{Y} = \{c_1, c_2, \ldots, c_N\}$이 있고, λ_{ij}는 실제 레이블이 c_j인 샘플이 c_i로 잘못 분류했을 때 발생하는 손실이라고 가정해 봅시다. 사후 확률 $P(c_i \mid \boldsymbol{x})$에 기반하여 샘플 $\boldsymbol{x}$를 c_i로 분류했을 때 발생하는 기대 손실expected loss을 구할 수 있습니다. 즉, 조건 리스크conditional risk를 식 7.1을 통해 구할 수 있습니다.

$$R(c_i \mid \boldsymbol{x}) = \sum_{j=1}^{N} \lambda_{ij} P(c_j \mid \boldsymbol{x}) \,. \qquad \text{식 7.1}$$

우리의 목적은 판별 기준 $h : \mathcal{X} \mapsto \mathcal{Y}$를 찾아 전체 리스

$$R(h) = \mathbb{E}_{\boldsymbol{x}}\left[R\left(h\left(\boldsymbol{x}\right) \mid \boldsymbol{x}\right)\right] \,. \qquad \text{식 7.2}$$

당연한 이야기지만, 각 샘플 $\boldsymbol{x}$에 대해 h가 조건 리스크 $R(h(\boldsymbol{x}) \mid \boldsymbol{x})$를 최소화할 수 있다면 전체 리스크 $R(h)$ 또한 최소화될 수 있습니다. 따라서 베이즈 결정 규칙Bayes decision rule이 만들어집니다. 전체 리스크를 최소화하려면 각 샘플에서 조건 리스크 $R(c \mid \boldsymbol{x})$를 최소화할 수 있는 클래스 레이블을 선택하면 됩니다. 즉, 식 7.3입니다.

$$h^*(\boldsymbol{x}) = \arg\min_{c \in \mathcal{Y}} R(c \mid \boldsymbol{x}) \ , \qquad \text{식 7.3}$$

이때 h^*는 **베이즈 최적 분류기**Bayes optimal classifier라고 부르고 이에 대응하는 전체 리스크 $R(h^*)$는 **베이즈 리스크**Bayes risk라고 부릅니다. $1 - R(h^*)$는 분류기가 도달할 수 있는 최적의 성능을 나타내고, 머신러닝을 통해 생성한 모델이 이론적으로 달성할 수 있는 정확도의 최댓값을 뜻합니다.

오차율은 0/1 손실 함수에 대응한다. 6장을 참조하라.

만약 목표가 분류기 오차율을 최소화하는 것이라고 한다면 오판으로 인한 손실 λ_{ij}는 다음과 같이 나타낼 수 있습니다.

$$\lambda_{ij} = \begin{cases} 0, & \text{if } i = j \ ; \\ 1, & \text{otherwise}, \end{cases} \qquad \text{식 7.4}$$

이때 조건 위험은 식 7.5이고, 따라서 분류 오차율을 최소화하는 베이즈 최적 분류기는 식 7.6이 됩니다.

$$R(c \mid \boldsymbol{x}) = 1 - P(c \mid \boldsymbol{x}) \ , \qquad \text{식 7.5}$$

$$h^*(\boldsymbol{x}) = \arg\max_{c \in \mathcal{Y}} P(c \mid \boldsymbol{x}) \ , \qquad \text{식 7.6}$$

즉, 각 샘플 $\boldsymbol{x}$에 대해 사후 확률 $P(c \mid \boldsymbol{x})$를 최대화할 수 있는 클래스 레이블을 선택하는 것입니다.

주의해야 할 것은, 이는 확률 프레임으로 머신러닝을 이해하는 것이다. 사실상 많은 머신러닝 기술은 사후 확률 계산 없이도 정확한 분류를 진행할 수 있다.

여기서 우리는 베이즈 결정 규칙을 사용하여 결정 위험을 최소화하려면 먼저 사후 확률 $P(c \mid \boldsymbol{x})$를 얻어야 한다는 것을 어렵지 않게 알아차릴 수 있습니다. 그러나 현실 문제에서 사후 확률을 직접적으로 얻는 것은 어렵습니다. 이런 관점에서 보면, 머신러닝을 통해 실현하려는 것은 유한한 훈련 샘플 데이터에 기반하여 최대한 정확하게 사후 확률 $P(c \mid \boldsymbol{x})$를 예측하는 것으로 볼 수 있습니다. 대략적으로는 두 가지 전략이 있습니다. 하나는 $\boldsymbol{x}$가 주어졌을 때 직접 $P(c \mid \boldsymbol{x})$을 모델링해 c를 예측하는 **판별 모델**discriminative models이고, 또 하나는 먼저 결합 확률 분포 $P(\boldsymbol{x}, c)$를 모델링한 후 이를 통해 $P(c \mid \boldsymbol{x})$를 얻는 **생성 모델**generative models입니다. 우리가 앞서 소개한 의사결정 트리, BP 신경망, 서포트 벡터 머신 등은 판별식 모델 범위에 속합니다. 생성 모델은 반드시 식 7.7을 고려해야 합니다.

$$P(c \mid \boldsymbol{x}) = \frac{P(\boldsymbol{x}, c)}{P(\boldsymbol{x})} \ . \qquad \text{식 7.7}$$

베이즈 정리에 기반해 $P(c \mid \boldsymbol{x})$는 다음처럼 작성할 수 있습니다.

$$P(c \mid \boldsymbol{x}) = \frac{P(c)\, P(\boldsymbol{x} \mid c)}{P(\boldsymbol{x})}, \qquad \text{식 7.8}$$

여기서 $P(c)$는 사전확률prior probability입니다. $P(\boldsymbol{x} \mid c)$는 클래스 레이블 c에 대한 샘플 $\boldsymbol{x}$의 **클래스 조건 확률**class-conditional probability 혹은 **우도**likelihood라고 합니다. $P(\boldsymbol{x})$는 증거 팩터evidence factor를 정규화하는 데 사용됩니다. 주어진 샘플 $\boldsymbol{x}$에 대해, 증거 팩터 $P(\boldsymbol{x})$와 클래스 레이블은 무관하고, 따라서 $P(c \mid \boldsymbol{x})$를 예측하는 문제는 어떻게 훈련 데이터 D로 사전 확률 $P(c)$와 우도 $P(\boldsymbol{x} \mid c)$를 계산하는가에 대한 문제로 전환됩니다.

$P(\boldsymbol{x})$는 모든 클래스에 대해 동일하다.

쉬운 논의를 위해 모든 속성이 이산값이라고 가정한다. 연속 속성에 대해서는 확률질량 함수 $P(\cdot)$를 확률밀도 함수 $P(\cdot)$로 바꿀 수 있다.

클래스 사전 확률 $P(c)$는 샘플 공간에서 각 클래스 샘플이 차지하는 비율을 나타냅니다. 대수의 법칙에 근거해 훈련 세트가 충분한 독립항등분포 샘플을 포함하고 있을 때 $P(c)$는 각 클래스 샘플의 출현빈도를 통해 계산해 낼 수가 있습니다.

7.3절을 참조하라.

클래스 조건 확률 $P(\boldsymbol{x} \mid c)$는 $\boldsymbol{x}$에 관한 모든 속성의 결합 확률이 필요한데, 직접적으로 샘플 출현빈도만으로 계산하기는 어렵습니다. 예를 들어, 샘플의 d개 속성이 모두 이진값이라고 가정한다면, 샘플 공간에는 2^d개 가능한 값이 있을 것입니다. 현실 응용 중에서 이 값은 샘플 데이터 수 m과 큰 차이가 납니다. 즉, 많은 샘플값이 훈련 세트에 없다는 뜻입니다. 더불어 '관측되지 못한'과 '출현빈도가 0'은 다른 개념이고, 따라서 직접적으로 빈도를 사용하여 $P(\boldsymbol{x} \mid c)$를 계산하는 것은 어려운 일입니다.

* d개의 속성 $x_1, x_2, \cdots x_d$가 각각 독립적으로 0 or 1의 두가지 값 중 하나를 가진다 → 모두 조합한 $x = (x_0 x_2, \cdots, x_d)$가 가질 수 있는 전체 경우의 수는 다음과 같이 계산 $2 \times 2 \times 2 \times \cdots \times 2 = 2^d$ ($x_1, x_2, x_3, \cdots x_d$)

* 훈련 데이터에 없으니 빈도 = 0 → 확률 = 0으로 계산
: 실제로는 존재 가능한 (우연히 샘플링 되지 않았을 뿐인) 사건에 확률 0 → 심각한 오류

7.2 최대 우도 추정

클래스 조건 확률을 구하기 위해 자주 사용되는 전략은 먼저 모종의 정해진 확률 분포 형식이 있다고 가정한 후 훈련 샘플에 기반해 확률 분포의 파라미터를 추정하는 전략입니다. 구체적으로 클래스 c에 관련된 클래스 조건 확률을 $P(\boldsymbol{x} \mid c)$로 기록하고, $P(\boldsymbol{x} \mid c)$가 정해진 형식이 있고 파라미터 벡터 $\boldsymbol{\theta}_c$에 의해서만 결정된다고 가정해 보겠습니다. 우리의 목적은 훈련 세트 D를 이용하여 파라미터 $\boldsymbol{\theta}_c$를 추정하는 것입니다. 더 명확히 하고자 우리는 $P(\boldsymbol{x} \mid c)$를 $P(\boldsymbol{x} \mid \boldsymbol{\theta}_c)$로 표기하겠습니다.

연속 분포하에서 확률밀도 함수 $p(\boldsymbol{x}|c)$이다.

* 수학적 표기 정리
- c : 특정 클래스(레이블)
- $P(x|c)$: 클래스 c에서 샘플 x가 나타날 클래스 조건 확률
- θ_c : 클래스 c의 확률분포를 결정짓는 파라미터 벡터
- D (D_c) : 훈련 세트 (클래스 c에 속하는 훈련 샘플들)

↳ 확률이 클래스 c 자체가 아닌 그 클래스를 대표하는 파라미터 θ_c에 의해 완전히 결정

최대우도 추정
Maximum Likelihood Estimation, MLE

- 어떤 정해진 확률 분포 형식이 있다는 가정
→ 훈련 샘플에 기반해 확률 분포의 파라미터를 추정하는 전략

* 왜 유용한가?

방식	필요한 정보량
직접 빈도 계산 ($P(x\|c)$)	2^d개 (또는 무한대에 가까운) 확률값 전부
파라미터 추정 방식	분포를 결정하는 파라미터 벡터 α_c 몇개

속성 수 d가 커도 평균 벡터, 공분산 행렬만 필요 → $2^d \gg m$ 문제 해결

* 목적의 전환

훈련세트 D를 이용해 파라미터 α_c 추정

$P(x|c) \rightarrow P(x|\alpha_c)$

클래스 조건 확률 자체를 구하는 것 x → 파라미터 α_c를 추정하는 것

↳ 확률이 클래스 c 자체가 아니라 그 클래스를 대표하는 파라미터 α_c에 의해 완전히 결정

의 두가지 값 중 하나를 가진다
→ 모두 조합한 $x = (x_1, x_2, \cdots, x_d)$가 가질 수 있는 전체 경우의 수는 다음과 같이 계산
$2 \times 2 \times 2 \times \cdots \times 2 = 2^d$
$x_1\ x_2\ x_3\ \cdots\ x_d$

플값이 훈련 세트에 없다는 뜻입니다. 더불어 '관측되지 못한'과 '출현빈도가 0'은 다른 개념이고, 따라서 직접적으로 빈도를 사용하여 $P(\boldsymbol{x} \mid c)$를 계산하는 것은 어려운 일입니다.

* 훈련 데이터에 없으니 빈도 = 0 → 확률 = 0으로 계산
: 실제로는 존재 가능한 (우연히 샘플링 되지 않았을 뿐인) 사건에 확률 0 ↝ 심각한 오류

7.2 최대 우도 추정

클래스 조건 확률을 구하기 위해 자주 사용되는 전략은 먼저 모종의 정해진 확률 분포 형식이 있다고 가정한 후 훈련 샘플에 기반해 확률 분포의 파라미터를 추정하는 전략입니다. 구체적으로 클래스 c에 관련된 클래스 조건 확률을 $P(\boldsymbol{x} \mid c)$로 기록하고, $P(\boldsymbol{x} \mid c)$가 정해진 형식이 있고 파라미터 벡터 $\boldsymbol{\theta}_c$에 의해서만 결정된다고 가정해 보겠습니다. 우리의 목적은 훈련 세트 D를 이용하여 파라미터 $\boldsymbol{\theta}_c$를 추정하는 것입니다. 더 명확히 하고자 우리는 $P(\boldsymbol{x} \mid c)$를 $P(\boldsymbol{x} \mid \boldsymbol{\theta}_c)$로 표기하겠습니다.

↳ 확률이 클래스 c 자체가 아닌 그 클래스를 대표하는 파라미터 α_c에 의해 완전히 결정

연속 분포하에서 확률밀도 함수 $p(\boldsymbol{x}|c)$이다.

* 수학적 표기 정리
- c : 특정 클래스 (레이블)
- $P(x|c)$: 클래스 c에서 샘플 x가 나타날 클래스조건 확률
- α_c : 클래스 c의 확률분포를 결정짓는 파라미터 벡터
- D (D_c): 훈련 세트 (클래스 c에 속하는 훈련 샘플들)

사실상 확률 모델의 훈련 과정은 **파라미터 추정**parameter estimation 과정으로 볼 수 있습니다. 파라미터 추정에 대해 통계학계의 두 학파 사이에 서로 다른 해결 방안을 제시하고 있습니다. **빈도주의 학파**Frequentist는 파라미터는 미지의 수지만, 객관적으로 존재하는 고정값이라고 생각합니다. 따라서 우도 함수의 최적화 등의 방법으로 파라미터값을 정할 수 있다고 생각합니다. **베이지안 학파**Bayesian는 파라미터는 관측되지 않은 확률 변수라 여기고 본질적으로 어떤 분포를 가지고 있다고 생각합니다. 따라서 파라미터가 하나의 사전분포를 따른다고 가정할 수 있고, 관측된 데이터에 기반해 파라미터의 사후분포를 추정할 수 있다고 생각합니다. 이번 절에서는 데이터 샘플링에 기반해 확률 분포 파라미터를 추정하는 전통적인 방법인 빈도주의 학파의 **최대 우도 추정**Maximum Likelihood Estimation, MLE을 소개합니다.

20C 대부터 빈도주의학파와 베이지안학파 사이의 논쟁이 시작되었다. 이 논쟁은 오늘날까지도 계속되고 있다. 두 학파는 많은 중요한 문제에서 다른 관점을 보였는데, 심지어 확률에 대한 기본 해석에도 이견이 있었다. 관심 있는 독자는 [Efron, 2005; Samaniego, 2010]을 참조하라.

'최대 우도법'이라고도 부른다.

역주 최대 우도법은 어떤 확률 변수에서 표집한 값들을 토대로 그 확률 변수의 모수를 구하는 방법이다. 어떤 모수가 주어졌을 때, 원하는 값들이 나올 가능도를 최대로 만드는 모수를 선택하는 방법이다.

D_c로 훈련 세트 D에서 c 클래스 샘플로 구성된 집합을 나타내고, 이런 샘플들이 독립항등분포라고 가정한다면, 데이터 세트 D_c에 대한 파라미터 $\boldsymbol{\theta}_c$의 우도는 식 7.9가 됩니다.

$$P(D_c \mid \boldsymbol{\theta}_c) = \prod_{\boldsymbol{x} \in D_c} P(\boldsymbol{x} \mid \boldsymbol{\theta}_c) \ . \qquad \text{식 7.9}$$

$\boldsymbol{\theta}_c$에 대해 최대 우도를 추정하는 것은 바로 우도 $P(D_c \mid \boldsymbol{\theta}_c)$를 최대화하는 파라미터값 $\hat{\boldsymbol{\theta}}_c$를 찾는 것으로 볼 수 있습니다. 직관적으로 본다면 최대 우도 추정은 $\boldsymbol{\theta}_c$의 모든 가능한 값 중에서 데이터 출현의 가능성을 최대화하는 값을 찾는 것입니다.

* 오버플로우(overflow)
: 어떤 수치 값이 표현할 수 있는 최대값을 초과했을 때 발생

* 언더플로우(underflow)
: 수치 값이 표현할 수 있는 가장 작은 값보다 작아졌을 때 발생

식 7.9에서 연속되는 곱셈 계산이 *오버플로overflow를 일으키기 쉬우므로 일반적으로 로그 우도log likelihood를 사용합니다.

$$\begin{aligned} LL(\boldsymbol{\theta}_c) &= \log P(D_c \mid \boldsymbol{\theta}_c) \\ &= \sum_{\boldsymbol{x} \in D_c} \log P(\boldsymbol{x} \mid \boldsymbol{\theta}_c) \ , \end{aligned} \qquad \text{식 7.10}$$

이때, 파라미터 $\boldsymbol{\theta}_c$의 최대 우도 추정 $\hat{\boldsymbol{\theta}}_c$는 식 7.11입니다.

$$\hat{\boldsymbol{\theta}}_c = \arg\max_{\boldsymbol{\theta}_c} LL(\boldsymbol{\theta}_c) \ . \qquad \text{식 7.11}$$

$\mathcal{N}$은 정규 분포다. 부록 C1.7을 참조하라.

예를 들어, 연속 속성일 때 확률밀도 함수 $P(\boldsymbol{x} \mid c) \sim \mathcal{N}(\boldsymbol{\mu}_c, \boldsymbol{\sigma}_c^2)$를 가정하면 파라미터 $\boldsymbol{\mu}_c$와 $\boldsymbol{\sigma}_c^2$의 최대 우도 추정은 다음 두 식과 같습니다.

MLE 유도과정

1) 기본가정 i.i.d

독립동일분포 (independent and identically distributed, i.i.d)

훈련세트 D_c 의 각 샘플 $x_1, x_2, \cdots, x_m$ 이 다음을 만족한다고 가정

- 독립성 (Independence) : 각 샘플이 독립적으로 생성
- 동일분포 (Identically Distributed) : 모두 같은 확률분포 $P(x \mid \theta_c)$ 에서 생성

2) 결합확률의 곱셈법칙

독립인 사건들의 결합확률 (joint probability)은 각 사건의 확률의 곱(product)로 계산

훈련세트 $D_c = \{x_1, x_2, \cdots, x_m\}$ 에 속한 모든 샘플이 동시에 관측될 확률

$\Rightarrow P(D_c \mid \theta_c) = P(x_1, x_2, \cdots, x_m \mid \theta_c)$

i.i.d 가정 하에서 (각 샘플은 모두 독립)

$P(x_1, x_2, \cdots, x_m \mid \theta_c) = P(x_1 \mid \theta_c) P(x_2 \mid \theta_c) \cdots P(x_m \mid \theta_c)$

3) 정리

$$P(D_c \mid \theta_c) = \prod_{x \in D_c} P(x \mid \theta_c) \quad \text{식 7.9}$$

$\mathcal{N}$은 정규 분포다. 부록 C1.7을 참조하라.

예를 들어, 연속 속성일 때 확률밀도 함수 $P(\boldsymbol{x} \mid c) \sim \mathcal{N}(\boldsymbol{\mu}_c, \boldsymbol{\sigma}_c^2)$를 가정하면 파라미터 $\boldsymbol{\mu}_c$와 $\boldsymbol{\sigma}_c^2$의 최대 우도 추정은 다음 두 식과 같습니다.

hood
성

1) MLE의 문제점
오버플로우

$P(D_c \mid \theta_c) = \prod_{x \in D_c} P(x \mid \theta_c)$ * m개의 확률값을 곱하는 연산

확률은 $0 \le P \le 1$ 범위의 값

($P(x \mid \theta_c)$ 는 일반적으로 매우 작은 값)

ex.) 컴퓨터로

하나의 데이터 포인트가 관측될 확률 $P(x \mid \theta_c) \approx 0.01 \sim 0.001$

훈련 세트의 크기 $m = 10000$ 개

$P(D_c \mid \theta_c) = 0.001 \times 0.001 \times \cdots \times 0.001 = (0.001)^{10000}$

2) 수치계산의 한계

컴퓨터는 부동소수점(floating-point) 수로 계산, 표현 가능한 범위 제한

IEEE 754 표준 (64 bit double precision)

- 표현 가능한 최소양수 $\approx 10^{-308}$
- 표현 가능한 최대양수 $\approx 10^{308}$

$(0.001)^{10000} = (10^{-3})^{10000} = 10^{-30000}$

10^{-308} 보다 훨씬 작은 값 → 0으로 반올림함

3) 로그함수

$\ln P(D_c \mid \theta_c) = \ln \prod_{x \in D_c} P(x \mid \theta_c)$

$\therefore \ln P(D_c \mid \theta_c) = \sum_{x \in D_c} \ln P(x \mid \theta_c)$ * 로그의 곱셈성질

$\ln(a \times b) = \ln a + \ln b$

로 볼 수
해결 방안
지만, 객관
등의 방법
파라미터
있다고 생
고, 관측
다. 이번
적인 방법
합니다.

샘플들이
우도는 식

식 7.9

는 파라미
정은 θ_c의
입니다.

일반적으

식 7.10

식 7.11

$\mathcal{N}$은 정규 분포다. 부록 C1.7을 참조하라.

예를 들어, 연속 속성일 때 확률밀도 함수 $P(\boldsymbol{x} \mid c) \sim \mathcal{N}(\mu_c, \sigma_c^2)$를 가정하면 파라미터 μ_c와 σ_c^2의 최대 우도 추정은 다음 두 식과 같습니다.

$$\hat{\boldsymbol{\mu}}_c = \frac{1}{|D_c|} \sum_{\boldsymbol{x} \in D_c} \boldsymbol{x} \ , \qquad \text{식 7.12}$$

$$\hat{\boldsymbol{\sigma}}_c^2 = \frac{1}{|D_c|} \sum_{\boldsymbol{x} \in D_c} (\boldsymbol{x} - \hat{\boldsymbol{\mu}}_c)(\boldsymbol{x} - \hat{\boldsymbol{\mu}}_c)^{\mathrm{T}} \ . \qquad \text{식 7.13}$$

즉, 최대 우도 추정법을 통해 얻은 정규 분포값은 샘플의 평균값이며, 분산은 $(\boldsymbol{x} - \hat{\boldsymbol{\mu}}_c)(\boldsymbol{x} - \hat{\boldsymbol{\mu}}_c)^{\mathrm{T}}$의 평균값이 됩니다. 이는 직관에 부합하는 결과입니다. 이산 속성일 때도 비슷한 방법을 통해 클래스 조건 확률을 추정할 수 있습니다.

이러한 파라미터화 방법은 클래스 조건 확률 추정을 상대적으로 간단하게 만들긴 하지만, 추정 결과의 정확성은 가정하는 확률 분포 형식이 잠재적인 실제 데이터 분포와 얼마나 일치하는지에 과하게 의존하게 됩니다. 실제 응용환경에서 비교적 괜찮은 데이터 분포 가설을 세우려면 일정 정도 이상의 도메인 지식이 필요합니다. 그렇지 않고 확률 분포 형식에 대해 마음대로 예측하고 가정한다면 잘못된 결과를 얻을 가능성이 큽니다.

7.3 나이브 베이즈 분류기

베이즈 공식 7.8에 기반해 사후 확률 $P(c \mid \boldsymbol{x})$을 계산할 때 가장 어려운 점은 클래스 조건 확률 $P(\boldsymbol{x} \mid c)$가 모든 속성상의 결합 확률이기 때문에 유한한 훈련 샘플만으로 직접적으로 추정하기 힘들다는 것입니다. 이런 장애물을 피하고자 **나이브 베이즈 분류기**naive Bayes classifier는 **속성 조건독립 가설**attribute conditional independence assumption을 이용합니다. 속성 조건독립 가설이란, 이미 알고 있는 클래스에 대해 모든 속성은 서로 독립적이라고 가정하는 것입니다. 바꿔 말하면, 각 속성은 독립적으로 분류 결과에 대해 영향을 끼친다는 뜻입니다.

훈련 샘플에 기반해 결합 확률을 계산할 때, 계산상에서 '조합 폭발(조합의 수가 기하급수로 늘어남)' 문제가 나타날 수 있고, 데이터상에서는 샘플 희소 문제가 나타날 수 있다. 속성 개수가 많을수록 문제가 커진다.

속성 조건독립 가설에 기반하여 식 7.8을 다음처럼 바꿔 쓸 수 있습니다.

$$P(c \mid \boldsymbol{x}) = \frac{P(c)\, P(\boldsymbol{x} \mid c)}{P(\boldsymbol{x})} = \frac{P(c)}{P(\boldsymbol{x})} \prod_{i=1}^{d} P(x_i \mid c) \ , \qquad \text{식 7.14}$$

여기서 d는 속성 개수, $\boldsymbol{x}_i$는 i번째 속성상에서 $\boldsymbol{x}$의 값을 나타냅니다.

$\boldsymbol{x}$는 사실상 '색깔 = 청록색'과 같은 하나의 '속성값' 쌍(pair)이다. 쉬운 논의를 위해 상하 문맥이 명확할 때 x_i로 i번째 속성이 대응하는 변수(예를 들면 '색깔')를 나타낸다. 가끔은 $\boldsymbol{x}$가 뜻하는 속성값(예를 들면 '청록색')을 직접 나타내기도 한다.

모든 클래스에 대해 $P(\boldsymbol{x})$는 동일하므로 식 7.6에 베이즈 결정 규칙을 적용하면 식 7.15를 얻을 수 있습니다.

$$h_{nb}(\boldsymbol{x}) = \arg\max_{c \in \mathcal{Y}} P(c) \prod_{i=1}^{d} P(x_i \mid c) \,, \qquad \text{식 7.15}$$

이것이 바로 나이브 베이즈 분류기의 표현식입니다.

나이브 베이즈 분류기의 훈련 과정은 훈련 세트 D에 기반해 클래스 사전 확률 $P(c)$를 추정하고 각 속성을 위해 조건 확률 $P(x_i \mid c)$를 계산하는 것과 같다고 할 수 있습니다.

D_c로 훈련 세트 D에서 c 클래스 샘플로 구성된 집합을 나타내고, 충분한 독립항등분포 샘플이 있다면, 클래스 사전 확률은 쉽게 추정할 수 있습니다.

$$P(c) = \frac{|D_c|}{|D|} \,. \qquad \text{식 7.16}$$

이산 속성에 대해서는 D_{c,x_i}를 D_c 중에 속성 i상에서의 값이 x_i인 샘플로 구성된 집합을 나타낸다면, 조건 확률 $P(x_i \mid c)$는 식 7.17로 추정될 수 있습니다.

$$P(x_i \mid c) = \frac{|D_{c,x_i}|}{|D_c|} \,. \qquad \text{식 7.17}$$

연속 속성에 대해서는 확률밀도 함수를 고려할 수 있습니다. $p(x_i \mid c) \sim \mathcal{N}(\mu_{c,i}, \sigma_{c,i}^2)$을 가정한다면, $\mu_{c,i}$와 $\sigma_{c,i}^2$는 각각 c 클래스 샘플이 i 속성상에서 취하는 값의 평균과 분산입니다.

$$p(x_i \mid c) = \frac{1}{\sqrt{2\pi}\sigma_{c,i}} \exp\left(-\frac{(x_i - \mu_{c,i})^2}{2\sigma_{c,i}^2}\right) \,. \qquad \text{식 7.18}$$

수박 데이터 세트 3.0은 104쪽의 표 4.3을 참조하라.

그럼 이제 수박 데이터 세트 3.0을 사용하여 나이브 베이즈 분류기를 훈련해 봅시다. 테스트 샘플은 '테스트1'로 표기하고 이에 대한 분류를 진행해 보겠습니다.

번호	색깔	꼭지 모양	소리	줄무늬	배꼽 모양	촉감	밀도	당도	잘 익은 수박
테스트1	청록색	말림	혼탁	선명함	움푹 패임	단단함	0.679	0.460	?

먼저, 클래스 사전 확률 $P(c)$를 계산합니다.

$$P(\text{잘 익은 수박} = \bigcirc) = \frac{8}{17} \approx 0.471 ,$$

$$P(\text{잘 익은 수박} = \times) = \frac{9}{17} \approx 0.529 .$$

샘플 수가 충분히 많을 때에만 유의미한 확률 예측을 진행할 수 있다. 책에서 소개하는 예제는 단순히 개념 설명을 목적으로 하므로 많은 샘플을 사용하지 않는다.

그리고 각 속성의 조건 확률 $P(x_i \mid c)$를 추정합니다.

$$P_{\text{청록}|\bigcirc} = P(\text{색깔} = \text{청록} \mid \text{잘 익은 수박} = \bigcirc) = \frac{3}{8} \approx 0.375 ,$$

$$P_{\text{청록}|\times} = P(\text{색깔} = \text{청록} \mid \text{잘 익은 수박} = \times) = \frac{3}{9} \approx 0.333 .$$

$$P_{\text{말림}|\bigcirc} = P(\text{꼭지 모양} = \text{말림} \mid \text{잘 익은 수박} = \bigcirc) = \frac{5}{8} \approx 0.625 ,$$

$$P_{\text{말림}|\times} = P(\text{꼭지 모양} = \text{말림} \mid \text{잘 익은 수박} = \times) = \frac{3}{9} \approx 0.333 .$$

$$P_{\text{혼탁}|\bigcirc} = P(\text{소리} = \text{혼탁} \mid \text{잘 익은 수박} = \bigcirc) = \frac{5}{8} \approx 0.625 ,$$

$$P_{\text{혼탁}|\times} = P(\text{소리} = \text{혼탁} \mid \text{잘 익은 수박} = \times) = \frac{4}{9} \approx 0.444 .$$

$$P_{\text{선명함}|\bigcirc} = P(\text{줄무늬} = \text{선명함} \mid \text{잘 익은 수박} = \bigcirc) = \frac{7}{8} \approx 0.875 ,$$

$$P_{\text{선명함}|\times} = P(\text{줄무늬} = \text{선명함} \mid \text{잘 익은 수박} = \times) = \frac{2}{9} \approx 0.222 .$$

$$P_{\text{움푹 패임}|\bigcirc} = P(\text{배꼽 모양} = \text{움푹 패임} \mid \text{잘 익은 수박} = \bigcirc) = \frac{6}{8} \approx 0.750 ,$$

$$P_{\text{움푹 패임}|\times} = P(\text{배꼽 모양} = \text{움푹 패임} \mid \text{잘 익은 수박} = \times) = \frac{2}{9} \approx 0.222 .$$

$$P_{\text{단단함}|\bigcirc} = P(\text{촉감} = \text{단단함} \mid \text{잘 익은 수박} = \bigcirc) = \frac{6}{8} \approx 0.750 ,$$

$$P_{\text{단단함}|\times} = P(\text{촉감} = \text{단단함} \mid \text{잘 익은 수박} = \times) = \frac{2}{9} \approx 0.667 .$$

$$p_{\text{밀도: 0.697}|\bigcirc} = p(\text{밀도} = 0.697 \mid \text{잘 익은 수박} = \bigcirc)$$

$$= \frac{1}{\sqrt{2\pi} \cdot 0.129} \exp\left(-\frac{(0.697 - 0.574)^2}{2 \cdot 0.129^2}\right) \approx 1.959 ,$$

$$p_{\text{밀도: 0.697}|\times} = p(\text{밀도} = 0.697 \mid \text{잘 익은 수박} = \times)$$

$$= \frac{1}{\sqrt{2\pi} \cdot 0.129} \exp\left(-\frac{(0.697 - 0.574)^2}{2 \cdot 0.129^2}\right) \approx 1.959 ,$$

$$p_{\text{당도: 0.460}|\bigcirc} = p(\text{당도} = 0.460 \mid \text{잘 익은 수박} = \bigcirc)$$

$$= \frac{1}{\sqrt{2\pi} \cdot 0.101} \exp\left(-\frac{(0.460 - 0.279)^2}{2 \cdot 0.101^2}\right) \approx 0.788\ ,$$

$$p_{\text{당도: 0.460}|\times} = p(\text{당도} = 0.460 \mid \text{잘 익은 수박} = \times)$$

$$= \frac{1}{\sqrt{2\pi} \cdot 0.108} \exp\left(-\frac{(0.460 - 0.154)^2}{2 \cdot 0.108^2}\right) \approx 0.066\ .$$

따라서 예측값은 다음과 같이 계산될 수 있습니다.

실제로 계산할 때는 지수를 취하는 경우가 많다.

$$P(\text{잘 익은 수박} = \bigcirc) \times P_{\text{청록}|\bigcirc} \times P_{\text{말림}|\bigcirc} \times P_{\text{혼탁}|\bigcirc} \times P_{\text{선명}|\bigcirc} \times P_{\text{움푹 패임}|\bigcirc} \times P_{\text{단단함}|\bigcirc} \times p_{\text{밀도:0.697}|\bigcirc} \times p_{\text{당도:0.460}|\bigcirc} \approx 0.052,$$

$$P(\text{잘 익은 수박} = \times) \times P_{\text{청록}|\times} \times P_{\text{말림}|\times} \times P_{\text{혼탁}|\times} \times P_{\text{선명}|\times} \times P_{\text{움푹 패임}|\times} \times P_{\text{단단함}|\times} \times p_{\text{밀도:0.697}|\times} \times p_{\text{당도:0.460}|\times} \approx 6.80 \times 10^{-5}$$

$0.052 > 6.80 \times 10^{-5}$이므로 나이브 베이즈 분류기는 테스트 샘플 '테스트1'을 '잘 익은 수박'으로 판별합니다.

주의해야 할 점은 만약 어떤 속성값이 훈련 세트 중 어떤 클래스와 동시에 나온 적이 없다면, 직접 식 7.17에 기반하여 확률을 계산하고 식 7.15를 이용해 판별을 진행하는 것은 문제가 있습니다. 예를 들어, 수박 데이터 세트 3.0을 사용하여 나이브 베이즈 분류기를 훈련시킬 때 '소리 = 맑음'인 테스트 샘플에 대한 값이 다음과 같다면 식 7.15의 연속 곱셈 계산에 의해 나온 확률값은 0이 됩니다.

$$P_{\text{맑음}|\bigcirc} = P(\text{소리} = \text{맑음} \mid \text{잘 익은 수박} = \bigcirc) = \frac{0}{8} = 0$$

따라서 해당 샘플의 기타 속성이 무엇이든, 심지어 다른 모든 속성에서는 '잘 익은 수박'일지라도 분류 결과는 '잘 익은 수박 = ×'가 될 것인데, 이는 불합리합니다.

기타 속성이 가지고 있는 정보가 훈련 세트 중에서 나오지 않은 속성값 때문에 말소되는 것을 방지하기 위해, 확률 예측 시에 일반적으로 **평활화**smoothing를 합니다. 자주 사용하는 방법으로는 **라플라시안 보정**Laplacian correction이 있습니다. 구체적으로, 훈련 세트 D의 클래스 개수를 N, i번째 속성이 취할 수 있는 값을 N_i로 나타낸다면, 식 7.16과 7.17은 각각 식 7.19와 7.20으로 수정됩니다.

$$\hat{P}(c) = \frac{|D_c| + 1}{|D| + N}\ , \qquad \text{식 7.19}$$

$$\hat{P}(x_i \mid c) = \frac{|D_{c,x_i}| + 1}{|D_c| + N_i}\ . \qquad \text{식 7.20}$$

예를 들어, 이번 절의 예제에서 클래스 사전 확률은 다음과 같이 예측될 수 있습니다.

$$\hat{P}(\text{잘 익은 수박} = \bigcirc) = \frac{8+1}{17+2} \approx 0.474\ ,\ \hat{P}(\text{잘 익은 수박} = \times) = \frac{9+1}{17+2} \approx 0.526\ .$$

이와 유사하게, $P_{\text{청록}|\bigcirc}$과 $P_{\text{청록}|\times}$는 다음 수식이 됩니다.

$$\hat{P}_{\text{청록}|\bigcirc} = \hat{P}(\text{색깔} = \text{청록} \mid \text{잘 익은 수박} = \bigcirc) = \frac{3+1}{8+3} \approx 0.364\ ,$$

$$\hat{P}_{\text{청록}|\times} = \hat{P}(\text{색깔} = \text{청록} \mid \text{잘 익은 수박} = \times) = \frac{3+1}{9+3} \approx 0.333\ .$$

동시에 위에서 언급한 확률 $P_{\text{맑음}|\bigcirc}$는 다음 수식이 됩니다.

$$\hat{P}_{\text{맑음}|\bigcirc} = \hat{P}(\text{소리} = \text{맑음} \mid \text{잘 익은 수박} = \bigcirc) = \frac{0+1}{8+3} \approx 0.091\ .$$

사실상 속성값과 클래스가 균등 분포라고 가정한다.

라플라시안 보정법은 훈련 데이터의 샘플이 충분하지 않아 확률 예측값이 0이 되는 문제를 방지합니다. 그리고 훈련 데이터의 크기가 커질 때 보정 과정에서 유입된 사전prior 영향은 점차 희미해져 예측값을 실제 확률값에 근사하게 만듭니다.

현실에서는 나이브 베이즈 분류기가 여러 가지 방식으로 사용됩니다. 예를 들어, 풀고자 하는 문제에서 예측 속도에 대한 요구가 비교적 높다면 훈련 데이터가 정해졌을 때 나이브 베이즈 분류기에 관계되는 모든 확률값을 사전에 계산해 저장하여 예측을 진행하며, 필요할 때 꺼내 보며 판별을 진행할 수 있습니다. 만약 풀고자 하는 문제에서 데이터 교체 주기가 빠르다면, **게으른 학습**lazy learning 방식을 사용하여 미리 어떠한 훈련도 진행하지 않고 예측 요구가 왔을 때 그 당시의 데이터 세트에 기반해 확률 예측을 진행합니다. 만약 데이터가 지속적으로 증가한다면 현재 예측값을 기초로 하여 새로 증가되는 샘플의 속성값에 관련된 확률값에 대해서만 수정을 진행하여 점진적 학습incremental learning을 실현합니다.

게으른 학습에 관해서는 10.1절을 참조하라.

점진적 학습(incremental learning)에 관해서는 5.5.2절을 참조하라.