[Paper Review] Selective Naive Bayes의 반도체 제조 적용

발표 핵심 한 문장
반도체 제조의 많은 공정 변수 중 **Cycle Time 예측에 중요한 요인만 골라내기 위해 CMIM과 Selective Naive Bayesian Classifier(SNBC)를 결합한 연구**이다.

1. 논문 정보

Cycle-Time Key Factor Identification and Prediction in Semiconductor Manufacturing Using Machine Learning and Data Mining

- Yair Meidan, Boaz Lerner, Gad Rabinowitz, Michael Hassoun
- IEEE Transactions on Semiconductor Manufacturing
- Vol. 24, No. 2, 2011, pp. 237-248
- DOI: 10.1109/TSM.2011.2118775

선정 이유: 이번에 공부한 Naive Bayes가 실제 반도체 제조 문제에서 어떻게 활용되는지 확인하기 좋다.

---

2. 연구 문제

반도체 제조에서 **Cycle Time(CT)**은 생산 효율과 연결되는 중요한 지표이다.

하지만 Cycle Time에 영향을 줄 수 있는 공정 요인이 너무 많으면,

- 어떤 요인이 실제로 중요한지 알기 어렵고
- 모든 변수를 그대로 사용하면 모델 해석도 복잡해진다.

연구 질문
수많은 공정 변수 중 Cycle Time 예측에 중요한 변수만 선별하면서도 충분한 예측 성능을 확보할 수 있을까?

---

3. 전체 연구 흐름

182개 후보 요인 → CMIM 1차 변수 선택 → Selective Naive Bayes → 약 20개 핵심 요인 → Cycle Time 관련 분류

핵심 아이디어
많은 변수를 그대로 쓰지 않고, 먼저 후보를 압축한 뒤 Naive Bayes로 예측에 도움이 되는 변수만 다시 선택한다.

---

4. CMIM은 무엇인가?

CMIM = Conditional Mutual Information Maximization

쉽게 말하면,

> **"이 변수를 새로 알게 되었을 때 예측 대상에 대한 정보를 얼마나 더 얻을 수 있는가?"**

를 기준으로 변수를 선택하는 방법이다.

단순히 관련성이 높은 변수만 반복해서 선택하는 것이 아니라, **이미 선택된 변수와 겹치지 않는 새로운 정보를 주는 변수**를 우선적으로 찾는다.

> **역할:** SNBC에 모든 변수를 바로 넣기 전에 중요한 변수 후보를 줄여주는 1차 필터

---

5. Selective Naive Bayesian Classifier

기본 Naive Bayes는 다음과 같이 표현할 수 있다.

$$P(C \mid X) \propto P(C) \prod_{i=1}^{n} P(x_i \mid C)$$

즉, **사전확률 × 각 변수의 조건부 확률**을 이용해 가장 가능성이 높은 클래스를 선택한다.

일반 Naive Bayes의 문제

변수가 많다고 해서 모든 변수가 예측에 도움이 되는 것은 아니다.

- 불필요한 변수
- 비슷한 정보를 반복하는 변수
- 예측 성능을 떨어뜨리는 변수

가 포함될 수 있다.

SNBC의 아이디어

Selective Naive Bayesian Classifier(SNBC)는 Naive Bayes를 사용하면서 **예측에 도움이 되는 변수만 선택해서 사용**한다.

> **한 줄 이해**
> **SNBC = Naive Bayes + Feature Selection**

---

6. 실험 결과

항목	결과
초기 후보 요인	182개
최종 핵심 요인	약 20개
대표 설정 평균 정확도	72.6%
기준 확률	Low / Medium / High 3개 클래스 → 33.3%

논문은 SNBC 기반 접근이 **예측 정확도를 기준 대비 거의 40%p 높이면서**, 변수 수를 **182개에서 약 20개로 줄였다**고 보고한다.

또한 Decision Tree, Neural Network, Multinomial Logistic Regression과 비교했을 때 **비교 가능한 정확도**를 보이면서도 단순성과 해석 가능성이 장점이라고 설명한다.

> **결과의 의미**
> 변수를 많이 사용하는 것보다 **예측에 필요한 핵심 변수만 잘 선택하는 것**이 중요할 수 있다.

---

7. 이 논문에서 Naive Bayes가 중요한 이유

이 연구는 단순히 “예측을 잘하는 모델”만 만드는 것이 목적이 아니다.

1. **Cycle Time과 관련된 핵심 요인을 찾고**
2. **그 요인만 이용해 분류하고**
3. **결과를 현장에서 해석하기 쉽게 만든다.**

즉, 고차원 제조 데이터에서 **변수 선택 + 분류 + 해석**을 함께 수행한다는 점이 핵심이다.

---

8. 한계점

① 실제 Fab 데이터가 아닌 simulated fab 데이터

연구 데이터는 실제 생산 Fab 자체가 아니라 **simulated fab을 표현한 데이터셋**이다. 실제 생산 환경에서 같은 결과가 나오는지는 추가 검증이 필요하다.

② Naive Bayes의 조건부 독립 가정

Naive Bayes는 클래스가 주어졌을 때 변수들이 서로 독립이라고 가정한다. 실제 반도체 공정 변수들은 서로 영향을 주고받을 수 있기 때문에 이 가정이 완벽하게 성립하지 않을 수 있다.

③ 선택되는 변수는 공정 환경에 따라 달라질 수 있음

다른 Fab이나 다른 제품에서는 중요하게 선택되는 공정 요인이 달라질 가능성이 있다.

---

9. 결론

최종 정리
이 논문은 **CMIM으로 변수 후보를 먼저 줄이고, Selective Naive Bayes로 핵심 요인을 추가 선택하여 반도체 Cycle Time 관련 예측을 수행한 연구**이다.

182개 후보 요인 → CMIM → SNBC → 약 20개 핵심 요인 → 예측

이번 Chapter 7과 연결하면,

> **Naive Bayes는 단순한 확률 분류 알고리즘에 그치지 않고, 실제 제조 데이터에서 변수 선택과 해석 가능한 예측에도 활용될 수 있다.**

참고문헌

Meidan, Y., Lerner, B., Rabinowitz, G., & Hassoun, M. (2011). Cycle-Time Key Factor Identification and Prediction in Semiconductor Manufacturing Using Machine Learning and Data Mining. IEEE Transactions on Semiconductor Manufacturing, 24(2), 237-248.

IEEE Xplore 논문 페이지