나이브 베이즈 기반 소셜 미디어 상의 신조어 감성 판별 기법

- 저자: 김정인, 박상진, 김형주, 최준호, 김한일, 김판구
- 학술지: 스마트미디어저널, 2020
- 원문: https://www.kism.or.kr/file/memoir/9_1_7.pdf

- **아이디어**:
  - 데이터 셋에 대해 특정 확률을 리턴 하는 '나이브베이즈' 분류기를 활용
  - 감성 판별이 어려웠던 '신조어'에 대해서도 주제별 감성 확률을 도출
    - ex) p(꿀잼 | 부정), p(꿀잼 | 긍정) 학습 → p(긍정 | 꿀잼), p(부정 | 꿀잼)으로 긍/부정 분류
  - → 기존 신조어를 활용하지 않았던 모델에 비해 감성 정도를 상대적으로 민감하게 판별
  -
- **문제정의**
  - 빈번하게 사용되고 생성되는 신조어의 '사전적 의미' 없음으로 인한 '텍스트 마이닝', '빅데이터 알고리즘 성능 저하' 문제

- **해결책**
  - '오피니언 마이닝'과 '감성판별분석'을 통한 학습 데이터 구축 그리고 데이터 마이닝의 성능향상

1. 신조어의 형성 원리

(참고)

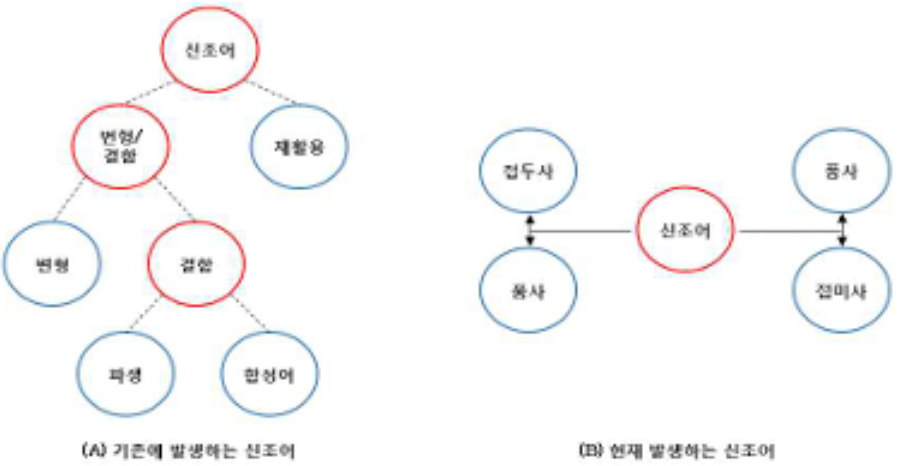


그림 1. 신조어 형성과정

2. 텍스트 마이닝(Text Mining)

- 비정형 데이터 (text)
- 특징 추출 및 키워드화
- 유사도 기반 군집화
- 정형화 후 패턴 및 키워드 분석

3. 오피니언 마이닝(Opinion Mining)

- 자연어 처리, 텍스트 마이닝 기법
- text·context의 정서와 주관적 정보를 식별 및 정량화
- 맥락과 사용자 의도에 의해 결정되므로 문맥 고려 필요
- 과정: 데이터 수집 → 데이터 전처리(불용성 제거) → 긍/부정 등 감성 인식 → 주제에 대한 오피니언 분석 및 정보 파악

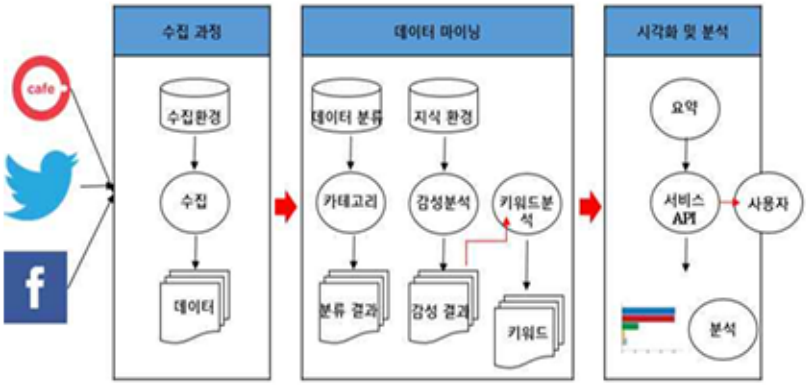


그림 3. 오피니언 마이닝 절차

4. **감성 판별 시스템**

- 국내 포털 사이트 카페-블로그 텍스트 수집
- '한나눔' 한국어 형태소 분석기 기반 추출
- SNS 댓글 어휘 X(신조어 의미 파악 실패)
- 신조어 위주 감성 분석(긍/부정) 실행
- 신조어 사전: 위키피디아 소셜미디어 신조어 목록 사용

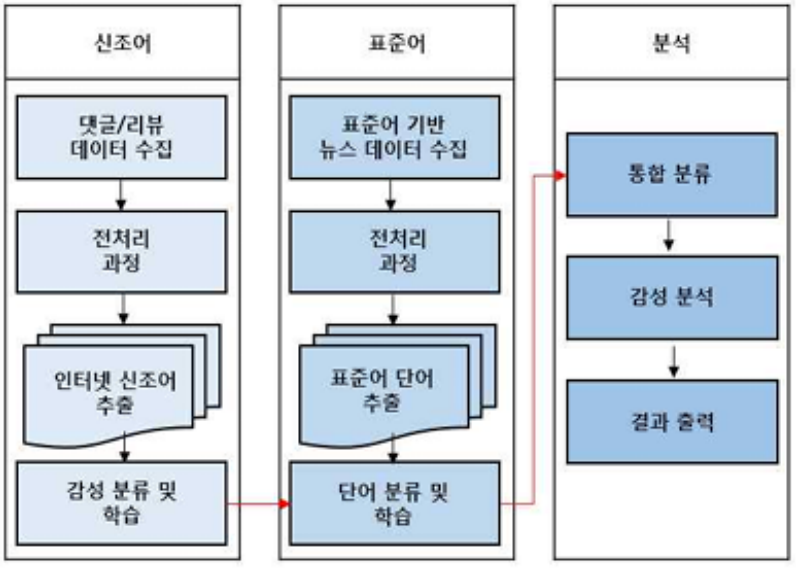


그림 4. 신조어 감성 판별 시스템 구성도

5. **신조어 감성 분석(긍/부정)**

- 신조어 접두사 '개' → 비하·욕설·인신공격 등의 이유로 추출 후 제거
- 토크나이징(Tokenizing) 적용 → 분석 가능한 단위(문장 → 단어)로 분리

표 1. 소셜 미디어 데이터의 토크나이징

	댓글/리뷰 원문
원본 데이터	1. 레알 창렬 오브 창렬 ㅋㅋㅋㅋㅋㅋㅋㅋㅋ. 이게 과연 5만원 상인가 싶어서 웃음만 나오더라고요 2. 야 어벤져스 그전에 마블영화 하나도 안보고보면 노잼이야 3. 솔직히 이렇게 욕하는거 드물잖아 아무리 개존못이라도ㅋㅋ ⋮
토크 나이징 적용 후 데이터	1. 레알, 창렬, 오브, 창렬, 이게, 과연, 5만원, 상인가, 싶어서,웃음만, 나오더라고요, 2. 야, 어벤져스, 그, 전에, 마블 영화, 하나도, 안, 보고보면, 노잼, 이야, 3. 솔직히, 이렇게, 욕, 하는거, 드물잖아, 아무리, 개존못, 이라도 ⋮

- '코퍼스' 불용어 리스트 구축 → 품사·고빈도 불용어 제거

표 2. 한국어 불용어 리스트

형태	비율	형태	비율
이	0.01828	나오	0.000725
있	0.011699	가지	0.00072
하	0.009774	씨	0.00071
것	0.005723	만들	0.000704
⋮	⋮	⋮	⋮

- 키워드 추출 및 빈도수(Word Count) 기반 신조어 리스트 구축

표 4. 빈도수로 추론된 상위 단어

단어	빈도수
꿀잼	211
개꿀잼	154
노잼	103
창렬	98
갑분싸	78
가즈아	63
핵노답	61
노답	59
개이득	54
혜자	51
존못	49
극혐	44
⋮	⋮

- 신조어 사전(정답 라벨지)을 통해 감성 분류 후 학습

표 5. 위키피디아를 참조한 긍정, 부정 분류와 의미

	단어	의미
긍정	꿀잼	너무 재미있다.
	개이득	완전 이익/이득
	혜자	가격대비 (품질/맛) 좋다
	위꼴	위가 뒤틀릴 정도로 맛있다(맛있어 보인다)
부정	노잼	너무 재미없다
	노답	(사람 또는 특정주제) 답이 없다
	창렬	가격대비 (품질/맛) 좋지 않다
	극혐	극도로 혐오

표 7. 신조어 감성에 따른 긍정, 부정 판별

단어	감성	단어	감성
꿀잼	positive	혜자	positive
개이득	positive	창렬	negative
노잼	negative	극혐	negative
헬조선	negative	노답	negative

6. **표준어(일반어) 감성 분석**

- 뉴스 Text 데이터 스크래핑(일반어 주로 사용)
- 형태소 분석

- 명사 추출
  - 신조어와 달리 <명사-사전적 정의 명확>
- 불용어 제거
- **TF-IDF 계산**
  - 빈도수 x 희소성 기반 단어 별 중요도(가중치) 측정

$$TF = \frac{\text{문서 내 단어의 개수}}{\text{문서 내 모든 단어의 수}}$$
$$IDF = \log\left(\frac{\text{문서 전체 갯수}}{\text{단어를 포함한 문서의 수}}\right) \quad (1)$$

- Naive Bayes로 긍/부정 분류(NLTK 패키지 - Naive Bayes Classifier)

표 8. 나이브 베이즈 기법에 가중치 적용

문서	좋다	별로다	부족하다	감성
doc1	3.36	0	0	pos
doc2	5.75	0	1.03	pos
doc3	0	2.88	2.12	neg
doc4	0.42	0.92	3.03	neg

7. 실험 진행 및 평가

- 실험 방법
  - 신조어 학습 분류기와 일반어 학습 분류기 결합
  - <신조어+표준어 혼용 데이터>에 대해 성능 평가
  - 표준어 중심 분류기와 정확도(?) 비교

데이터 예시

표 12. 문서별 표준어와 신조어 분석

문서	문장
doc1	이 겜 완전 꿀잼 (..) 정말 잘 샀다능...! 만족 만족! ㅎ
doc2	헬조선 취업 정말 어렵다 (...) 불합격 통지 꿀잼..(...)
doc3	어쩔 수 없이 샀는데 가성비 창렬 (...) 이렇게 비싸고..
⋮	⋮

분류 결과

표 13. 표준어와 신조어 결과 값 도출

문서	표준어	신조어	감성	결과
doc1	만족	꿀잼	Pos.	0.9362
doc2	어렵다	헬조선	Neg.	0.7893
doc3	비싸다	창렬	Neg.	0.9113
⋮	⋮	⋮	⋮	

기존 분류 vs 혼합 분류 성능 비교

표 14. 기존 연구와 제시한 연구에 대한 비교 수치

텍스트 분류를 통한 연구		신조어/표준어 감성 연구	
문서	감성	문서	감성
doc1	0.8967	doc1	0.9362
doc2	0.6832	doc2	0.7893
doc3	0.8799	doc3	0.9113
⋮	⋮	⋮	⋮

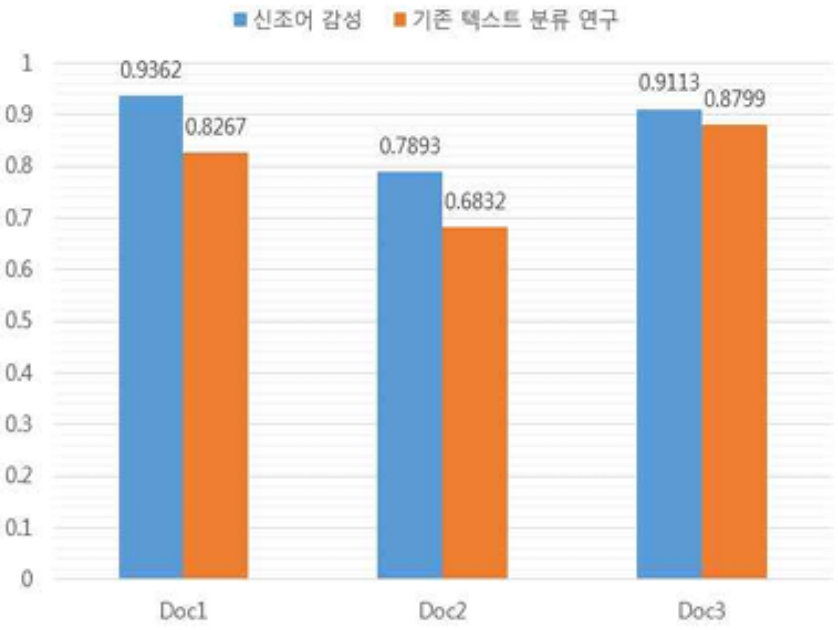


그림 6. 감성 비교분석 및 평가 수치

- 표준어(일반어) 중심 분류기 보다 신조어/표준어 분류 모델에서 **감성 강도가 더 크게 나타나는 경향**
- 신조어의 감성을 추가로 포착하고 감성 점수에 반영하여 보다 **감성 강도를 보다 풍부하고 민감하게 잡아냄**
- 연구에서는 '정확도'로 표기하지만, 인간의 **주관적인 '감성'에 '정확성'이라는 표현 자체가 성립한다고 보기 어려우며** 객관적으로 타당한 감성 정확도가 있다고 하더라도 **외부 시선에서 판단하기 어려움.**
- 따라서 연구의 '정확도'라는 표현 보다는 '감성 정도'를 민감하게 잡아내거나 다양한 양상을 분석할 수 있다라는 결론이 보다 타당함.