10주차 _ Bayes 논문

상태	시작 전
날짜	2026년 9월 28일

▼ 연구 배경 및 목적

배경

- 의사결정지원 도구 → 대부분 전문가 규칙 기반
- 임상 데이터로 학습 가능한 도구 탐구 → 난제: 진단 논리에서 참조되는 데이터의 **빈번한 결측**
- 적용 맥락 → **문제 목록(problem list)** 자동 제안 (POMR 기반)
  - 목표 → 진단 자체가 아니라 문제 목록의 완전성·시의성 향상
  - 임상의의 암묵적 행위(검사 미처방 등)도 정보로 활용
- 예시 → X-ray 처방 부재 → 폐렴을 고려하지 않았을 가능성

결측 메커니즘 (Little & Rubin)

- **MCAR** → 어떤 값과도 무관 → 결측성 정보 없음
- **MAR** → 관측값에만 의존 → 관측값으로 추론 가능
- **NMAR** → 결측된 값 자체에 의존 → 관측값으로 추론 불가한 정보 보유
- 기존 방법(완전사례, 대체, EM) → MCAR/MAR 가정
- NMAR → 결측을 명시적으로 모델링해야 함
  - **결측 지시자** → 관측 여부 이분형 변수 추가
  - **층화** → "missing" 명목값 부여

Table 1
An example data set

Patient ID	Body temperature	WBC	Sputum culture	Chest X-ray
A001	Normal	Normal	Negative	Normal
A002	Fever	High	Negative	Infiltrate
A003	Normal	Normal	Negative	Normal
A004	Fever	High	Positive	Infiltrate
A005	Normal	Normal	Negative	(Missing)
⋮				

목적

- 의료 영역에서 **결측성(missingness) 자체가 정보 가치를 담고 있는지** 판별 (2절)
- 결측을 명시적으로 표현한 데이터셋(처리 방식 C, D)과 그렇지 않은 데이터셋(A, B)의 예측 성능(AUC) 비교
- 성능 향상을 결측성이 제공하는 정보 가치의 척도로 사용
- 통계적 가설
  - 귀무가설 → C·D로 학습된 시스템의 예측 성능 = A·B로 학습된 시스템의 성능
  - 대립가설 → C·D로 학습된 시스템의 예측 성능 > A·B 기반 시스템

▼ 데이터

출처

- Intermountain HealthCare(IHC, Salt Lake City) 전사적 데이터 웨어하우스(EDW)
- HELP 병원정보시스템에 기록된 일상 임상 진료 데이터

대상 질병

- 급성 췌장염, 급성 신부전, 천식, 요로감염, 폐렴
- 급성기 진료 현장의 흔한 질병 중 진단 난이도가 서로 다른 수준을 대표하도록 선택

대상 환자

- **출처** → Intermountain HealthCare EDW (HELP 시스템 일상 진료 데이터)
- **대상 질병(5)** → 급성 췌장염, 급성 신부전, 천식, 요로감염, 폐렴
- **기간·기준** → 2000~2004년, ICD9 주 퇴원진단
- **양성군** → 해당 질병 주 진단 퇴원 환자
- **음성군(2가지 전략)**
  - 응급실 입원 + 48시간 초과 재원 환자 중 무작위 선택
  - 나머지 4개 질병군 환자
- **데이터셋** → 5개 질병 × 2가지 음성군 = **10개**
- **변수** → 입원 후 **첫 48시간** 데이터, 복수 값이면 첫 값 사용
  - 연속형(C), 이분형(D)
  - 가용률(비결측 비율)
    - 연속형 → PO2·PCO2 21%, Lipase·Amylase 29%, Band% 36%, Eos% 54%, Urine_WBC 55%, Neutrophil% 74%, Seg% 75%, Glucose·BUN·Creatinine 78%, WBC 80%, SpO2 96%, SBP·DBP 98%, BodyTemp 99.2%, HeartRate·Resp.Rate 99.7%
    - 이분형(복부압통, 반동압통, 날카로운 통증, 경련통, 천명, 건성 수포음, 습성 수포음, 파열음, 객담 동반 기침) → 100%

Table 2
The patient distribution in the data sets

Disease	Number of patients
Acute pancreatitis	611
Acute renal failure	562
Asthma	703
Pneumonia	1521
Urinary tract infection	1058
Randomly sampled negative patients	1376
Total	5831

Table 3
The availability of data in the data sets

Variable	Type	Availability (%)
PO2	C	21
PCO2	C	21
Lipase	C	29
Amylase	C	29
Band%	C	36
Eos%	C	54
Urine_WBC	C	55
Neutrophil%	C	74
Seg%	C	75
Glucose	C	78
BUN	C	78
Creatinine	C	78
WBC	C	80
SpO2	C	96
SBP	C	98
DBP	C	98
BodyTemp	C	99.2
HeartRate	C	99.7
Resp.Rate	C	99.7
Abd.Tend	D	100
Rebound	D	100
Sharp pain	D	100
Cramp	D	100
Wheezing	D	100
Ronchi	D	100
Rales	D	100
Crackles	D	100
Productive cough	D	100

▼ 방법론

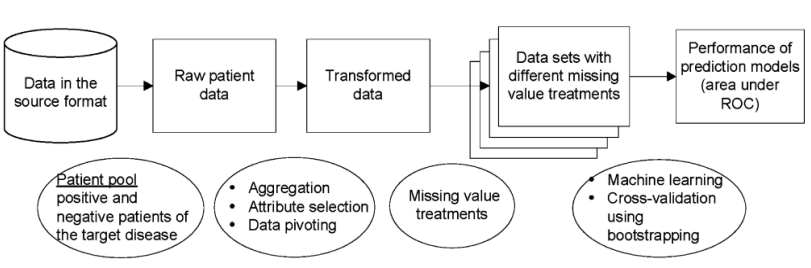


Fig. 2. The process of data preparation and analysis, from the data source to model performance testing.

전체 흐름

데이터 추출·변환 → 결측 처리(A~D) → BN 학습(모델 1~4) → 부트스트랩 검증 → AUC → 순위합 순열검정

Step 1. 데이터 준비

- EDW 추출 (unpivoted) → 집계 → 속성 선택 → **피벗팅**
- 열 기반 형식으로 변환

a

ID	Code	Value	Time
a001	(BUN)	60.0	t1
a001	(CRE)	4.0	t1
a001	(WBC)	8.5	t1
a001	(WBC)	9.5	t2
a002	(CRE)	1.0	t3
a002	(WBC)	12	t3
.	.	.	

'(BUN)' refers to the PTXT code for 'BUN'.

b

ID	BUN	CRE	WBC
a001	60.0	4.0	8.5
a002	?	1.0	12.0
.			
.			
.			

'?' refers to the data element is missing.

Fig. 3. (a) Unpivoted table, (b) pivot table. Note that, in cases where more than one value was recorded in the first 48 h, the first value was chosen as representative.

Step 2. 결측 처리 (4가지)

방식	키워드	결측 명시
A	무처리 (빈 셀 유지)	×
B	평균/최빈값 대체	×
C	변수 내 **"missing" 상태** 추가 (층화)	○
D	**결측 지시 변수** 추가 (예: mWBC)	○

- C 적용을 위해 전 데이터셋 **등빈도 구간화(equal-frequency binning)**

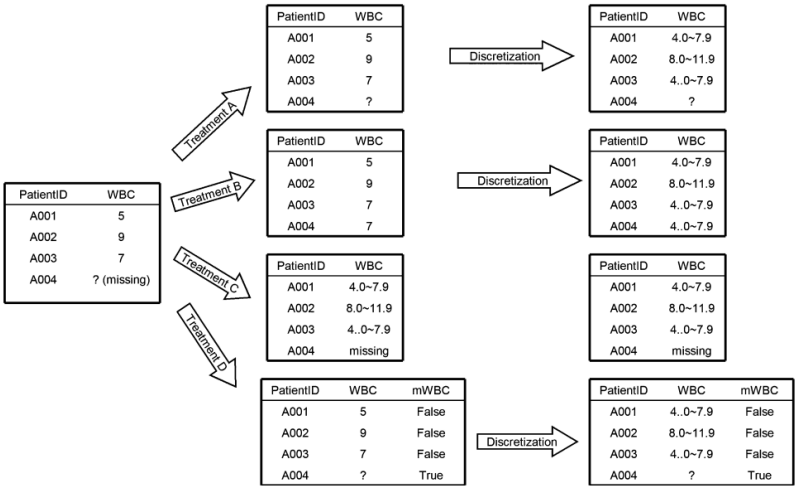
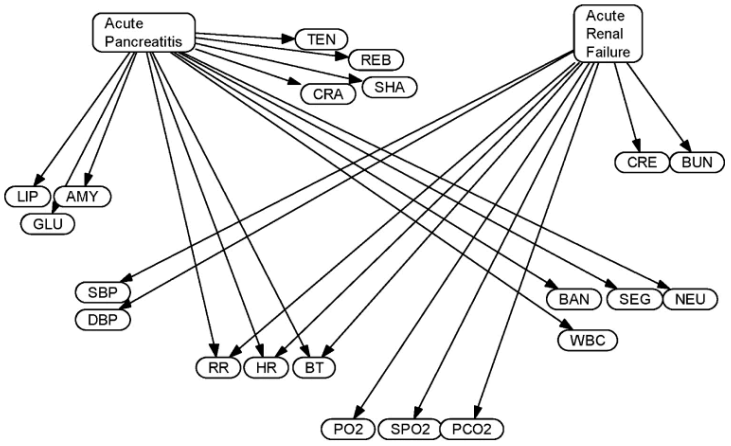


Fig. 4. An illustration of the missing value treatment process.

Step 3. 베이지안 네트워크 학습 (4가지 모델)

모델	구조	확률표
1	Naive Bayes	자체 Java
2	WinMine 학습	WinMine
3	WinMine 학습	Netica
4	저자 구성 (질병 → 이상 변수, 인과 모델)	Netica

- 종속변수 → 질병 유무 (이분형 노드)
- **학습** → 질병 유무 포함 전체 정보로 BN 학습
- **검증** → 질병 유무 제외 입력 → 확률 추론 → 실제와 비교
- 주의 → WinMine은 "missing" 상태 자동 도입 → **Model 2는 A 불가** (Model 3으로 보완)



Step 4. 성능 지표

- **AUC** → 유병률에 둔감
- 평가 단위 → 5개 질병 × 4개 모델 × 4개 처리 방식

Step 5. 부트스트랩 검증

- **500회 반복**
- 복원추출 → **재표집 세트(학습)** / 미선택 → **잔여 세트(검증)**
- 재표집·잔여 양쪽 AUC → **.632+ 가중평균**
  - R = (test − apparent) / (0.5 − apparent)
  - w = 0.632 / (1 − 0.368·R)
  - 추정 성능 = (1 − w)·apparent + w·test

Step 6. 통계 분석

- **순위합 순열검정**
  - 이유 → AUC 비정규 / 2집단 vs 2집단 / Model 2는 측정값 3개
  - 통계량 → 처리 방식 C+D **순위합**
  - p값 → 순위합 분포의 단측 누적 면적
- 산출 → 질병별 5 + 모델별 4 + 전체 1 = 10개 (음성군 전략별 각 1세트)

Use the ranking of four as an example:
The test statistic is the sum of ranks of last two elements.

Statistic (rank sum)	Frequency (number of permutations that produce values equal to the statistic)	Significance level	
3	4	4/4!	= 0.1667
4	4	(4+4)/4!	= 0.3333
5	8	(4+4+8)/4!	= 0.6667
6	4	(4+4+8+4)/4!	= 0.8883
7	4	(4+4+8+4+4)/4!	= 1

▼ 해석·한계

- C·D가 A·B보다 유의하게 우수 ($p<0.05$)

- 질병 기준 → 10개 중 **8개**
- 모델 기준 → 10개 중 **9개** (1개 borderline, p=0.0594)
- 전체 순위합 → **p=0.0000**

- 예외 → 천식 1개, 폐렴 1개 데이터셋은 향상 없음
- 해석 → 명시적 결측 표현 시 성능 향상 → **결측의 일부는 NMAR**

Table 4
The average AUCs of systems using randomly selected negative group

Diagnosis	Missing data treatment	Bayesian network learning scheme				Rank sum of Treatments C and D [possible min., possible max.]
		Naive Bayes	WinMine	WinMine + Netica	Human-composed structure	
Acute pancreatitis	A	0.9572(3)	x	0.9479(2)	0.9481(3)	14 [12, 26] ($p = 0.0278$)
	B	0.9433(4)	0.9459(3)	0.9458(3)	0.9294(4)	
	C	0.9818(2)	0.9881(2)	0.9881(1)	0.9816(1)	
	D	0.9818(1)	0.9887(1)	0.9420(4)	0.9816(2)	
Acute renal failure	A	0.9905(3)	x	0.9827(3)	0.9880(3)	12 [12, 26] ($p = 0.0015$)
	B	0.9843(4)	0.9734(3)	0.9734(4)	0.9505(4)	
	C	0.9971(1)	0.9978(1)	0.9978(1)	0.9976(1)	
	D	0.9970(2)	0.9971(2)	0.9848(2)	0.9963(2)	
Asthma	A	0.9758(2)	x	0.9772(4)	0.9750(1)	20 [12, 26] ($p = 0.7315$)
	B	0.9775(1)	0.9785(3)	0.9785(3)	0.9749(2)	
	C	0.9691(4)	0.9826(2)	0.9826(1)	0.9743(3)	
	D	0.9719(3)	0.9835(1)	0.9797(2)	0.9734(4)	
Pneumonia	A	0.9677(4)	x	0.9686(4)	0.9647(4)	13 [12, 26] ($p = 0.0077$)
	B	0.9786(3)	0.9774(3)	0.9774(2)	0.9749(3)	
	C	0.9793(2)	0.9833(2)	0.9833(1)	0.9791(1)	
	D	0.9802(1)	0.9851(1)	0.9705(3)	0.9778(2)	
Urinary tract infection	A	0.8764(4)	x	0.8875(3)	0.8447(4)	12 [12, 26] ($p = 0.0015$)
	B	0.8973(3)	0.8846(3)	0.8846(4)	0.8476(3)	
	C	0.9361(2)	0.9586(2)	0.9586(1)	0.9303(1)	
	D	0.9370(1)	0.9600(1)	0.9164(2)	0.9303(2)	
	Rank sum of Treatments C and D [possible min., possible max.]	19 [15, 35] ($p = 0.0271$)	15 [15, 25] ($p = 0.0041$)	18 [15, 35] ($p = 0.0104$)	19 [15, 35] ($p = 0.0271$)	71 [60, 130] ($p = 0.0000$)

The AUCs are the results of 500 iterations of bootstrapping for training/testing of each data set. The data sets are composed of each disease group of patients and the randomly selected negative group. Missing data treatments include A, original status; B, imputed with general mean; C, "missing" state; and D, "missing" node.
The numbers in parentheses are the ranks among four missing data treatments for each combination of disease and Bayesian model. In the margin cells, rank sums of Treatments C and D are shown. The numbers in the bracket are the minimums and maximums of all permutations of ranks. The p values were calculated by permutation tests. Note that, because WinMine automatically generates parameters based on explicitly missing values, an analysis of data Treatment A used to train WinMine alone is not possible.

Table 5
The average AUCs of systems using the other diseases as the negative group

Diagnosis	Missing data treatment	Bayesian network learning scheme				Rank sum of Treatments C and D [possible min., possible max.]
		Naive Bayes	WinMine	WinMine + Netica	Human-composed structure	
Acute pancreatitis	A	0.9623(3)	x	0.9580(2)	0.9366(3)	13 [12, 26] ($p = 0.0077$)
	B	0.9333(4)	0.9157(3)	0.9157(4)	0.8841(4)	
	C	0.9863(1)	0.9880(1)	0.9880(1)	0.9847(2)	
	D	0.9862(2)	0.9846(2)	0.9358(3)	0.9848(1)	
Acute renal failure	A	0.9779(3)	x	0.9708(4)	0.9730(3)	13 [12, 26] ($p = 0.0077$)
	B	0.9759(4)	0.9735(3)	0.9735(2)	0.9715(4)	
	C	0.9811(1)	0.9772(1)	0.9772(1)	0.9750(1)	
	D	0.9809(2)	0.9771(2)	0.9726(3)	0.9750(2)	
Asthma	A	0.9034(4)	x	0.8901(2)	0.8760(3)	13 [12, 26] ($p = 0.0077$)
	B	0.9049(3)	0.8856(3)	0.8856(4)	0.8696(4)	
	C	0.9235(1)	0.9233(1)	0.9233(1)	0.8886(2)	
	D	0.9234(2)	0.9153(2)	0.8870(3)	0.8893(1)	
Pneumonia	A	0.8678(1)	x	0.8766(2)	0.8236(1)	17 [12, 26] ($p = 0.2685$)
	B	0.8546(4)	0.8551(3)	0.8551(4)	0.8002(4)	
	C	0.8605(3)	0.8816(1)	0.8816(1)	0.8131(2)	
	D	0.8606(2)	0.8800(2)	0.8754(3)	0.8120(3)	
Urinary tract infection	A	0.9371(3)	x	0.9280(2)	0.8661(3)	13 [12, 26] ($p = 0.0077$)
	B	0.9237(4)	0.9148(3)	0.9148(4)	0.8514(4)	
	C	0.9476(1)	0.9555(1)	0.9555(1)	0.8893(2)	
	D	0.9474(2)	0.9457(2)	0.9222(3)	0.8894(1)	
	Rank sum of Treatments C and D [possible min., possible max.]	17 [15, 35] ($p = 0.0033$)	15 [15, 25] ($p = 0.0041$)	20 [15, 35] ($p = 0.0594$)	17 [15, 35] ($p = 0.0033$)	69 [60, 130] ($p = 0.0000$)

The AUCs are the results of 500 iterations of bootstrapping for training/testing of each data set. The experiment and analysis are identical to that of Table 4, except the data sets are composed of each disease group of patients and the other disease groups as the negative group.

한계

- 결측을 **모든 변수에 일괄 처리** → 일부 지시자만 성능에 기여 (예비 연구, χ^2 순 추가)
- ICD9 **주진단만** 사용 → 다중질환 환자 교란
- 임상 적용 시 → ROC 검토, 사전확률 재보정, 임계값 설정 필요

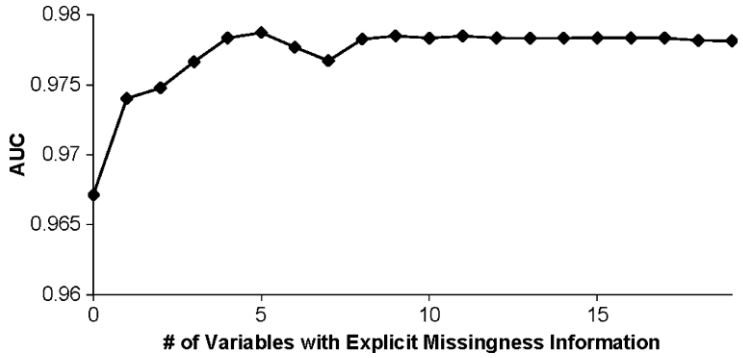


Fig. 6. The AUC of gradually adding missing information for detecting pneumonia.