KBO 리그 관중 수 예측 논문 리뷰

딥러닝 기반 KBO 리그 흥행 예측: 관중 수를 중심으로 · 유현정·장병희 · 2026

1. 연구 배경 및 목적

- 관중 수는 구단 수익·경기 운영·마케팅 계획에 연결된다. 기존 연구는 팀 성적, 일정, 과거 관중 수 등 **정형 정보**에 집중했다.
- 이 연구는 뉴스·이벤트·유튜브 텍스트를 추가하면 **경기별 관중 수 예측이 개선되는지** 비교한다.
- OLS부터 멀티모달 DNN까지 다섯 모델을 비교한다. 목표는 예측 성능 검토이며, 마케팅의 인과적 효과를 입증하는 것은 아니다.

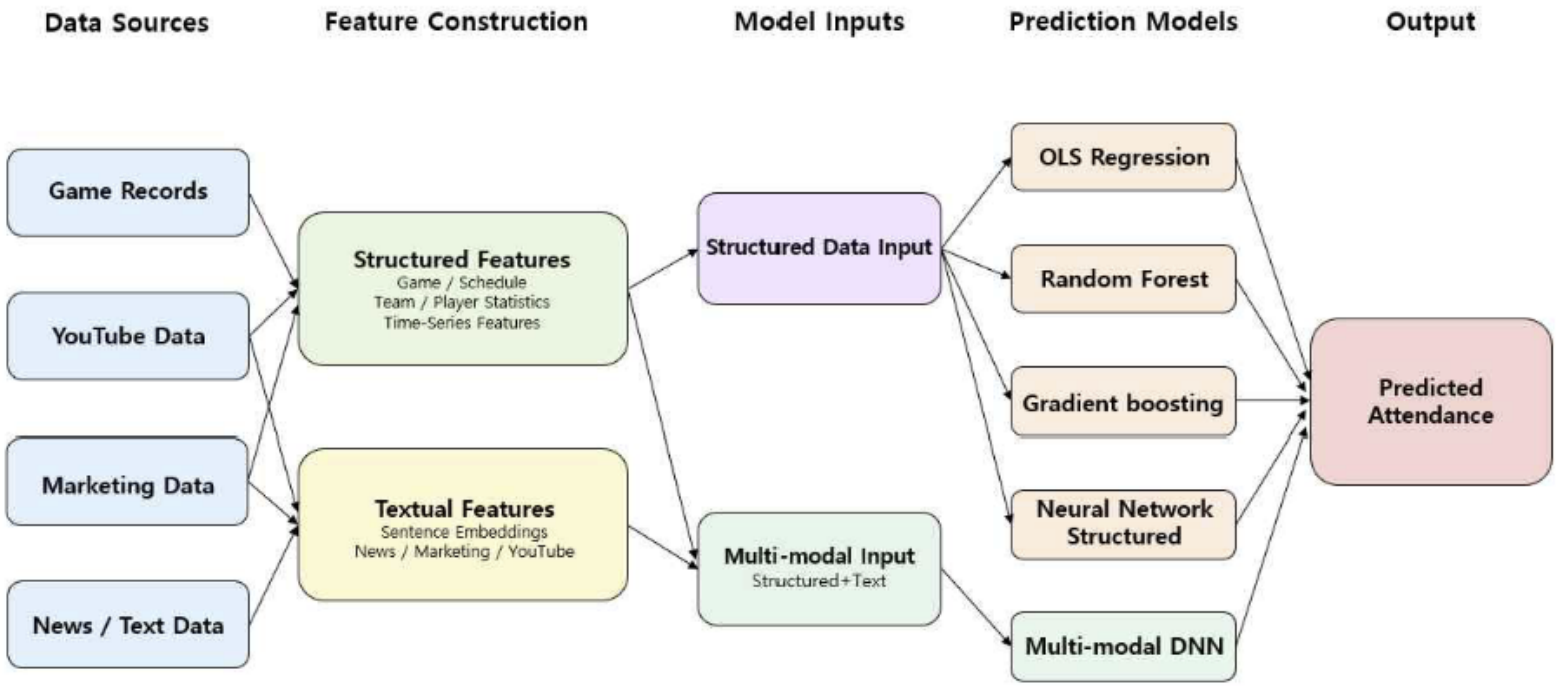


그림 1. 연구모형 | 원문 p.215

읽는 포인트 경기 기록과 텍스트에서 특징을 만들고, 서로 다른 모델로 같은 목표인 관중 수를 예측한다.

2. 데이터 수집 및 전처리

- **대상**: 2023-2025년 KBO 정규시즌 2,161경기.
- **분석 단위**: 개별 경기.
  예측 대상: 관중 수.
- **정형·시계열**: 팀·구장·요일·주말 여부·시즌 진행도·성적·과거 관중 수.
- **텍스트**: 뉴스 제목, 이벤트·마케팅 문구, 유튜브 제목·설명.
- 수치형은 표준화 또는 정규화, 범주형은 원-핫 인코딩 또는 임베딩을 사용한다.
- Sentence-Transformers로 문장의 의미를 수치 벡터로 바꾼다.
- **경기 시작 전 정보**를 사용한다. 누적 조회 수·좋아요 등은 수집 시점 확인이 필요하다.

분류		주요 내용	변수 개수	모델 입력 피처 개수	특징
수치/시계열	시계열 변수 (TS)	홈팀의 과거 관중 수, 최근 성적 흐름 등	16개	약 87개	1:1 대응 (스케일링만 수행)
	팀/선수 성적 (Static)	홈/원정팀의 시즌 타격·투수 지표 및 주요 선수 지표	68개		
	마케팅 및 외부 지표	마케팅 게시물 건수, 팀 간 마케팅 격차 등	3개		
범주형	시간 및 경기 정보	날짜, 요일, 시즌 진행률, 구장 정보 등	팀/장소 변수 (4개): 요일, 구장, 홈팀명, 원정팀명	피처 수십 개 (차원 설정에 따라 가변)	임베딩 차원에 따라 결정
텍스트/임베딩	텍스트/고정 임베딩	마케팅 제목, 뉴스, 유튜브 영상 텍스트 임베딩	텍스트 소스 4개 그룹(마케팅 텍스트(홈/원정), 뉴스 제목, 유튜브 정보)+팀 정적 임베딩 1개	약 256~512개 (추정)	고차원 벡터로 변환
총합			약 96개	**최소 400~700개 사이**	**데이터 차원 확장 발생**

표 해석
입력 차원에는 '약', '추정', '가변' 표기가 있다. 고정된 동일 차원으로 해석하지 않는다.

표 1. 독립변수 및 피처 구성 · p.216

3. 예측 모형과 선형 회귀

모형	핵심 방법	비교에서의 역할
OLS	입력 변수의 선형 결합	선형 회귀 기준 모델
Random Forest	여러 의사결정나무의 예측 결합	비선형 관계 학습
Gradient Boosting	앞선 예측의 오차를 보완하며 나무 추가	단계적인 예측 개선
Neural Network	정형·범주형 입력을 다층 신경망으로 처리	신경망 기준 모델
Multi-modal DNN	시계열·정형·텍스트 특징을 결합	정보 통합 효과 검토

선형 회귀와 연결해서 이해하기

$$\hat{y}_i = b + \sum_{j=1}^{p} w_j x_{ij}$$

- x_{ij}: i번째 경기의 j번째 입력 변수. w_j: 변수에 곱하는 가중치. **b**: 절편.
- y_i는 실제 관중 수, 위 식의 예측값은 모델이 계산한 관중 수이다.
- OLS는 실제값과 예측값의 **차이를 제곱한 합**이 가장 작아지도록 가중치와 절편을 정한다.

$$\min_{w,b} \sum_{i=1}^{n} (y_i - \hat{y}_i)^2$$

이 논문에서 OLS는 **기준점**이다. 더 복잡한 모델이나 텍스트 정보가 이 기준보다 예측 오차를 얼마나 줄이는지 살펴본다.

3. 예측 모형 구성 | 멀티모달 DNN

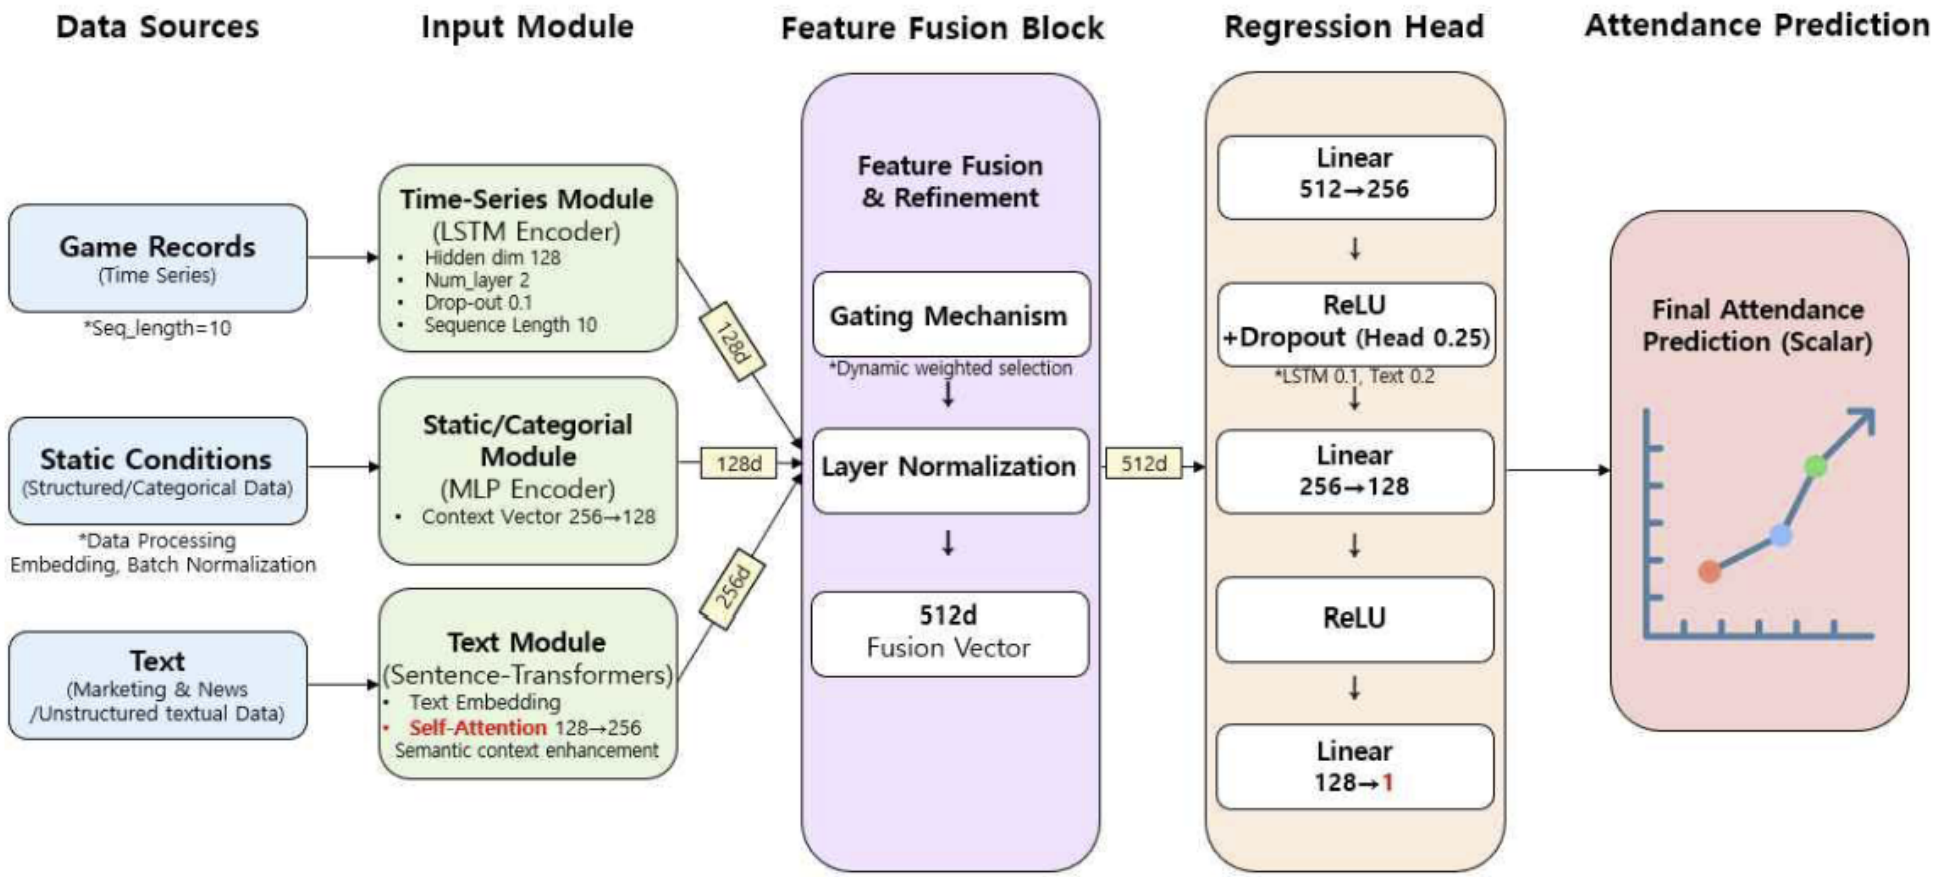


그림 2. 관중 수 예측을 위한 멀티모달 딥러닝 모형 구조 · p.218

- **LSTM**: 최근 관중 수와 성적의 시간적 흐름을 학습한다. **MLP**: 일정·팀·구장 등 정형·범주형 정보를 처리한다.
- **텍스트 모듈**: 문장 임베딩과 어텐션으로 뉴스·홍보 문구의 의미 정보를 처리한다.
- **특징 결합 → 회귀 헤드**: 각 경로의 특징을 합쳐 최종적으로 관중 수 하나를 출력한다.

멀티모달은 이 논문에서 시계열·정형·텍스트 정보를 함께 활용한다는 뜻이다.

4. 학습 및 평가 방법

- 전체 경기 데이터를 무작위로 섞어 **훈련 70% / 검증 15% / 테스트 15%**로 분할한다.
- 비교 모델에 동일한 데이터 분할과 평가 지표를 적용했다고 보고한다.

〈표 2〉. 모델 학습 및 최적화를 위한 하이퍼파라미터
(Tab 2. Hyperparameter for Model Learning and Optimization)

항목	설정 내용
손실 함수 (Loss Function)	MSE(Mean Squared Error) Loss
옵티마이저 (Optimizer)	Adam
학습률 (Learning Rate)	1x1e-4
배치 크기 (Batch Size)	64
에포크 (Epochs)	150
학습 스케줄러 (Learning Rate Scheduler)	RecueLROnPlateau (Factor=0.5, Patience=10, Min_lr=1e-5)
조기 종료 (Early Stopping)	Patience=30
데이터 분할	랜덤 셔플 후 Train 0.7, Validation 0.15, Test 0.15

표 2. 모델 학습 및 최적화를 위한 하이퍼파라미터 · p.218

지표	쉽게 이해하는 의미	좋은 방향
RMSE	큰 예측 오차에 더 민감한 오차 지표	낮을수록 좋음
MAE	실제값과 예측값 차이의 절댓값 평균	낮을수록 좋음
MAPE	실제 관중 수 대비 절대 오차의 평균 비율	낮을수록 좋음
R^2	관중 수 변동을 예측이 얼마나 설명하는지 표시	높을수록 좋음

표의 Adam·MSE 등은 신경망 학습 설정이다. 랜덤 분할 결과를 미래 시즌 예측 성능으로 바로 해석하지 않는다.

5. 모델별 예측 성능

〈표 3〉. 전체 모델별 예측 성능 비교 결과
(Tab 3. Forecast Performance Comparison Results by overall Model)

	Model	RMSE	MAE	MAPE	R^2
Statistics	OLS	3,449	2,707	0.342	0.717
Machine Learning	Random Forest	2,936	2,092	0.247	0.795
	Gradient Boosting	2,887	2,206	0.244	0.801
Deep Learning	Neural Network	2,753	2,203	0.209	0.812
	Neural Network + Text Embedding	2,362	1,708	0.150	0.847

표 3. 전체 모델별 예측 성능 비교 결과 · p.218

- **Multi-modal DNN이 네 가지 평가 지표에서 가장 좋은 결과**를 보였다.
- **RMSE 2,362명 / MAE 1,708명 / MAPE 0.150 / R^2 0.847**. OLS의 MAE는 2,707명이다.
- 정형 Neural Network 대비 멀티모달 모델의 **RMSE가 약 14.2% 감소**했다.
- MAPE 0.150은 15.0%이다. **R^2 0.847은 '정확도 84.7%'가 아니다.**
- 모든 지표가 모델 복잡도와 함께 개선되지는 않는다. MAE에서는 Random Forest가 정형 Neural Network보다 작다.

5. 주요 변수 해석 | 무엇이 예측에 중요했나?

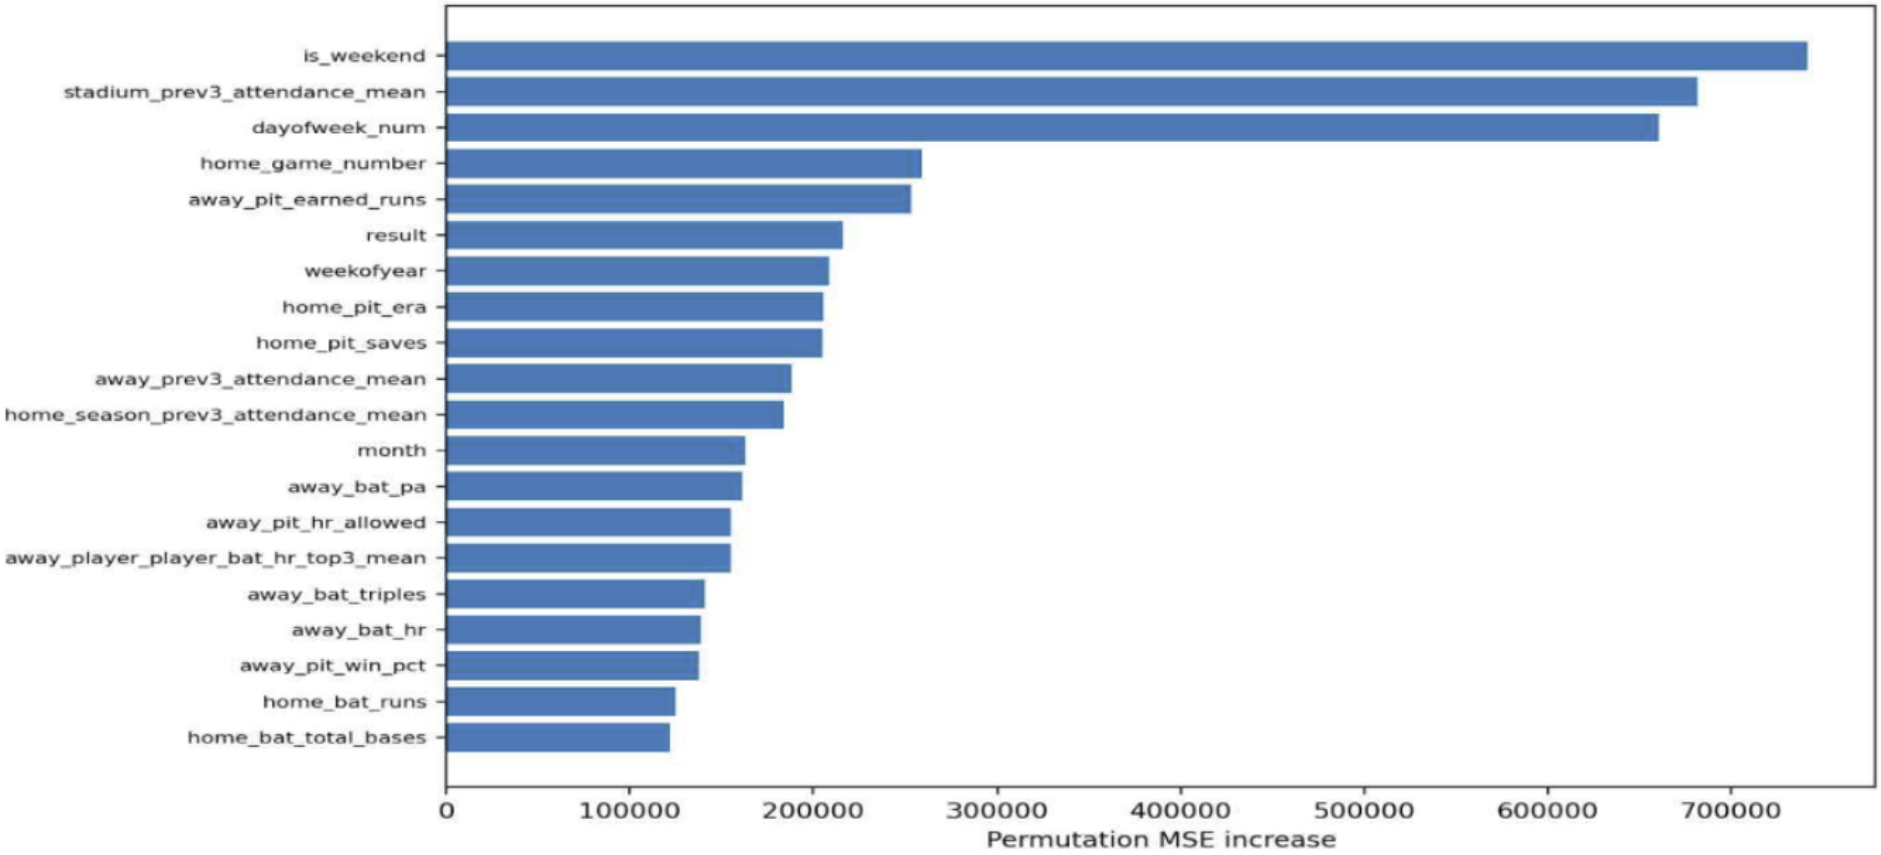


그림 7. Multi-modal DNN 모델 변수 중요도 결과 분석 · p.220

- **주말 여부, 요일, 최근 관중 수, 시즌 진행도** 등 일정과 과거 수요 관련 변수가 중요하게 보고되었다.
- 이 그래프의 가로축은 **Permutation MSE increase**이다. 해당 정보를 섞었을 때 오차가 얼마나 증가하는지 나타낸다.
- 중요도는 예측에서의 유용성을 보여준다. 해당 변수를 바꾸면 관중 수가 증가한다는 인과적 증거는 아니다.

텍스트 정보는 기본적인 수요 구조에 경기별 관심과 맥락을 더하는 보완 정보로 해석된다.

6. 텍스트 정보의 기여도

Ablation Study는 입력 정보나 구성 요소를 추가·제거하면서 성능 변화를 비교하는 실험이다.

〈표 5〉. Ablation study 결과
(Tab 5. Results of Ablation study)

Model	Input	RMSE	MAE	MAPE	R^2
Neural Network + Structured	정형 + 시계열 + 범주형	2,753	2,203	0.209	0.812
Neural Network + News Text	정형 + 뉴스 기사 제목 임베딩	2,612	2,031	0.189	0.824
Neural Network + Marketing Text	정형 + 이벤트/마케팅 텍스트 임베딩	2,548	1,964	0.178	0.832
Neural Network + Youtube Text	정형 + 유튜브 콘텐츠 텍스트 임베딩	2,596	2,004	0.185	0.827
Neural Network + All Text	정형 + 전체 텍스트 임베딩	2,362	1,708	0.150	0.847

표 5. Ablation study 결과 · p.221

- 텍스트 미사용 RMSE는 **2,753명**. 뉴스 추가 2,612명, 마케팅 추가 2,548명, 유튜브 추가 2,596명이다.
- **전체 텍스트 결합은 RMSE 2,362명**으로 가장 낮았다.
- 단일 소스에서는 마케팅 텍스트가 가장 좋았고, 전체 텍스트를 함께 사용한 모델이 가장 우수했다.
- 이는 텍스트를 추가한 모델의 **예측 오차 감소**를 보여준다. 마케팅 문구의 인과적 효과를 뜻하지 않는다.

7. 결론 및 리뷰 관점

논문의 기여

- 선형 회귀를 기준으로 머신러닝·딥러닝 모델의 관중 수 예측 성능을 비교했다.
- 일정·과거 관중 수가 중요한 기반이며, 텍스트 정보가 이를 보완할 수 있음을 제시했다.
- 구단의 경기별 수요 예측과 마케팅 자원 배분에 활용할 가능성을 보여준다.

논문이 밝힌 한계

- **랜덤 분할 검증**: 미래 시즌에서의 일반화 성능은 시간 기반 검증으로 추가 확인해야 한다.
- **수집 시점**: 경기 이후의 반응이 입력에 섞이지 않도록 정보의 생성·수집 시간을 통제해야 한다.
- **인과관계**: 개별 변수나 마케팅 활동의 인과적 효과를 직접 검증하지 않았다.

리뷰에서 추가로 확인할 점

- 텍스트 추가 효과를 분리하려면 나머지 모델 구조와 학습 조건이 얼마나 동일하게 통제되었는지 확인할 필요가 있다.
- **후속 실험 제안**: 2023-2024년으로 학습하고 2025년으로 평가한다. 이는 본 논문에서 수행한 실험이 아닌 리뷰자의 제안이다.

리뷰 핵심
선형 회귀를 기준으로 관중 수 예측 문제를 이해하고, 텍스트 정보의 추가 효과와 검증상의 한계를 함께 평가한다.

논문 출처
유현정·장병희(2026), 「딥러닝 기반 KBO 리그 흥행 예측: 관중 수를 중심으로」, 한국엔터테인먼트산업학회논문지, 20(3), 211-224.
DOI: 10.21184/jkeia.2026.6.20.3.211

시각자료는 사용자가 제공한 확대 원문 이미지이다. 도식·수치·변수명은 변경하지 않았고, 가독성을 위해 여백과 캡션 배치를 조정했다. 요약·수식 설명·리뷰 의견은 원문 시각자료와 구분해 작성했다.