SECOM 반도체 데이터에 PCA를 적용하면?

지난 논문에서 확인한 “많은 센서 변수 → 저차원 표현” 아이디어를 실제 공개 데이터에 적용하고, PCA 전·후 성능을 비교

발표의 핵심 질문

450개의 공정 변수를 PCA로 줄였을 때, 불량(Fail) 분류 성능과 학습 효율은 어떻게 달라질까?

DATA

1,567 × 590

Fail 104개 (6.64%)

PREPROCESS

590 → 450

고결측 24 + 상수 116 제거

FINAL PCA

450 → 127

90% 설명분산 · 71.8% 축소

한 문장 결론

PCA 90%는 전체 성능을 높이지는 않았지만, 450개 변수를 127개로 줄이면서 Balanced Accuracy를 거의 유지했고 Fail Recall과 Logistic Regression 학습 효율은 개선했다.

PCA 전에 먼저 “쓸 수 있는 센서 데이터”를 만든다

SECOM 원본은 결측치와 상수 변수가 많고, Fail 비율이 6.64%로 매우 불균형하다.

원본 데이터

Samples	Sensor variables	Missing values
1,567	590	41,951
공정 샘플 수	원본 공정 변수	538개 변수에 결측 존재

Class imbalance **Pass 1,463 (93.36%)** **Fail 104 (6.64%)**

따라서 Accuracy 하나만 보면 모델 성능을 과대평가할 수 있어 Fail Recall · Balanced Accuracy · F1 · ROC-AUC를 함께 비교.

전처리 흐름

Train/Test	고결측 제거	상수 제거	Median	Standardize
1253 / 314	590 → 566	566 → 450	결측값 → 0	μ≈0, σ≈1
stratify=y	Train 결측률 ≥ 50%	분산 0 변수 116개	Train 중앙값 사용	PCA 전 스케일 통일

표준화

$$z = (x - \mu) / \sigma$$

모든 전처리 기준(결측률, 중앙값, 평균·표준편차)은 Train에서만 학습하고 Test에는 transform만 적용했다. → Data Leakage 방지

Source: UCI Machine Learning Repository - SECOM · 실제 코드: notebooks/01_secom_pca.ipynb

450개 센서 변수를 주성분 좌표로 바꾼다

PCA는 라벨을 보지 않고 분산이 큰 방향을 찾는다. 이번 실험은 설명분산 기준을 여러 개 비교한 뒤 대표 설정을 선택했다.

핵심 수식

Projection

$$Z = W^T X$$

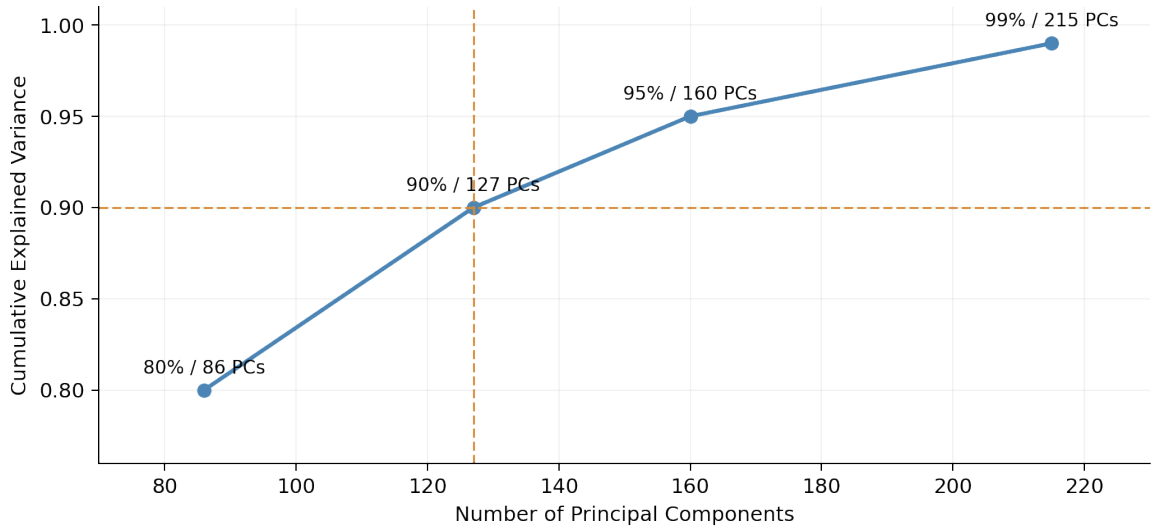
450차원 X를 주성분 방향 W에 투영해 PC 좌표 Z로 변환

Explained variance rule

$$\Sigma \text{ EVR} \geq \tau$$

τ = 0.80 / 0.90 / 0.95 / 0.99를 비교해
필요한 최소 PC 개수 확인

실험 결과



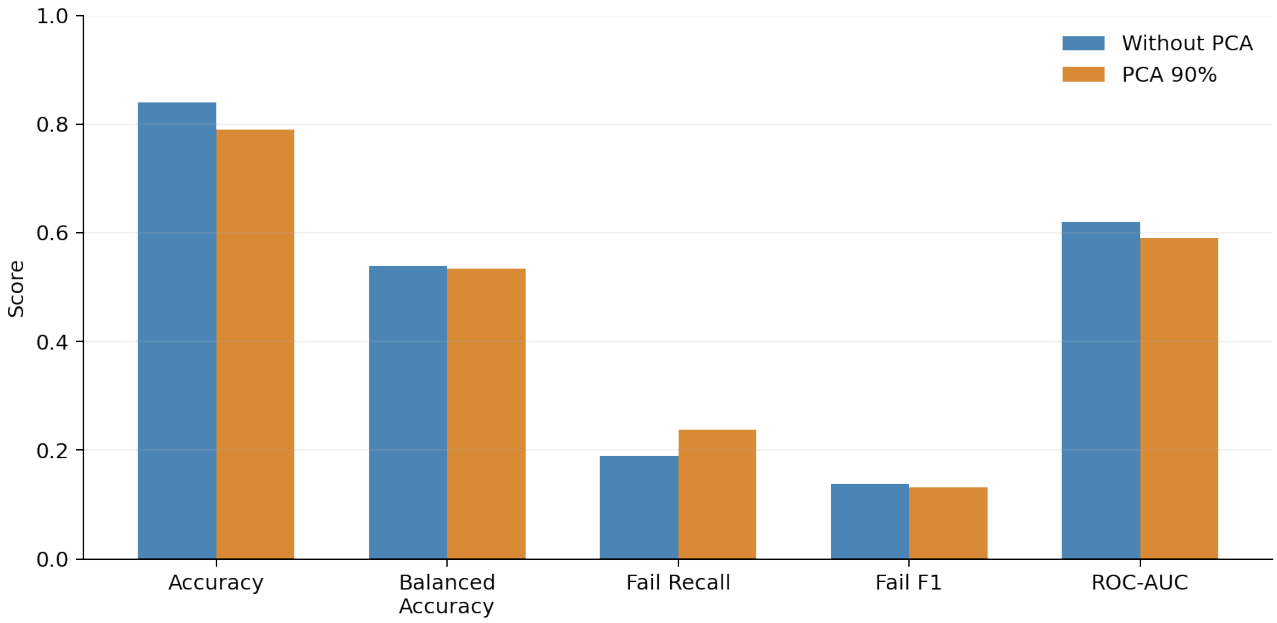
80%	90%	95%	99%
86 PC	127 PC	160 PC	215 PC
너무 강한 압축	최종 선택	추가 이득 없음	Recall 이점 소멸

최종 기준: PCA 90% = 127 PCs · 450 → 127 = 71.8% 차원 축소

차원은 크게 줄었지만, 분류 성능은 지표별로 엇갈렸다

동일한 Logistic Regression(class_weight="balanced")을 사용해 PCA 자체의 영향을 비교했다.

Dimensions	Balanced Acc.	Fail Recall	LR fit time
450 → 127	0.5389 → 0.5337	19.05% → 23.81%	0.0966 → 0.0289 s
-71.8%	거의 유지	+4.76%p	약 -70%



Confusion Matrix

Without PCA

	예측 Pass	예측 Fail
실제 Pass	260	33
실제 Fail	17	4

PCA 90%

	예측 Pass	예측 Fail
실제 Pass	243	50
실제 Fail	16	5

해석: PCA 후 Fail을 4개 → 5개로 더 잡았지만, 정상 샘플 오경보도 33개 → 50개로 증가

왜 95%가 아니라 90%를 최종 기준으로 골랐나?

설명분산을 높일수록 PC는 늘지만 성능이 단조롭게 좋아지지 않았다. → “정보 보존율”과 “분류 성능”은 같은 개념이 아니다.

설명분산	PC	Accuracy	Balanced	Recall	F1	ROC-AUC
80%	86	0.7134	0.4928	0.2381	0.1000	0.5999
90%	**127**	**0.7898**	**0.5337**	**0.2381**	**0.1316**	**0.5911**
95%	160	0.7803	0.5286	0.2381	0.1266	0.5636
99%	215	0.7994	0.5167	0.1905	0.1127	0.6168

Baseline (Without PCA)

450 vars · Accuracy 0.8408 · Balanced 0.5389 · Recall 0.1905 · F1 0.1379 · AUC 0.6203

선택 논리

80%	86 PC	Accuracy·Balanced Accuracy가 크게 하락 → 과도한 압축
90%	127 PC	Balanced Accuracy 거의 유지 + Recall 상승 + 큰 차원축소
95%	160 PC	PC는 33개 늘었지만 90%보다 성능 이득 없음

결론

대표 설정은 PCA 90%. “설명분산을 가장 많이 남기는 설정”이 아니라, 차원축소와 성능 간 trade-off가 가장 납득 가능한 지점을 선택했다.

중요: PCA는 분산을 보존하지, Fail 라벨을 가장 잘 구분하는 방향을 직접 최적화하지 않는다.

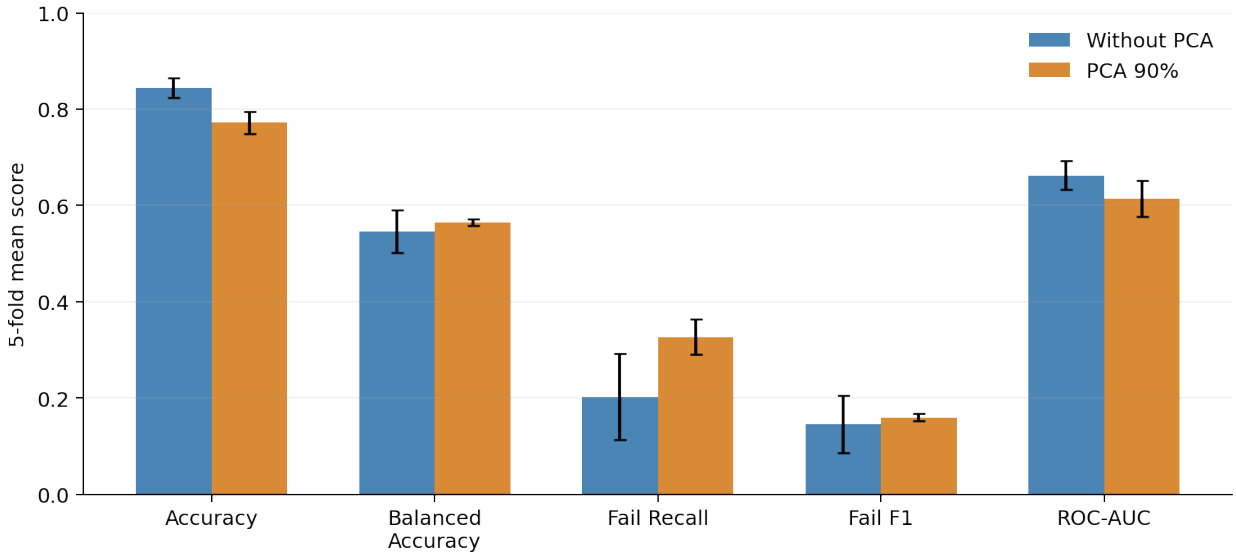
단일 split 결과가 우연인지 5-fold 교차검증으로 다시 확인

Test Fail이 21개뿐이라 한 번의 분할 결과에 민감할 수 있다. 그래서 같은 전처리와 모델을 fold마다 다시 학습해 평균 성능을 비교했다.

검증 설계

Stratified 5-fold CV

각 fold에서 고결측 제거 → 상수 제거 → Median → StandardScaler를 Train에만 fit한 뒤, Without PCA와 PCA 90%를 동일한 Logistic Regression으로 비교.



Balanced Acc.

0.5464 → 0.5653

평균 +0.0189

Fail Recall

20.29% → 32.67%

평균 +12.38%p

Fail F1

0.1462 → 0.1599

평균 소폭 개선

해석

교차검증 평균에서는 PCA 90%가 Balanced Accuracy·Fail Recall·F1을 높였다. 다만 Accuracy(0.8443→0.7722)와 ROC-AUC(0.6628→0.6139)는 낮아져, "전체 성능 향상"보다는 불량 민감도와 차원축소의 trade-off로 해석하는 것이 맞다.

범위 결정: 새 데이터셋을 추가하기보다 동일 SECOM에서 재현성 검증을 우선. UCI SECOM 설명도 cross-validation 평가를 권장한다.

PCA의 효과는 “성능 향상” 하나로 판단하면 안 된다

단일 split과 5-fold 교차검증을 함께 보면, PCA 90%의 장점과 한계가 더 분명해진다.

1

차원축소

450 → 127 (71.8% 축소)
5-fold에서도 평균 PC 수 약 127개로 안정적

2

불량 탐지

단일 split Recall 19.05% → 23.81%
5-fold 평균 Recall 20.29% → 32.67%
Balanced Accuracy도 CV 평균에서 0.5464 → 0.5653

3

남은 trade-off

Accuracy와 ROC-AUC는 PCA 후 감소
PCA는 비지도 방식이라 라벨에 중요한 저분산 정보가 손실될 수 있음

사용 툴 및 코드

VS Code · Jupyter Notebook · Python 3.11.15 · pandas · NumPy · Matplotlib · scikit-learn

Code: notebooks/01_secom_pca.ipynb Results: results/*.csv, results/*.png

최종 한 문장: “PCA 90%는 차원을 크게 줄이고 Fail 탐지 민감도를 높였지만, Accuracy·AUC 손실이 있어 목적에 따라 선택해야 하는 trade-off 방법이다.”