유방암 예측

상태 완료

유방암 예측

1. 분석 목적 및 문제 정의

▼ 배경

최근 유방암은 여성에게 발생하는 암 중 발생률이 높은 질환 중 하나로, 조기 발견 및 위험 요인 파악이 환자의 예후와 생존율에 중요한 영향을 미친다. 유방암의 발생은 유전적 요인, 생활습관, 병력, 진단 소견 등 다양한 요인이 복합적으로 작용하는 것으로 알려져 있으나, 어떤 요인이 실제로 유방암 발생과 유의한 관련이 있는지, 그리고 이를 기반으로 얼마나 정확하게 예측이 가능한지에 대한 체계적인 분석이 필요하다.

▼ 분석 목적

본 분석은 10,000명을 대상으로 한 설문 및 의료 데이터를 활용하여, 인구통계학적 특성·생활습관 요인·병력·진단 소견이 유방암 발생 여부(`Cancer`)에 어떤 영향을 미치는지 파악하고, 이를 기반으로 유방암 발생 여부를 예측하는 분류 모델을 구축하는 것을 목적으로 한다.

▼ 연구 문제

- 어떤 인구통계학적·생활습관·병력·진단 요인이 유방암 발생 여부와 유의한 관련이 있는가?
- 위 요인들을 feature로 활용하여 유방암 발생 여부를 얼마나 정확하게 예측할 수 있는가?
- 예측에 상대적으로 크게 기여하는 변수(군)은 무엇인가?

---

2. 개요

N: 10,000

Demographics

- **Num**
  - `age`, `BMI`, `Annual_Income_USD`
- **CAT**
  - `Gender`

Lifestyle Factors

- **Num**
  - `Exercise_Days_Per_Week`
- **CAT**
  - `Alcohol_Consumption`, `Physical_Activity`, `Breastfeeding_History`, `Smoking`

Medical History

- **Num**
  - `Blood_Pressure`, `Cholesterol`
- **CAT**
  - `Family_History`, `Hormone_Therapy`, `Menopause_Status`, `Genetic_Mutation`, `Diabetes`

Diagnostic Findings

- **Num**
  - `Tumor_Size_cm`
- **CAT**
  - `Lymph_Node_Involvement`, `Mammogram_Result`, `Biopsy_Result`, `Cancer_Stage`

---

3. 데이터 전처리

▼ 1) Feature/Target

a. Feature

`Patient_ID` 제외 (식별자 제거)
`Biopsy_Result`, `Cancer_Stage` 제외 (`Cancer`와 정보가 동일)

b. Target

`Cancer`

▼ 2) 결측치 처리

```
결측치 제거 전 암 환자 비율: 0.1933 (19.33%)
결측치 제거 전 전체 행 수: 10000
결측치 제거 후 암 환자 비율: 0.1945 (19.45%)
결측치 제거 후 전체 행 수: 9700
```

→ 결측치 제거

▼ 3) Encoding

a. 이진 (binary)

	Gender	Family_History	Smoking	Alcohol_Consumption
count	10000	10000	10000	9700
unique	2	2	2	2
top	Female	No	No	No
freq	9277	6979	7462	6319

Hormone_Therapy	Menopause_Status	Genetic_Mutation	Lymph_Node_Involvement
9700	10000	10000	10000
2	2	2	2
No	Post	Negative	No
7704	5509	8542	7977

Diabetes	Breastfeeding_History
10000	10000
2	3
No	Yes
8296	4514

`Gender`, `Family_History`, `Smoking`, `Alcohol_Consumption`, `Hormone_Therapy`, `Menopause_Status`, `Genetic_Mutation`, `Lymph_Node_Involvement`, `Diabetes` → 0/1 매핑

b. 순서 (ordinal)

Physical_Activity	
Moderate	4379
Low	2876
High	2445

dtype: int64

- `Physical_Activity` (Low < Moderate < High)

c. **명목 (nomial)**

`Mammogram_Result`, `Breastfeeding_History`

▼ 4) Train/Test

a. **ratio**

train/test (0.8/0.2)

b. **target**

`Cancer` 기준 stratify 적용

▼ 5) Scailing

- 대상: 연속형 변수 전체 + Ordinal Encoding된 변수

▼ 6) 다중공선성 (VIF)

a. **판단 기준**

- VIF > 10 → 제거 필요
- VIF 5~10 → 주의 관찰
- VIF < 5 → 문제 없음

b. **결과 요약**

- 최댓값: `Mammogram_Result_Normal` = 2.86 → 관대 기준(5)은 물론 엄격 기준에서도 전혀 문제 없음
- 전체 feature 중 VIF > 5 변수 없음

c. **주의 관찰 구간 (VIF 4~7)**

- 해당 없음

	feature	VIF
0	Mammogram_Result_Normal	2.86
1	Breastfeeding_History_Yes	1.99
2	Menopause_Status_Pre	1.70
3	Mammogram_Result_Suspicious	1.59
4	Alcohol_Consumption_Yes	1.46
5	Breastfeeding_History_Not Applicable	1.45
6	Family_History_Yes	1.39
7	Smoking_Yes	1.31
8	Lymph_Node_Involvement_Yes	1.23
9	Hormone_Therapy_Yes	1.23
10	Diabetes_Yes	1.18
11	Genetic_Mutation_Positive	1.16
12	Gender_Male	1.07
13	Age	1.00
14	Exercise_Days_Per_Week	1.00
15	Physical_Activity	1.00
16	Annual_Income_USD	1.00
17	Tumor_Size_cm	1.00
18	BMI	1.00
19	Blood_Pressure	1.00
20	Cholesterol	1.00

▼ 7) 최종 데이터셋 확정

a. **train**

```
X_train shape: (7760, 21)
X_test shape: (1940, 21)
```

b. **test**

```
y_train 분포:
 Cancer
0    0.805
1    0.195
Name: proportion, dtype: float64
y_test 분포:
 Cancer
0    0.806
1    0.194
Name: proportion, dtype: float64
```

---

4. 모델링 (without PCA)

▼ 모델링

a. **로지스틱 회귀 (Logistic Regression)**

정확도 (Accuracy) : 0.95

	precision	recall	f1-score	support
0	0.959	0.976	0.968	1563.000
1	0.894	0.828	0.860	377.000
accuracy	0.947	0.947	0.947	0.947
macro avg	0.927	0.902	0.914	1940.000
weighted avg	0.946	0.947	0.947	1940.000

	Pred_0	Pred_1
Actual_0	1526	37
Actual_1	65	312

b. **의사결정나무 (Decision Tree)**

정확도 (Accuracy) : 0.99

	precision	recall	f1-score	support
0	0.990	0.993	0.991	1563.000
1	0.970	0.958	0.964	377.000
accuracy	0.986	0.986	0.986	0.986
macro avg	0.980	0.975	0.978	1940.000
weighted avg	0.986	0.986	0.986	1940.000

	Pred_0	Pred_1
Actual_0	1552	11
Actual_1	16	361

	Feature	Importance
0	Age	0.1679
1	Tumor_Size_cm	0.1462
2	Smoking_Yes	0.1280
3	Family_History_Yes	0.1248
4	Genetic_Mutation_Positive	0.1232
5	Lymph_Node_Involvement_Yes	0.1149
6	BMI	0.1063
7	Mammogram_Result_Normal	0.0826
8	Physical_Activity	0.0010
9	Cholesterol	0.0009
10	Breastfeeding_History_Yes	0.0008
11	Annual_Income_USD	0.0008
12	Blood_Pressure	0.0008
13	Menopause_Status_Pre	0.0007
14	Hormone_Therapy_Yes	0.0007
15	Exercise_Days_Per_Week	0.0004
16	Gender_Male	0.0000
17	Alcohol_Consumption_Yes	0.0000
18	Mammogram_Result_Suspicious	0.0000
19	Diabetes_Yes	0.0000
20	Breastfeeding_History_Not Applicable	0.0000

c. **그래디언트 부스팅 (Gradient Boosting)**

정확도 (Accuracy) : 1.00

	precision	recall	f1-score	support
0	0.996	1.000	0.998	1563.000
1	1.000	0.984	0.992	377.000
accuracy	0.997	0.997	0.997	0.997
macro avg	0.998	0.992	0.995	1940.000
weighted avg	0.997	0.997	0.997	1940.000

	Pred_0	Pred_1
Actual_0	1563	0
Actual_1	6	371

	Feature	Importance
0	Mammogram_Result_Normal	0.1531
1	Tumor_Size_cm	0.1408
2	Age	0.1306
3	Smoking_Yes	0.1302
4	Family_History_Yes	0.1236
5	BMI	0.1220
6	Lymph_Node_Involvement_Yes	0.1002
7	Genetic_Mutation_Positive	0.0963
8	Mammogram_Result_Suspicious	0.0027
9	Annual_Income_USD	0.0002
10	Blood_Pressure	0.0001
11	Cholesterol	0.0001
12	Physical_Activity	0.0000
13	Hormone_Therapy_Yes	0.0000
14	Alcohol_Consumption_Yes	0.0000
15	Exercise_Days_Per_Week	0.0000
16	Gender_Male	0.0000
17	Menopause_Status_Pre	0.0000
18	Diabetes_Yes	0.0000
19	Breastfeeding_History_Not Applicable	0.0000
20	Breastfeeding_History_Yes	0.0000

▼ 모델 평가 및 비교

a. **교차 검증 (Cross-Validaion)**

	Logistic	DecisionTree	GradientBoosting
0	0.897341	0.975145	0.996905
1	0.890276	0.968017	0.991694
2	0.896922	0.977445	0.990643
3	0.880676	0.978389	0.996905
4	0.912129	0.980496	0.995878

	mean_macro_f1
Logistic	0.895
DecisionTree	0.976
GradientBoosting	0.994

b. **최종 성능 비교**

Model	Accuracy	Macro F1	Weighted F1
Logistic	0.947	0.914	0.947
DecisionTree	0.986	0.978	0.986
GradientBoosting	0.997	0.995	0.997

▼ 종합 결론

a. **모델 성능**

- Accuracy: Gradient Boosting(0.997) > Decision Tree(0.986) > Logistic(0.947)
- Macro F1: Gradient Boosting(0.995) > Decision Tree(0.978) > Logistic(0.914), CV 기준도 동일 순위(GB 0.994 > DT 0.976 > Logistic 0.895)
  *Macro F1: 클래스별 F1-score를 단순 평균낸 값

→ **Gradient Boosting이 test/CV 모두에서 가장 우수하고 안정적**

b. **변수 중요도 (Feature Importance)**

- 1위: `Mammogram_Result_Normal` (유방촬영 정상 여부) — GB 기준 0.153
- 2위: `Tumor_Size_cm` (종양 크기)
- 3~4위: `Age`, `Smoking_Yes` (연령, 흡연)
- 5~6위: `Family_History_Yes`, `BMI` (가족력, 체질량지수)
- 7~8위: `Lymph_Node_Involvement_Yes`, `Genetic_Mutation_Positive` (림프절 침범, 유전자 변이)
  → 위 8개 변수가 예측력의 대부분을 차지, 나머지 13개 변수(소득·혈압·콜레스테롤·음주 등)는 기여도 거의 0
  → Decision Tree와 Gradient Boosting **두 모델 모두 동일한 8개 변수**를 선택 (순위만 약간 다름) — 우연이 아닌 데이터 구조적 특성으로 보임

c. **종합 결론**

- 최종 모델: **Gradient Boosting** (Accuracy·Macro F1·CV 안정성 종합 1위)
- 핵심 예측 요인: 유방촬영 결과 > 종양 크기 > 연령·흡연 > 가족력·BMI → 임상적으로 알려진 유방암 위험 요인들과 대체로 일치
- **한계 (반드시 확인 필요)**: Gradient Boosting의 test Accuracy 0.997, ROC-AUC 1.0000은 실제 임상 데이터로는 비정상적으로 높은 수치입니다. `Biopsy_Result`·`Cancer_Stage`처럼 타겟과 100% 일치하는 컬럼은 이미 제거했지만, 8개 변수 조합이 5-fold 교차검증 전체에서 일관되게(0.99 안팎) 거의 완벽한 분류를 보인다는 점은 이 데이터셋이 **규칙 기반 합성(synthetic) 데이터일 가능성**을 시사합니다. → 실제 서비스에 적용하기 전에 데이터 출처(Kaggle 데이터셋 설명·생성 방식)를 확인하고, 가능하면 별도의 실제 임상 데이터로 재검증이 필요합니다.

---

5. 모델링 (with PCA)

▼ PCA

a. **진행 과정**

데이터 전처리 1) ~ 4) 까지 동일, Scaling 후 PCA

b. **기존 변수**

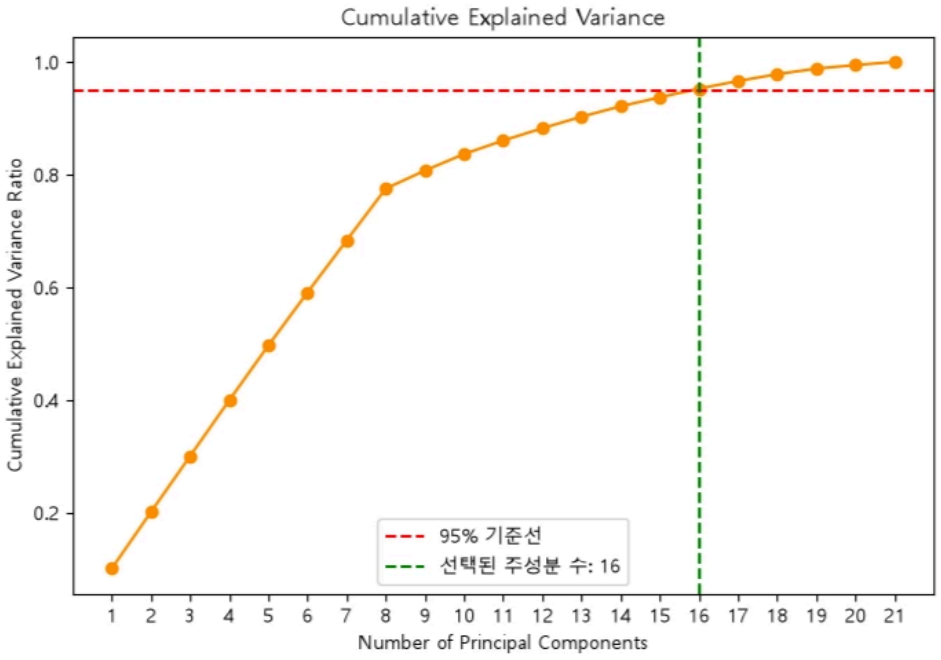
구분	개수	변수
수치형(연속형)	7개	Age, BMI, Tumor_Size_cm, Blood_Pressure, Cholesterol, Exercise_Days_Per_Week, Annual_Income_USD
순서형(Ordinal)	1개	Physical_Activity (Low=0, Moderate=1, High=2로 매핑)

구분	개수	변수
이진/명목형(One-Hot 더미)	13개	Gender, Family_History, Smoking, Alcohol_Consumption, Hormone_Therapy, Menopause_Status, Genetic_Mutation, Lymph_Node_Involvement, Mammogram_Result, Diabetes, Breastfeeding_History 등 각 범주 기준 (drop_first) 더미
합계	**21개**	

합계: 7 + 1 + 13 = 21개

c. **PCA**

90% 설명분산 도달 주성분 개수: 16



기존 변수 21개에 대해 크게 줄어들지 않음

▼ 모델링

a. **로지스틱 회귀 (Logistic Regression)**

정확도 (Accuracy) : 0.9026

	precision	recall	f1-score	support
0	0.923	0.960	0.941	1563.000
1	0.799	0.666	0.726	377.000
accuracy	0.903	0.903	0.903	0.903
macro avg	0.861	0.813	0.834	1940.000
weighted avg	0.899	0.903	0.899	1940.000

	Pred_0	Pred_1
Actual_0	1500	63
Actual_1	126	251

b. **의사결정나무 (Decision Tree)**

정확도 (Accuracy) : 0.8753

	precision	recall	f1-score	support
0	0.921	0.925	0.923	1563.000
1	0.682	0.671	0.676	377.000
accuracy	0.875	0.875	0.875	0.875
macro avg	0.801	0.798	0.800	1940.000
weighted avg	0.875	0.875	0.875	1940.000

	Pred_0	Pred_1
Actual_0	1445	118
Actual_1	124	253

	Feature	Importance
0	PC4	0.1656
1	PC16	0.1342
2	PC13	0.1144
3	PC14	0.1066
4	PC9	0.1017
5	PC7	0.0741
6	PC1	0.0459
7	PC6	0.0424
8	PC3	0.0410
9	PC5	0.0345
10	PC10	0.0280
11	PC11	0.0265
12	PC8	0.0240
13	PC2	0.0220
14	PC15	0.0202
15	PC12	0.0187

c. **그래디언트 부스팅 (Gradient Boosting)**

정확도 (Accuracy) : 0.9155

	Logistic	DecisionTree	GradientBoosting
0	0.830993	0.778352	0.841205
1	0.855311	0.796238	0.843396
2	0.836184	0.779037	0.840782
3	0.828726	0.756127	0.815802
4	0.841801	0.786113	0.836487

	Pred_0	Pred_1
Actual_0	1527	36
Actual_1	128	249

	Feature	Importance
0	PC4	0.2053
1	PC14	0.1690
2	PC9	0.1613
3	PC16	0.1606
4	PC13	0.1542
5	PC7	0.0533
6	PC6	0.0280
7	PC1	0.0233
8	PC11	0.0172
9	PC5	0.0068
10	PC15	0.0065
11	PC3	0.0051
12	PC8	0.0027
13	PC2	0.0027
14	PC12	0.0026
15	PC10	0.0016

▼ 모델 평가 및 비교

a. **교차 검증 (Cross-Validaion)**

	Logistic	DecisionTree	GradientBoosting
0	0.897341	0.975145	0.996905
1	0.890276	0.968017	0.991694
2	0.896922	0.977445	0.990643
3	0.880676	0.978389	0.996905
4	0.912129	0.980496	0.995878

	mean_macro_f1
Logistic	0.839
DecisionTree	0.779
GradientBoosting	0.836

b. **최종 성능 비교**

Model	Accuracy	Macro F1	Weighted F1
Logistic	0.903	0.834	0.899
DecisionTree	0.875	0.800	0.875
GradientBoosting	0.915	0.851	0.911

▼ 종합 결론

a. **모델 성능**

- Accuracy: Gradient Boosting(0.9155) > Logistic(0.9026) > Decision Tree(0.8753)
- Macro F1(test): Gradient Boosting(0.851) > Logistic(0.834) > Decision Tree(0.800)
- Weighted F1(test): Gradient Boosting(0.911) > Logistic(0.899) > Decision Tree(0.875)
- CV 기준(mean macro F1): Logistic(0.839) ≈ Gradient Boosting(0.836) > Decision Tree(0.779)

  → test에서는 Gradient Boosting이 근소하게 우세하지만, CV에서는 Logistic과 거의 차이가 없어 두 모델의 일반화 성능은 비슷한 수준

→ **Gradient Boosting이 test 성능(Accuracy·Macro F1·Weighted F1) 기준으로 가장 우수하나, CV 안정성 면에서는 Logistic Regression과 큰 차이가 없음**

b. **변수 중요도 (Feature Importance)**

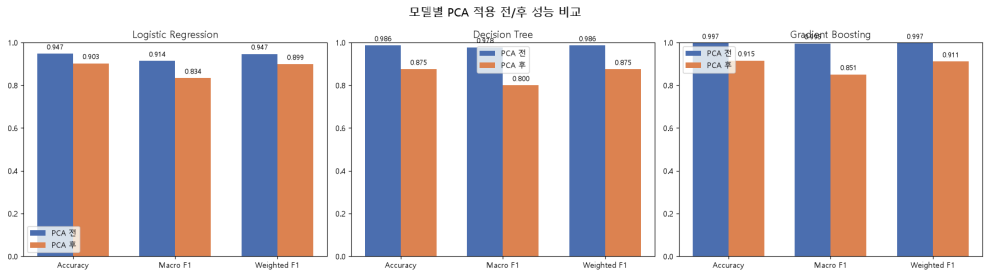
- 1위: **PC4** (DT 0.1656 / GB 0.2053) — 두 모델 모두 가장 중요한 주성분
- 2~5위: **PC16, PC13, PC14, PC9** — 순위는 모델별로 약간 다르지만 두 모델 모두 상위 5개 주성분으로 동일하게 선택
- 6위 이하(PC7, PC1, PC6, PC3, PC5 등)부터는 중요도가 급격히 낮아지며, 나머지 절반가량의 주성분은 기여도가 0에 가까움
  → Decision Tree와 Gradient Boosting 두 모델 모두 **동일한 상위 5개 주성분(PC4, PC9, PC13, PC14, PC16)**을 선택 — 우연이 아닌 데이터 구조적 특성으로 보임

c. **종합 결론**

- 최종 모델: **Gradient Boosting** (Accuracy·Macro F1·Weighted F1 종합 1위, CV 성능도 Logistic과 대등)
- 핵심 예측 요인: PC4를 중심으로 PC9·PC13·PC14·PC16 등 소수의 주성분이 예측력의 대부분을 차지
- **한계 (반드시 확인 필요)**: PCA로 생성된 주성분(PC4, PC9 등)은 원본 변수들의 선형결합이므로, 이름만으로는 어떤 원본 변수(예: Tumor_Size_cm, Age, Family_History 등)가 실제로 영향을 미치는지 알 수 없습니다. 임상적 해석을 위해서는 `pca.components_` (loading 값)를 확인하여 각 주성분에 크게 기여한 원본 변수를 함께 제시하는 것이 필요합니다. → 원본 변수 기준 모델(스케일링만 적용)과 PCA 기반 모델의 성능·해석력을 비교해 최종 모델 선택 시 참고하시길 권장드립니다.

---

8. 종합 결론



- **세 모델 모두 PCA 적용 후 성능 하락** (Accuracy·Macro F1·Weighted F1 전 지표에서 일관됨)
- 하락 폭:

  → **Decision Tree(-0.111~-0.178) > Gradient Boosting(-0.082~-0.144) > Logistic(-0.044~-0.080)** 순으로 손실 폭이 큼
- 모델 순위(PCA 전: Gradient Boosting > Decision Tree > Logistic → PCA 후: Gradient Boosting > Logistic > Decision Tree)는 **PCA 전후 뒤바뀜**
  → 원본 변수 기준에서는 Decision Tree가 2위였으나, PCA 적용 후에는 Logistic보다 낮은 3위로 하락 — **트리 기반 모델(Decision Tree)이 PCA로 인한 정보 손실에 더 취약함**

→ **PCA는 예측 성능 측면에서 이점이 없었음** — 원본 변수를 그대로 사용하는 것이 모든 모델에서 더 우수하며, 특히 Gradient Boosting은 PCA 전 Accuracy 0.997·Macro F1 0.995로 원본 변수 기준 최종 모델로 확정할 만한 수준