1. PCA

0. PCA의 목적

: 고차원의 데이터를 더 낮은 차원의 직교 좌표계로 투영, 데이터 구조를 보존하는 선형 차원 축소

1. PCA의 필요성

* 차원의 저주

: 차원 ↑ 시

데이터 희소
거리계산 어려움.
거리 알고리즘 성능 불안정
노이즈 ↑

→ 차원의 저주 해소 + 학습 가능한 형태로 데이터 축소

$$Z = W^T X$$

$$X = (x_1, x_2 \cdots x_n) \in \mathbb{R}^{d \times m}$$

2. PCA의 핵심 아이디어

1) 최근접 재구성

$$x_i \approx \hat{x}_i$$

저차원 → 고차원 재구성 시

샘플 간 거리가 작아야 함

2) 최대 가분성

저차원 투영 샘플의 분산이 가능한 커야함.

3. 데이터 중심화 (Zero - Centering)

PCA는 데이터의 '퍼짐 방향'을 찾는 알고리즘.

평균 미제거시 데이터의 평균이 주성분에 영향을 줌

$$\begin{cases} \sum_i x_i = 0 & \text{모든 데이터의 중심을 0으로} \\ x_i \leftarrow x_i - \frac{1}{m}\sum^{m} x_i & \text{평균 벡터를 빼기} \end{cases}$$

4. 저차원 좌표와 복원

직교 좌표계 $\{w_1, w_2 \cdots, w_d\}$

$\|w_i\|_2 = 1$ 단위벡터

$w_i^T w_j = 0$ 직교

투영행렬 $W = (w_1, w_2, \cdots w_d)$

샘플 x_i의 저차원 좌표 z_i

$$z_i = W^T x_i$$

좌표성분 $z_{ij} = w_j^T x_i$

: 샘플과 주성분 방향 w_j의 내적

복원 : 저차원 좌표 z_i를 원래의 고차원 공간 벡터로 변환

$$\hat{x}_i = \sum_{j=1}^{d'} z_{ij} w_j$$

$$\hat{x}_i = W z_i = W W^T x_i$$

5. PCA 적 최적화 : 최근접 최적화

$$\hat{x}_i = \sum_{j=1}^{d'} z_{ij} w_j$$

$$W z_i = z_{i1} w_1 + z_{i2} w_2 + \cdots + z_{id} \cdot w_d$$

복원오차 : $\sum \| W z_i - x_i \|_2^2$

$$= \sum_{i=1}^{m} z_i^T z_i - 2 \sum_{i=1}^{m} z_i^T W^T x_i + \text{const.}$$

$$(z_i = W^T x_i)$$

최종 목적식 : $\alpha - tr\left(W^T \left(\sum_{i=1}^{m} x_i x_i^T\right) W\right)$

$$(X = (x_1, x_2 \cdots, x_n))$$

$$\left(\sum x_i x_i^T = X X^T\right)$$

최적화 목표 : $\min_W -tr(W^T X X^T W) \quad s.t \ W^T W = I$

6. PCA 최적화와 최대 분산

★ 최대 분산 관점

: 좌표계 투영 후 분산의 최대화 목적

투영 후 공분산 행렬: $\sum W^T x_i \; x_i^T W$

전체 분산 : $tr(W^T X \; X^T W)$ (대각합)

∴ 최대 분산관점 최적화 : $\max_W tr(W^T X \; X^T W)$ s.t. $W^T W = I$

↕

최근접 재구성 목적식 $\min_W - tr(W^T X \; X^T W)$

∴ PCA 최근접 재구성과 최대분산은 결국 동일한 문제해결법

복원오차 최소화 (목적1) = 투영분산 최대화 (목적2)

7. 고유값 문제

$$X X^T w_i = \lambda_i w_i$$

- w_i : 고유벡터, 주성분 방향
- λ_i : 고유값

고유값 ↑ → 중요한 주성분

고유값 내림차순 정렬 $\lambda_1 \geq \lambda_2 \geq \lambda_3 \cdots \geq \lambda_d$

고유벡터 선택 (가장 큰 d'개 선택) $W^* = (w_1, w_2, w_3 \cdots w_{d'})$

W^* : PCA의 최종 투영행렬

8. PCA 알고리즘 원리

① 입력: $D = \{x_1, x_2, \cdots x_m\}$

② 저차원 공간 수: d'

③ 샘플 중심화: $x_i \leftarrow x_i - \frac{1}{m}\sum_{i=1}^{m} x_i$

④ 공분산 행렬 계산: XX^T

⑤ ④에 대한 고유값 분해: $XX^T w_i = \lambda_i w_i$

⑥ 가장 큰 d'개의 고유값에 대응하는 고유벡터 선택

$w_1 \sim w_{d'}$

⑦ 투영행렬 만들기

$W^* = (w_1, w_2, \cdots, w_{d'})$: 최종 결과

사용할 입력 샘플 x에 대해

샘플 중심화 이후

$z = W^{*T} x$ 로 저차원 좌표 출력

9. 일반적인 선형 PCA의 한계

:

선형 PCA: 선형 부분공간에 데이터 투영 (직선, 평면)

⇒ 비선형 구조의 데이터에서 부적합

9.1 커널 PCA

$x \rightarrow \phi(x)$

고차원 특징 공간에서 PCA 수행

커널함수 $K(x_i, x_j) = \phi(x_i)^T \phi(x_j)$

고유값 문제 $K\alpha^j = \lambda_i \alpha^j$ ($\because XX^T \rightarrow K\alpha = \lambda\alpha$)

새로운 x의 j번째 투영좌표

$$z_j = w_j^T \phi(x) = \sum_{i=1}^{m} a_i^j k(x_i, x)$$