4주차 _ PCA 논문

상태	완료
날짜	2026년 8월 7일
유형	논문

주성분 분석 기반 회귀모형을 활용한 북한 홍수 및 태풍 피해 추정 연구

▼ 논문 요약

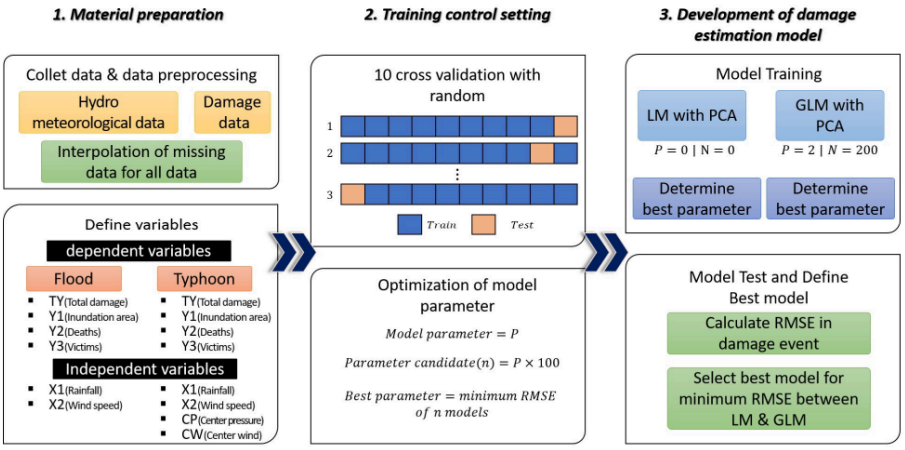
연구 배경 및 목적

- 물리적인 모형과 같은 정량적 분석
  - 국소적 지역에만 국한, 전반적 피해 파악에 한계
- 머신러닝 및 딥러닝 기법
  - 데이터가 제한적인 환경에서 과적합 문제 발생
  - 학습된 패턴이 일반화 되지 않아 새로운 데이터에 대한 예측력 저하
- 정성적 평가
  - 재난 발생 시 피해규모 추정 불가능
- 북한에 적용된 홍수 피해 추정 사례 전무

데이터

- **북한**
  - 전체 80% 이상이 산지, 깊고 좁은 계곡 & 복잡한 고도차 형성
    → 강수가 집중될 경우 홍수 피해 증가
  - 여름인 6~9월 사이 강수량 집중, 장마 & 태풍의 영향
    → 하천 범람 및 침수 피해 즈악
- **피해 자료(dependent)**: CRED(EM-DAT)의 1993~2018년 북한 홍수·태풍 피해 통계 (총 피해금액, 침수면적, 인명피해, 이재민 피해)
- **기상 자료(independent)**: 북한 27개 기상관측소의 강수량·풍속 자료 (한국 기상청 제공), 태풍의 경우 중심기압(CP)·중심최대풍속(CW) 추가
- 독립변수 총 54개(27개 지점 × 강우·풍속) → 다중공선성 문제 → PCA로 차원 축소(누적 설명분산 90% 이상, 상위 10개 주성분 선택)

방법론



1단계: 전처리 (Data Preprocessing)

- **문제점**: 북한은 정보 접근성이 낮고 공식 통계가 제한적이어서, 수집된 피해 자료(CRED/EM-DAT)에 **공간적 위치 정보의 부재** 및 **일부 항목의 누락**과 같은 한계가 존재
- **대응 방안**:
  - 특정 지역 단위가 아닌 **북한 전역을 단일 분석 단위**로 간주하여 피해를 정의
  - 누락된 자료는 **다른 피해 지표 간의 상관관계**를 활용하여 보정
  - 이벤트별 변동성이 큰 피해 자료의 특성을 고려해 **로그 변환** 적용
- 이 단계를 통해 종속변수(TY, 침수면적, 사망자, 이재민)와 독립변수(강우량, 풍속, 태풍의 경우 CP·CW)를 정의

2단계: 주성분 분석 (PCA)

- **문제점**: 27개 기상관측소 × 2개 변수 = 총 54개의 독립변수를 사용함에 따라 **다중공선성 문제** 발생 가능성이 높음
- **대응 방안**: 변수 간 상관성을 줄이고 모형의 안정성을 확보하기 위해 PCA를 적용해 차원 축소 수행
  - 선정 기준: ① 고유값 1 이상, ② 누적 설명분산 90% 이상을 동시 충족
  - 결과: 54개 원변수 → **10개 주성분**으로 축소, 이를 최종 독립변수로 활용

3단계: 교차검증 및 매개변수 최적화

- **문제점**: 북한의 피해 데이터 수 자체가 충분하지 않아, 학습·검증 데이터를 고정할 경우 과적합 위험이 큼
- **대응 방안**:
  - **10-Fold 교차검증**을 채택하여 전체 자료를 학습과 평가에 최대한 반복적으로 활용
  - 각 Fold는 매 반복마다 랜덤하게 구성되도록 설정해 특정 데이터에 대한 과도한 적합 방지
  - GLM with PCA의 경우 2개의 주요 매개변수에 대해 후보군을 무작위 생성 후 최적 조합을 탐색하는 방식으로 최적화 수행 (LM with PCA는 별도 매개변수 불요)
- 이 단계를 통해 LM with PCA와 GLM with PCA의 예측 성능(NRMSE, R^2)을 비교·평가하여 **LM with PCA를 최종 모형으로 선정**

주요 모델

1. LM with PCA (주성분 회귀모형)

정의

- 다중회귀분석(Multiple Linear Regression)에 PCA로 축소된 주성분을 독립변수로 사용하는 모형
- 회귀식: $Y = \beta_0 + \beta_1 x_1 + \ldots + \beta_i x_i + \varepsilon_i$
  - $\beta_0, \beta_1, \ldots, \beta_i$: 회귀계수(standardized beta coefficient)

- ε_i: 종속변수 Y_i 측정 시 발생하는 오차

특징

- 종속변수가 **정규분포**를 따른다는 가정 하에 연속형 반응변수를 설명
- 하나의 종속변수와 여러 독립변수(10개 주성분) 간 관계를 동시에 고려해 설명력과 예측 정확도 향상
- **별도의 하이퍼파라미터(매개변수) 최적화가 필요 없음** → 상대적으로 단순하고 안정적인 학습 구조

2. GLM with PCA (주성분 일반화 선형모형)

정의

- 일반화 선형모형(Generalized Linear Model)에 PCA로 축소된 주성분을 독립변수로 사용
- 연결식: $g(u_i) = \eta_i = \beta_0 + \beta_1 x_1 + \ldots + \beta_p x_p$
  - $u_i = E(Y_i)$: 반응변수 Y의 기댓값
  - η_i: 선형 예측자(linear predictor)
  - $g(\cdot)$: 연결함수(link function)

특징

- Nelder and Wedderburn(1972)이 제안, 반응변수가 **정규분포에 국한되지 않고** 이항분포·포아송분포 등 지수족(exponential family) 분포를 따를 수 있도록 일반화된 모형
- 일반화 방식 두 가지:
  1. 오차항을 정규분포뿐 아니라 다양한 지수족 분포로 정의 가능
  2. 반응변수의 기댓값과 설명변수의 선형결합을 연결함수를 통해 연결
- **2개의 주요 매개변수 최적화가 필요** → 후보군을 무작위 생성 후 최적 조합을 탐색하는 방식으로 튜닝 (Figs. 10, 11 참고)

3. 두 모형의 비교 및 최종 선정 결과

구분	LM with PCA	GLM with PCA
분포 가정	정규분포 한정	지수족 분포로 확장 가능
매개변수 최적화	불필요	필요 (2개 파라미터)
홍수 평균 NRMSE / R^2	0.1901 / 42%	0.2129 / 16%
태풍 평균 NRMSE / R^2	0.3077 / 85%	0.3132 / 11.24%
성능	**우수**	일부 종속변수에서 R^2=0 발생 (설명력 없음)

성능 평가 지표: R-squared와 NRMSE

논문에서는 예측값과 관측값 간의 관계를 평가하기 위해 **R-squared(결정계수)**와 **NRMSE(정규화된 평균제곱근오차)** 두 가지 지표를 사용하였다.

1. R-squared (결정계수, R^2)

정의

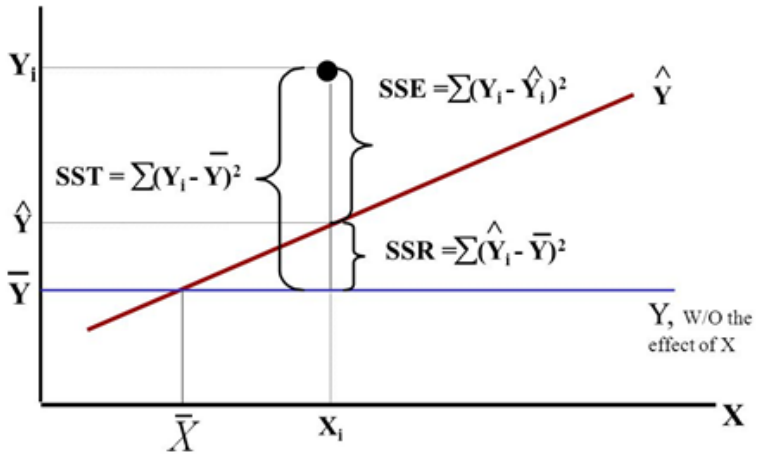
- 두 변수 간 선형관계에서 독립변수가 종속변수를 얼마나 설명하는지를 나타내는 지표

수식

$$R^2 = 1 - \frac{\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}{\sum_{i=1}^{n}(y_i - \bar{y})^2}$$

- y_i: i번째 관측데이터
- $\hat{y}_i$: i번째 모의(예측)데이터

- ȳ: 관측데이터의 평균



해석

- **1에 가까울수록** 모형의 성능이 우수함 (예측값과 관측값의 추세 유사성이 높음)
- 즉, 모형이 종속변수의 분산을 얼마나 잘 설명하는지를 나타냄
- **R^2=0**
  - 모형이 목표 변수의 분산을 전혀 설명하지 못함
  - 입력-출력 간 비선형적 관계를 학습하지 못한 채 모든 예측값을 평균값으로만 예측했다는 의미로 해석됨 (GLM with PCA의 일부 종속변수에서 발생)

2. NRMSE (Normalized Root Mean Squared Error)

정의

- RMSE(평균제곱근오차)를 정규화한 지표로, 예측값과 관측값 간의 오차 크기를 정량적으로 평가

수식

$$RMSE = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y})^2}$$

$$NRMSE = \frac{RMSE}{Max(y_i) - Min(y_i)}$$

해석

- **0에 가까울수록** 계산된 값이 참값과 유사함 (오차가 작음)
- RMSE를 관측값의 범위(최댓값−최솟값)로 나누어 정규화했기 때문에, 단위나 척도가 다른 변수들 간에도 오차 크기를 **상대적으로 비교** 가능

3. 두 지표를 함께 사용하는 이유

지표	평가 관점	우수한 모형의 조건
R-squared	예측값과 관측값 간의 **추세 유사성**(설명력)	1에 가까울수록 우수
NRMSE	예측값과 관측값 간의 **오차 크기**(정확도)	0에 가까울수록 우수

- R^2만으로는 추세는 잘 맞지만 절대적 오차가 큰 경우를 놓칠 수 있고, NRMSE만으로는 오차는 작지만 변수 간 관계를 제대로 설명하지 못하는 경우(예: 평균값으로만 예측)를 놓칠 수 있음

- → 두 지표를 함께 사용함으로써 **정확도(오차 크기)**와 **설명력(추세 반영도)**을 동시에 검증

주요 결과

Table 2. Result of Performance Evaluation for Flood

Type	NRMSE		R-squared	
	LM with PCA	GLM with PCA	LM with PCA	GLM with PCA
TY	0.1674	0.2017	98.45%	18.49%
Y1	0.2107	0.2148	2.19%	6.89%
Y2	0.1982	0.2246	33.65%	0.00%
Y3	0.1844	0.2107	33.60%	42.56%

Table 3. Result of Performance Evaluation for Typhoon

Type	NRMSE		R-squared	
	LM with PCA	GLM with PCA	LM with PCA	GLM with PCA
TY	0.7877	0.3158	99.96%	0.00%
Y1	0.0859	0.2980	98.90%	0.00%
Y2	0.2578	0.3406	45.66%	0.00%
Y3	0.0997	0.2985	96.77%	44.96%

- 전반적으로 **LM with PCA가 GLM with PCA보다 우수** → 최종 모형으로 선정
- GLM with PCA는 일부 종속변수에서 R^2=0으로 나타나, 비선형적 관계 학습에 한계
- **실증 검증**: 2020년 8월 실제 홍수 피해(사망 22명, 이재민 85,000명)에 모형 적용 → 예측값(**사망 31명, 이재민 108,747명**)이 유사한 수준으로 추정됨
- 선행연구(한강 권역 모형, NRMSE 0.1061~0.1220)와 비교 시 다소 낮은 정확도이나, 데이터 수 차이를 고려하면 격차가 크지 않음

결론 및 의의

- 정보가 제한된 북한 환경에서도 홍수·태풍 피해를 정량적으로 추정할 수 있는 방법론 제시
- 피해금액뿐 아니라 침수면적·사망자·이재민 수까지 포괄적으로 추정했다는 점에서 의의
- 향후 데이터 확보 시 기계학습 기반 비선형 기법 적용으로 정밀도 향상 가능, 재난 대응 체계가 미비한 타 국가에도 적용 가능한 사례로 확장 기대

▼ PCA 적용

1. PCA 도입 배경

- 독립변수: 북한 27개 기상관측소 × 2개 변수(강우량, 풍속) = **총 54개 변수**
- 변수 수가 많아 **다중공선성(multicollinearity)** 문제 발생 가능성 높음
  - 다중공선성(multicoliinearity)
    다중회귀분석에서 설명 변수 간에 상관관계(선형관계)가 존재하는 경우
- 변수 간 상관성을 줄이고 모형의 안정성을 확보하기 위해 PCA로 차원 축소 수행

2. PCA 이론적 절차 (2.1절)

- 독립변수 집합 $X = (X_1, X_2, \ldots, X_m)$의 공분산행렬 Σ 계산
- $\Sigma - \lambda I$의 행렬식이 0이 되는 고유값 $\lambda_1, \lambda_2, \ldots, \lambda_m$ (내림차순) 도출
- 각 고유값에 대응하는 고유벡터 $e_1, e_2, \ldots, e_m$ 산출 → 고유벡터 집합 E
- 주성분 $Y = EX$로 구성되며, 도출된 주성분들은 서로 독립적

3. 주성분 개수 선정 기준

다음 두 기준을 **동시에** 만족하는 지점까지 주성분 선택:

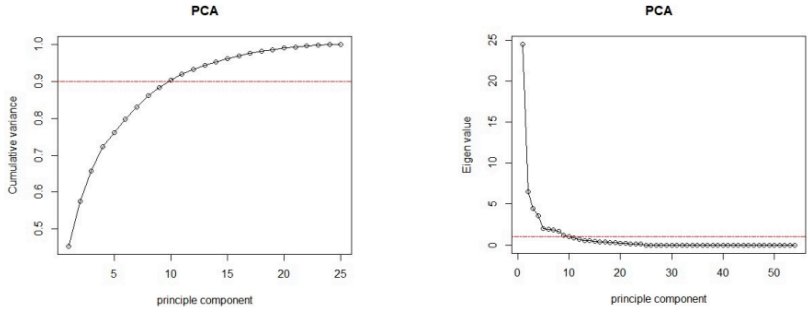
- ① 고유값(eigenvalue)이 **1 이상**인 주성분

  ▼ 고유값이 1 이상인 주성분

  - 어떤 주성분의 고유값이 **1보다 작다**는 것은, 그 주성분이 설명하는 분산의 크기가 **원래 변수 1개가 가진 정보량보다도 적다**는 의미 = 그 주성분은 원래 변수 하나만 사용하는 것보다도 정보 손실이 큼
  - 반대로 고유값이 **1 이상**이라는 것은, 해당 주성분이 원래 변수 1개 이상의 정보량을 응축하여 담고 있다는 의미
  - 따라서 **"주성분이 최소한 원래 변수 1개만큼의 설명력은 가져야 한다"**는 기준으로, 고유값이 1 이상인 주성분만 선택하는 것이 합리적

- ② 누적 설명분산(cumulative explained variance)이 **90% 이상**

4. 실제 적용 결과



(a) Cumulative explained variance by principal components (b) Eigenvalues of principal components

Fig. 9. The Selection of the Number of Principal Component

- 54개 원변수 → PCA 적용 결과 **상위 10개 주성분**이 두 기준을 모두 만족
- 이 10개 주성분을 최종 독립변수로 사용해 이후 회귀모형(LM, GLM) 학습에 투입
- 즉, 54차원 → 10차원으로 차원 축소하여 모형 안정성 확보 및 과적합 방지에 기여

5. PCA 이후 모형링 흐름

- PCA로 축소된 10개 주성분을 독립변수로 하여 두 가지 회귀모형 구축:
  - **LM with PCA** (주성분 회귀모형, 별도 하이퍼파라미터 불필요)
  - **GLM with PCA** (주성분 일반화 선형모형, 2개 매개변수 최적화 필요)
- 10-Fold 교차검증으로 두 모형의 예측 성능(NRMSE, R^2) 비교 → **LM with PCA가 최종 채택**

6. PCA의 역할 요약

목적	PCA의 기여
다중공선성 해소	54개 상관 변수를 독립적인 주성분으로 변환
차원 축소	54개 → 10개로 축소, 모형 단순화
과적합 방지	제한된 표본(1993~2018년 자료) 대비 변수 수 과다 문제 완화
정보 보존	원 변수 총 정보량의 90% 이상 유지

GLM(일반화 선형모형)과 매개변수 최적화

1. GLM의 기본 개념 (재정리)

정의

- 일반화 선형모형(Generalized Linear Model)은 반응변수가 반드시 정규분포를 따를 필요 없이, **지수족(exponential family)**에 속하는 다양한 분포(이항분포, 푸아송분포 등)를 따를 수 있도록 확장한 모형
- Nelder and Wedderburn(1972)이 처음 제안

일반화 방식

- 회귀식: $g(u_i) = \eta_i = \beta_0 + \beta_1 x_1 + \ldots + \beta_p x_p$
- 두 가지 확장 요소:
  1. **오차항의 확장**: 정규분포뿐 아니라 이항분포, 푸아송분포 등 지수족 분포로 정의 가능
  2. **연결함수(link function)의 도입**: 반응변수의 기댓값과 설명변수의 선형결합(linear predictor)을 연결함수를 통해 연결

2. GLM에서 최적화가 필요한 매개변수

- LM with PCA와 달리, GLM with PCA는 **2개의 주요 매개변수(하이퍼파라미터)**를 최적화해야 함
- 이는 GLM이 오차 분포(family)와 연결함수(link function)를 데이터 특성에 맞게 선택·조정해야 하는 모형이기 때문
- 논문 Fig. 8에서 모형별 파라미터 설정을 다음과 같이 표기:
  - LM with PCA: P = 0 (매개변수 불필요)
  - GLM with PCA: P = 2, N = 200 (2개 매개변수, 200개 후보 조합)

3. 매개변수 최적화 절차

과정 (Fig. 8 - Training control setting)

1. **후보군 생성**: 모형 매개변수 P에 대해 후보 조합을 무작위로 생성 (후보 개수 n = P × 100 → GLM의 경우 200개 후보)
2. **10-Fold 교차검증 적용**: 전체 데이터를 10개 Fold로 나누어 각 반복(iteration)마다 학습/검증 데이터를 랜덤하게 구성
3. **성능 평가**: 각 후보 매개변수 조합에 대해 RMSE를 계산 (Figs. 10, 11에서 iteration별 RMSE 변화를 시각화)
4. **최적 매개변수 선정**: n개의 후보 모형 중 **RMSE가 최소가 되는 조합**을 최적 매개변수로 채택

시각화 결과 (Figs. 10, 11)

- 홍수(TY, Y1, Y2, Y3)와 태풍(TY, Y1, Y2, Y3) 각 종속변수별로 매개변수 후보(반복 iteration)에 따른 RMSE 변동을 그래프로 표현
- 빨간 점으로 최소 RMSE를 기록한 지점(최적 매개변수)을 표시
- 예: 홍수 TY의 경우 iteration 약 70번째 부근에서 RMSE 최솟값(≈1.5) 도달 → 해당 조합을 최적 매개변수로 선정

4. 최적화가 GLM에서만 필요한 이유

모형	매개변수 필요 여부	이유
LM with PCA	불필요	정규분포 가정 하의 단순 선형회귀 구조 → 별도의 분포/연결함수 설정 없음
GLM with PCA	필요 (2개)	오차 분포(지수족 중 선택) 및 연결함수 설정에 따라 성능이 달라지므로, 데이터에 가장 적합한 조합을 탐색해야 함

5. 최적화 이후 결과와 한계

- 매개변수 최적화를 거쳤음에도 불구하고, GLM with PCA는 최종적으로 **LM with PCA보다 낮은 예측 성능**을 보임
  - 홍수: 평균 NRMSE 0.2129, R^2 16% (LM: 0.1901, 42%)
  - 태풍: 평균 NRMSE 0.3132, R^2 11.24% (LM: 0.3077, 85%)
- 일부 종속변수에서는 R^2=0으로 나타나, 최적화를 거쳐도 **변수 간 복잡하고 비선형적인 관계**를 안정적으로 학습하지 못하는 한계를 보임
- → 이는 GLM이 이론적으로 더 유연한 모형임에도, 제한된 표본 크기와 복잡한 데이터 구조 하에서는 오히려 과적합이나 불안정한 추정으로 이어질 수 있음을 시사