SECOM 반도체 공정 데이터 기반 SVM 불량 분류 프로젝트

Linear SVM - RBF SVM - 하이퍼파라미터 튜닝 - PCA - 지도형 Feature Selection 비교

핵심 결론: SelectKBest(35) + RBF-SVM이 최종 후보로 가장 좋은 균형을 보였다. 입력 변수를 450개에서 35개로 약 92.2% 줄이면서 Balanced Accuracy 0.6408, Fail Recall 0.4762, ROC-AUC 0.7754를 기록했다.

항목	결과
데이터	SECOM 반도체 제조 공정 데이터
표본	1,567개 (Pass 1,463 / Fail 104)
전처리	결측률 50% 이상 제거, 상수 변수 제거, 중앙값 대체, 표준화
최종 입력	590 -> 450 -> SelectKBest 35
최종 모델	RBF-SVM, C=2.0, gamma=0.004, class_weight=balanced
최종 Test	Accuracy 0.7834 / Balanced Acc. 0.6408 / Fail Recall 0.4762 / ROC-AUC 0.7754

작성일: 2026. 09. 02
실행 환경: VS Code · Jupyter Notebook · Python 3.11.15 · scikit-learn

INTRO

반도체 공정과 SECOM 데이터 이해

SVM 결과를 보기 전에, 이 데이터가 어디에서 만들어지는지 먼저 이해한다. 반도체 제조는 하나의 생산 단위가 여러 공정 장비를 거치는 동안 많은 신호를 측정하고, 라인 테스트에서 Pass/Fail을 확인하는 구조로 볼 수 있다.

1. 반도체 제조를 아주 단순하게 보면

① 생산 단위
실리콘 웨이퍼 등
반도체를 만드는 대상

→

② 반복 공정
증착·식각·세정 등
여러 장비를 거쳐 가공

→

③ 공정 측정
센서·측정점에서
다양한 신호/변수 수집

→

④ 라인 테스트
측정 결과를 바탕으로
Pass(-1) / Fail(+1)

중요: 위 공정명은 반도체 제조를 이해하기 위한 대표 예시다.

SECOM의 익명 변수 각각이 어떤 장비·센서·공정에 해당하는지는 공개되어 있지 않다.

2. 우리가 사용한 SECOM 데이터는 무엇인가?

1,567
생산 샘플

590
실제 분석에 사용한 공정 측정 변수

104
Fail 샘플 (6.64%)

UCI 설명에 따르면 현대 반도체 제조공정은 센서 및 공정 측정점에서 수집되는 많은 신호/변수를 지속적으로 감시한다. 하지만 모든 신호가 수율 판단에 똑같이 유용한 것은 아니며, 유용한 정보와 불필요한 정보·노이즈가 함께 존재한다.

SECOM의 각 예제는 하나의 생산 단위를 나타내고 라벨은 라인 테스트의 Pass/Fail 결과다. 따라서 이번 프로젝트는 여러 공정 측정값 중 어떤 정보가 Fail 구분에 도움이 되는지 SVM으로 학습하는 문제다.

3. 그래서 이번 SVM 분석에서 무엇을 보았나?

① 공정 측정값으로 Pass와 Fail을 구분할 수 있는가?

② Fail이 6.64%뿐인 불균형 데이터에서 Accuracy만 믿어도 되는가?

③ 590개 중 불필요한 변수를 줄이면 Fail 탐지력이 좋아지는가?

발표 연결 문장

"즉, 반도체를 만드는 과정에서 쌓이는 많은 측정값을 보고 불량 가능성을 구분하는 것이 이번 문제입니다. 이제 이 데이터를 Linear SVM과 RBF-SVM으로 분류하고, 불량을 얼마나 놓치지 않는지 비교하겠습니다."

근거: UCI Machine Learning Repository, SECOM (McCann & Johnston, 2008), DOI 10.24432/C54305.
UCI는 공정 신호/변수가 sensors and/or process measurement points에서 수집되며, 라벨은 in-house line test의 Pass/Fail이라고 설명한다.

01

문제 정의와 데이터 이해

목표는 반도체 공정 센서 데이터를 이용해 Pass(-1)와 Fail(+1)을 분류하고, 특히 희귀한 Fail을 얼마나 안정적으로 탐지할 수 있는지 확인하는 것이다. SECOM은 실제 제조공정 모니터링 신호를 담고 있으며, UCI 공식 설명에서도 많은 신호 중 실제 수율과 관련된 핵심 변수를 찾는 Feature Selection 문제를 주요 활용 방향으로 제시한다.

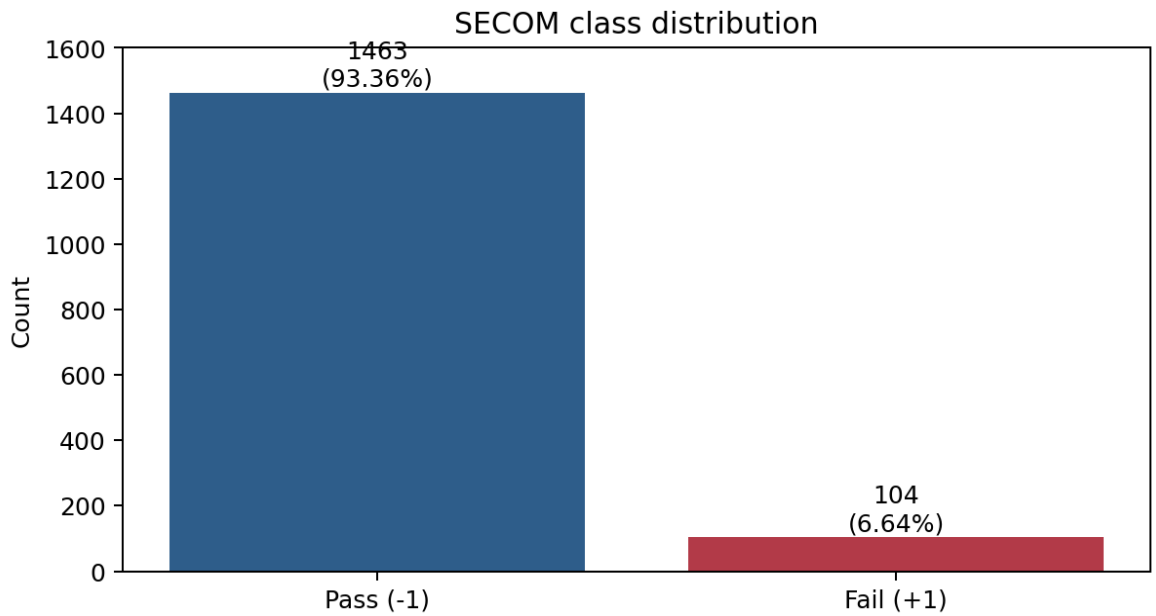


그림 1. 전체 클래스 분포 - Fail은 104개로 전체의 6.64%에 불과하다.

클래스 불균형 때문에 Accuracy만 사용하면 모델 성능을 과대평가할 수 있다. 따라서 본 실험에서는 Balanced Accuracy, Fail Recall, Fail F1, ROC-AUC, Confusion Matrix를 함께 사용했다.

데이터 분할

구분	전체	Pass	Fail
전체	1,567	1,463	104
Train	1,253	1,170	83
Test	314	293	21

Train/Test 분할은 test_size=0.2, random_state=42, stratify=y를 사용해 원래 클래스 비율을 유지했다.

02

전처리와 평가 설계

단계	처리	결과
1	Train 기준 결측률 50% 이상 변수 제거	590 -> 566 (24개 제거)
2	Train에서 상수 변수 제거	566 -> 450 (116개 제거)
3	Median Imputation	Train/Test 결측값 0
4	StandardScaler	Train 평균≈0, 표준편차=1

데이터 누수 방지

결측률 계산, 상수 변수 탐색, 중앙값 계산, 표준화 파라미터 등은 모두 Train 데이터에서만 학습하고 Test에는 transform만 적용했다. 이후 PCA 및 SelectKBest를 교차검증할 때는 Pipeline 내부에 전처리를 포함시켜 각 fold마다 새로 학습되도록 구성했다.

평가 지표

Balanced Accuracy: Pass와 Fail의 재현율을 균등하게 반영한다.
Fail Recall: 실제 Fail 중 모델이 Fail로 탐지한 비율이다.
Fail F1: Fail Precision과 Recall의 조화평균이다.
ROC-AUC: 임계값과 무관하게 decision score가 Pass/Fail을 얼마나 잘 순위화하는지 본다.

본 프로젝트에서 가장 중요한 질문은 “전체 Accuracy가 높은가?”가 아니라 “실제 Fail을 놓치지 않으면서 정상 샘플 오탐을 어느 정도로 제어하는가?”이다.

03

Linear / RBF-SVM과 Accuracy의 함정

모델	Accuracy	Balanced Acc.	Fail Recall	Fail F1	ROC-AUC
Linear SVM	0.8567	0.5475	0.1905	0.1509	0.6096
기본 RBF-SVM	0.9268	0.5187	0.0476	0.0800	0.6329
Tuned RBF-SVM	0.8089	0.6324	0.4286	0.2308	0.6930

기본 RBF-SVM은 Accuracy 0.9268로 가장 높았지만 Fail 21개 중 단 1개만 탐지했다. 대부분을 Pass로 예측한 결과 Accuracy가 높아진 것이다.

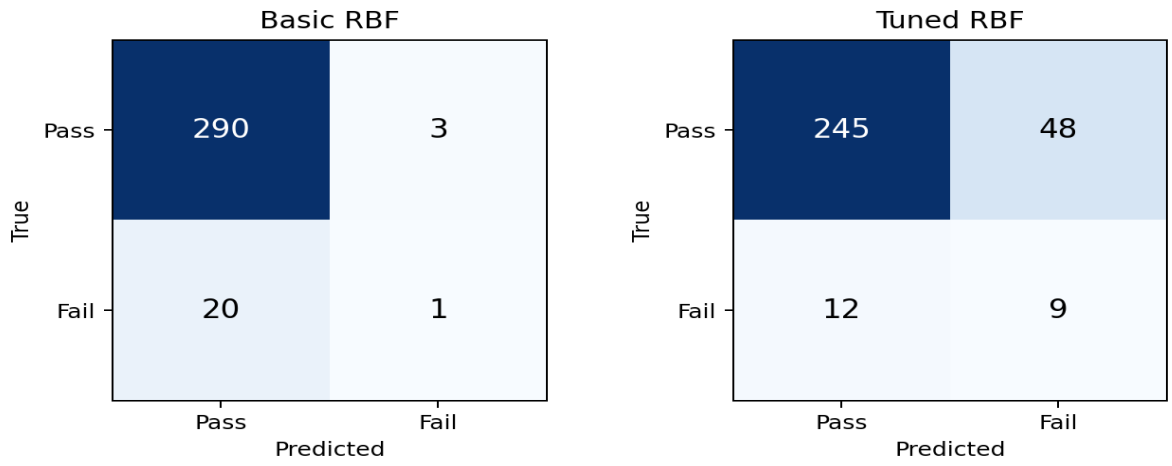


그림 2. 기본 RBF(좌)와 Tuned RBF(우) Confusion Matrix

Balanced Accuracy를 기준으로 5-fold Grid Search를 수행한 결과 C=0.1, gamma=0.002가 선택되었고, CV Balanced Accuracy는 0.6061이었다. Test에서는 Fail Recall이 0.0476에서 0.4286으로 크게 개선되었다.

핵심 해석: 불균형 데이터에서는 높은 Accuracy가 높은 불량 탐지 성능을 의미하지 않는다. 기본 RBF의 92.68% Accuracy보다 Tuned RBF의 42.86% Fail Recall이 실제 목표에 더 중요했다.

04

Threshold / class weight 추가 실험

Decision Threshold 조정

Train OOF decision score에서 Balanced Accuracy가 최대가 되는 threshold를 탐색했으며 최적값은 약 -0.4359였다. Test에 적용하면 Fail Recall은 0.7619로 상승해 Fail 21개 중 16개를 잡았지만, 정상 293개 중 142개를 Fail로 오탐했다.

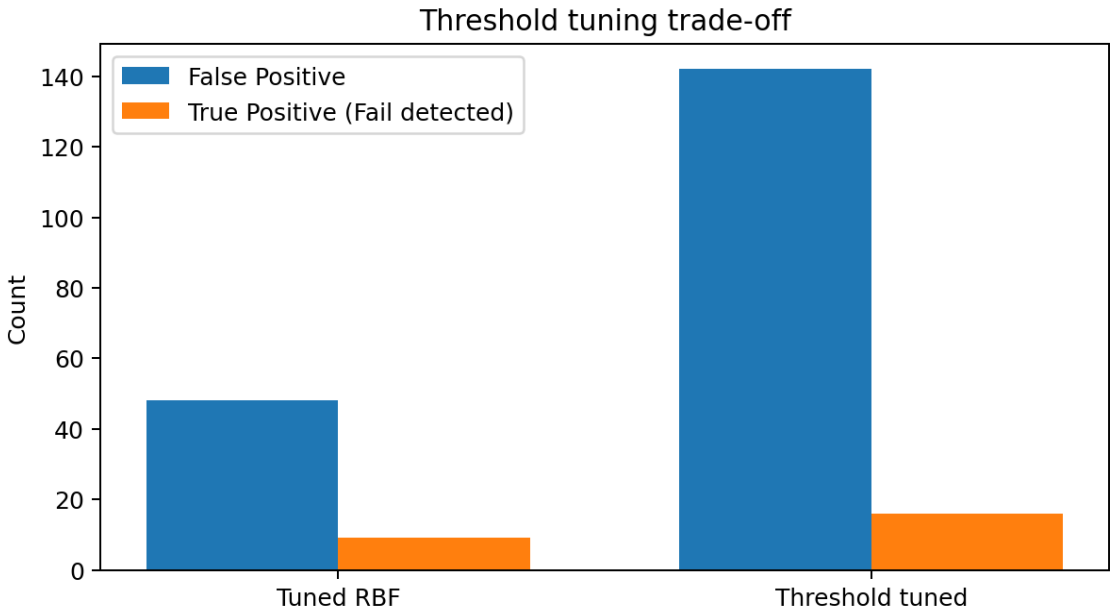


그림 3. Threshold를 낮추면 Fail 탐지는 늘지만 False Positive가 급증했다.

모델	Accuracy	Balanced Acc.	Fail Recall	Fail F1
Tuned RBF	0.8089	0.6324	0.4286	0.2308
Threshold tuned	0.5318	0.6386	0.7619	0.1788

Class weight 동시 튜닝

C, gamma, class_weight를 동시에 탐색한 결과 C=0.05, gamma=0.003, class_weight={-1:1, +1:15}가 선택되었지만 CV Balanced Accuracy는 0.6087로 기존 0.6061 대비 개선폭이 매우 작았다.

결론: Threshold는 Recall을 크게 높일 수 있지만 오탐 비용이 너무 컸고, class weight 추가 탐색은 개선폭이 미미했다. 이후 성능 개선의 초점을 "결정경계"보다 "입력 변수 선택"으로 전환했다.

05

PCA와 지도형 Feature Selection 비교

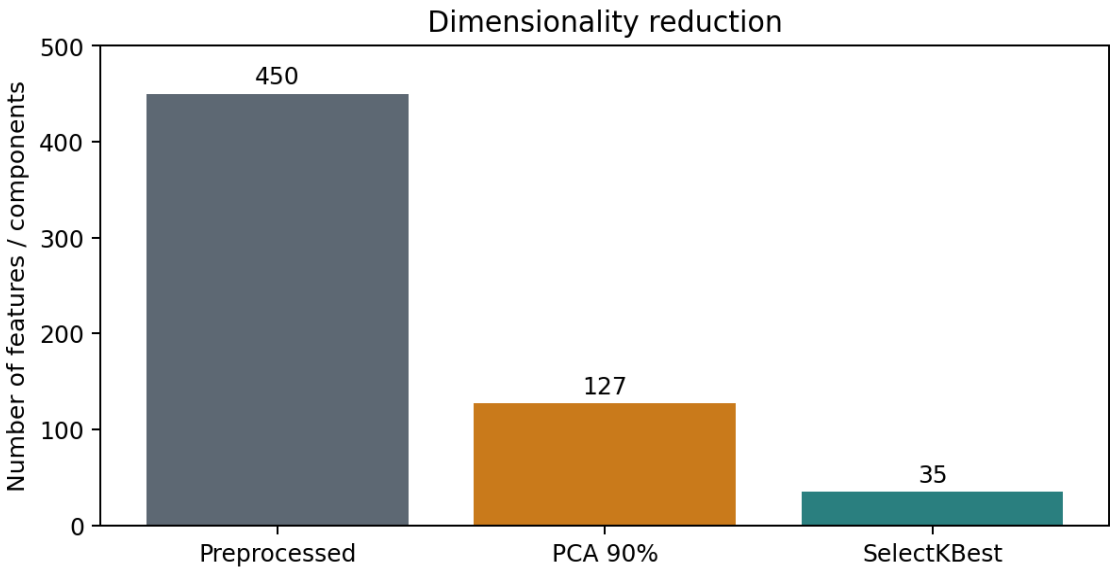


그림 4. 전처리 후 450개 변수에서 PCA는 127개, SelectKBest는 35개로 축소.

PCA 90%는 450개 변수를 127개 주성분으로 줄이고 누적 설명분산 약 90.12%를 유지했다. 그러나 PCA는 라벨을 사용하지 않고 분산이 큰 방향을 보존하기 때문에 Fail 분류에 중요한 저분산 정보가 손실될 수 있다.

방법	차원	Accuracy	Balanced Acc.	Fail Recall	ROC-AUC
Tuned RBF	450	0.8089	0.6324	0.4286	0.6930
PCA90 + RBF	127	0.7866	0.5983	0.3810	0.6771
SelectKBest + RBF	35	0.7834	0.6408	0.4762	0.7754

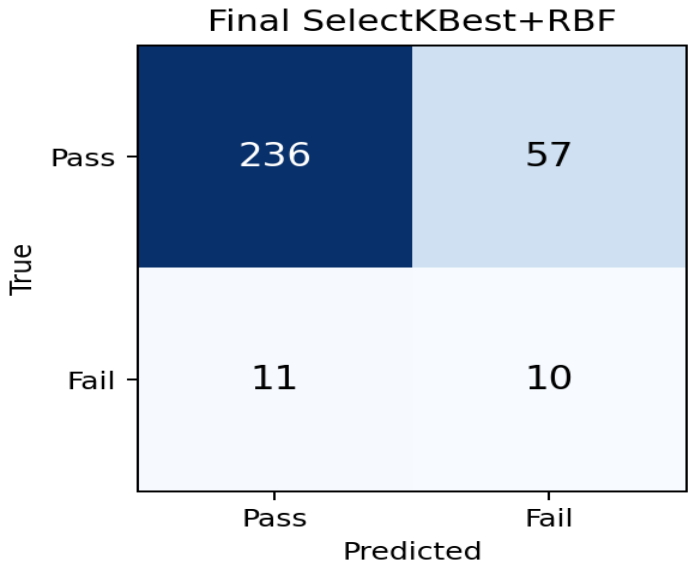
SelectKBest(f_classif)는 Pass/Fail 라벨을 이용해 두 클래스를 잘 구분하는 센서를 직접 선택한다. 1차 Grid Search에서는 k=30, C=0.5, gamma=0.003에서 CV Balanced Accuracy 0.6567을 기록했고, 정밀 탐색에서는 k=35, C=2.0, gamma=0.004에서 0.6603으로 개선되었다.

PCA보다 더 적은 35개 변수만 사용했는데도 최종 Test의 Balanced Accuracy, Fail Recall, ROC-AUC가 모두 Tuned RBF보다 높았다. 이번 문제에서는 “분산 보존”보다 “라벨과 직접 관련된 센서 선택”이 더 효과적이었다.

06

최종 모델과 성능

최종 모델 후보
SelectKBest(f_classif, k=35) + RBF-SVM
C=2.0 · gamma=0.004 · class_weight=balanced



지표	값
Accuracy	0.7834
Balanced Accuracy	0.6408
Fail Recall	0.4762
Fail F1	0.2273
ROC-AUC	0.7754
Fail 탐지	10 / 21

Confusion Matrix는 [[236,57],[11,10]]이다. 즉 실제 Fail 21개 중 10개를 탐지했고 11개를 놓쳤으며, 정상 293개 중 57개를 Fail로 오탐했다.

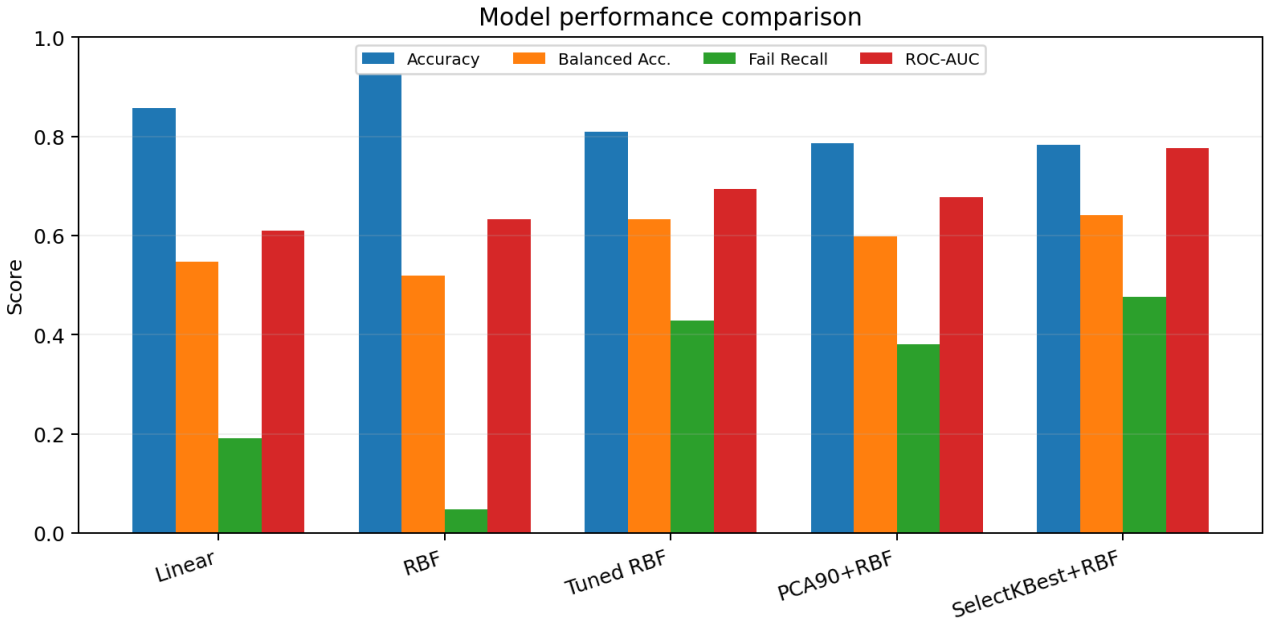


그림 5. 주요 모델 성능 비교. 최종 모델은 특히 ROC-AUC에서 가장 큰 개선을 보였다.

반복 교차검증 안정성 확인: 5-fold × 10회 Repeated Stratified CV에서 Balanced Accuracy 0.6099 ± 0.0530, Fail Recall 0.4457 ± 0.1091, Fail F1 0.1930 ± 0.0431, ROC-AUC 0.6679 ± 0.0501이었다. Grid Search의 단일 CV 최고값 0.6603보다 낮아져, 데이터 분할에 따른 변동성이 존재함을 확인했다.

07

결론, 한계 및 재현 정보

최종 결론

1) 기본 RBF-SVM은 Accuracy가 92.68%였지만 Fail 21개 중 1개만 탐지하여 불균형 데이터에서 Accuracy 단독 평가는 부적절했다.
2) Balanced Accuracy 기준 C/gamma 튜닝으로 Fail Recall을 4.76%에서 42.86%까지 높였다.
3) Threshold 조정은 Fail Recall을 76.19%까지 올렸지만 정상 오탐이 142개로 급증해 최종안으로 채택하지 않았다.
4) PCA 90%는 450 -> 127로 차원을 줄였지만 분류 성능은 감소했다.
5) SelectKBest를 사용해 450 -> 35로 약 92.2% 축소하면서 Balanced Accuracy 0.6408, Fail Recall 0.4762, ROC-AUC 0.7754를 기록해 최종 후보가 되었다.

한계

Test의 Fail이 21개로 매우 적어 한두 개의 예측 변화만으로 Recall이 크게 움직인다. 또한 실험 과정에서 동일한 Test 결과를 여러 차례 확인했기 때문에 이 Test set을 완전히 untouched holdout으로 보기는 어렵다. 엄밀한 최종 성능 추정에는 Nested Cross Validation 또는 새로운 holdout 데이터가 필요하다.

재현 정보

항목	내용
Notebook	notebooks/02_secom_svm.ipynb
원본 데이터	data/raw/secom.data, secom_labels.data
결과 파일	results/svm_model_comparison_final.csv 등
환경	Python 3.11.15 / pandas / NumPy / Matplotlib / scikit-learn
최종 모델	SelectKBest(k=35) + RBF-SVM(C=2.0, gamma=0.004, class_weight=balanced)

참고자료

McCann, M. & Johnston, A. (2008). SECOM [Dataset]. UCI Machine Learning Repository. DOI: 10.24432/C54305. UCI 공식 설명은 SECOM이 실제 반도체 제조 공정 신호의 Pass/Fail 분류와 Feature Selection 연구를 위한 데이터임을 설명한다.
본 보고서의 모델 성능 수치는 2026-09-02 VS Code/Jupyter에서 직접 실행한 실험 결과를 기반으로 정리하였다.

한 문장 요약

SECOM 불량 분류에서는 모든 센서를 쓰거나 PCA로 분산을 압축하는 것보다, Pass/Fail에 직접 관련된 35개 센서를 지도형으로 선택한 뒤 RBF-SVM을 적용하는 방식이 가장 좋은 불량 탐지 균형을 보였다.