One-Class SVM 기반 이상치 탐지 모델 비교 실험

1. 실험 목적

- 클래스 불균형 데이터에서 One-Class SVM의 이상치 탐지 성능을 확인한다.
- 낙상 데이터가 아닌 다른 도메인에서도 One-Class SVM이 적용 가능한지 검토한다.
- 비교 모델은 이상치 탐지에서 자주 사용되는 Isolation Forest와 Autoencoder로 설정한다.

분석 진행 순서

```
Data Load
→ Data EDA
→ Data Profiling
→ Data Cleansing
→ Feature Engineering
→ Data Split
→ Modeling
→ Validation
→ Test
→ Model Comparison
→ Conclusion
```

- 데이터 로드: Kaggle 신용카드 사기 거래 데이터 불러오기
- EDA/Profile: 변수 구조, 결측치, 중복, 타깃 불균형 확인
- Cleansing: 완전 중복 행 제거
- Feature Engineering: `Amount` 로그 변환, RobustScaler 적용
- Split: 시간 순서를 유지한 학습·검증·테스트 분할
- Modeling: One-Class SVM, Isolation Forest, Autoencoder 학습
- Evaluation: PR-AUC(AUPRC) 기준으로 모델 성능 비교

2. 데이터 및 문제 설정

- 사용 데이터: Kaggle Credit Card Fraud Detection 데이터
- 전체 데이터: 284,807건, 31개 변수
- 최종 분석 데이터: 중복 제거 후 283,726건
- 입력 변수: `Time`, `Amount`, `V1` ~ `V28`
- 타깃 변수: `Class`
  - `0`: 정상 거래
  - `1`: 사기 거래
- 문제 유형: 극단적인 클래스 불균형을 가진 이상치 탐지 문제

구분	전체 건수	정상 거래	사기 거래	사기 비율
학습	170,235	169,893	342	0.201%
검증	56,745	56,688	57	0.100%
테스트	56,746	56,672	74	0.130%

- 사기 거래 비율이 매우 낮기 때문에 Accuracy는 적절한 평가 지표가 아니다.
- 본 실험에서는 이상 점수가 높은 거래가 실제 사기 거래를 얼마나 잘 상위에 배치하는지 평가한다.

3. 평가 방식: PR-AUC(AUPRC)

- 평가 지표: PR-AUC(AUPRC)
- 양성 클래스: 사기 거래 `Class = 1`
- 모델 출력: 거래별 이상 점수
- 해석 방식: 이상 점수가 높을수록 사기 거래일 가능성이 높다고 판단
- 계산 방식: Precision-Recall 곡선을 구한 뒤, 곡선 아래 면적을 사다리꼴 방식으로 계산

Precision

$$Precision = \frac{TP}{TP + FP}$$

- 모델이 사기라고 판단한 거래 중 실제 사기 거래의 비율
- 오탐이 많아질수록 Precision은 낮아진다.

Recall

$$Recall = \frac{TP}{TP + FN}$$

- 실제 사기 거래 중 모델이 찾아낸 사기 거래의 비율
- 놓친 사기 거래가 많아질수록 Recall은 낮아진다.

PR-AUC

$$PR\text{-}AUC = \int_0^1 Precision(Recall)\, dRecall$$

실제 계산에서는 곡선을 이산적인 점으로 구한 뒤 사다리꼴 면적을 더한다.

$$PR\text{-}AUC \approx \sum_{i=1}^{n-1} \frac{Precision_i + Precision_{i+1}}{2} \times (Recall_{i+1} - Recall_i)$$

- PR-AUC가 높을수록 여러 임계값에서 사기 거래를 더 잘 상위에 배치한 것이다.
- 단일 Precision이나 Recall이 아니라, 임계값 변화에 따른 전체 성능을 요약한 값이다.

4. 전처리 및 실험 설계

- `Amount`는 오른쪽 꼬리가 긴 분포를 보여 `log1p` 변환을 적용하였다.
- 스케일링은 RobustScaler를 사용하였다.
- RobustScaler는 정상 학습 거래를 기준으로 학습하였다.
- 검증 데이터와 테스트 데이터에는 학습 데이터에서 계산한 동일한 기준을 적용하였다.

학습 표본

- 정상 단독 학습: 정상 거래 5,000건
- 혼합 학습: 정상 거래 4,658건 + 사기 거래 342건
- 혼합 학습의 사기 비율: 6.84%
- 혼합 표본은 원본 데이터의 사기 비율을 유지하지 않는다.

실험 모델

실험	모델	학습 데이터
E1	One-Class SVM	정상 거래
E2	Isolation Forest	정상 거래
E3	Autoencoder	정상 거래
E4	Isolation Forest	정상 + 사기 거래
E5	Autoencoder	정상 + 사기 거래

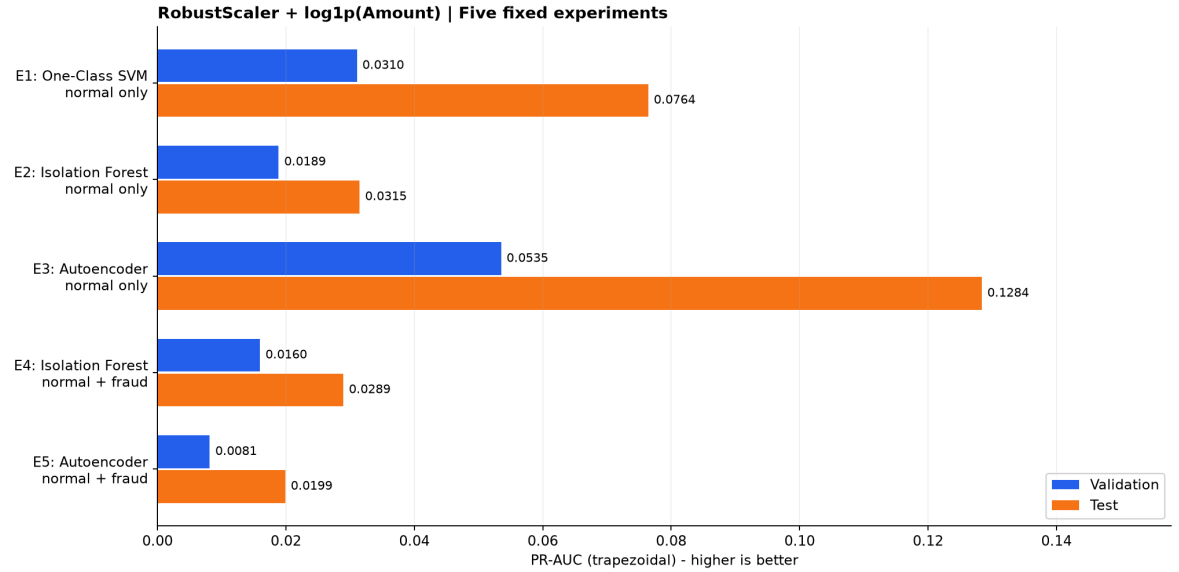
- One-Class SVM: RBF 커널, `gamma=scale`, `nu=0.01`
- Isolation Forest: 트리 200개, `max_samples=auto`
- Autoencoder: 입력 복원용 MLP, 은닉층 `16 → 8 → 16`
- 모든 모델은 같은 검증 데이터와 테스트 데이터에서 평가하였다.

5. 실험 결과

- 검증 PR-AUC 기준 1위: 정상 거래만 학습한 Autoencoder
- 테스트 PR-AUC 기준 1위: 정상 거래만 학습한 Autoencoder
- One-Class SVM은 Isolation Forest보다 높고 Autoencoder보다 낮은 성능을 보였다.
- 정상 데이터만 학습한 모델들이 혼합 학습 모델보다 전반적으로 좋은 결과를 보였다.

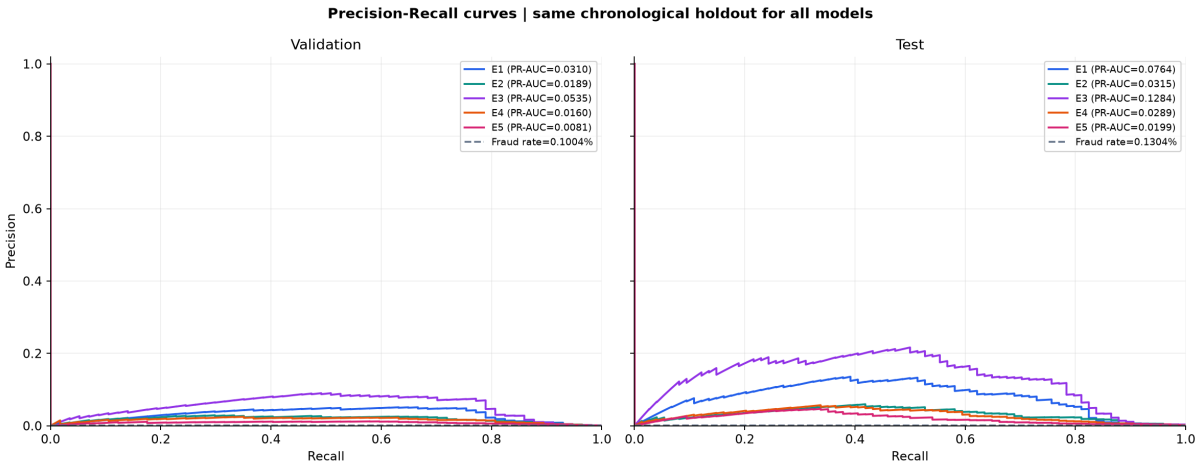
순위	실험	모델	학습 데이터	검증 PR-AUC	테스트 PR-AUC
1	E3	Autoencoder	정상 거래	0.053505	0.128372
2	E1	One-Class SVM	정상 거래	0.031047	0.076431
3	E2	Isolation Forest	정상 거래	0.018873	0.031472
4	E4	Isolation Forest	정상 + 사기 거래	0.015954	0.028946

순위	실험	모델	학습 데이터	검증 PR-AUC	테스트 PR-AUC
5	E5	Autoencoder	정상 + 사기 거래	0.008141	0.019898



- 테스트 기준 One-Class SVM의 PR-AUC는 0.0764310이다.
- 테스트 기준 Isolation Forest의 PR-AUC는 0.0314720이다.
- One-Class SVM은 Isolation Forest보다 사기 거래를 더 높은 순위에 배치했다.
- Autoencoder는 가장 높은 성능을 보였지만, 최대 반복 횟수에 도달했다는 수렴 경고가 있었다.

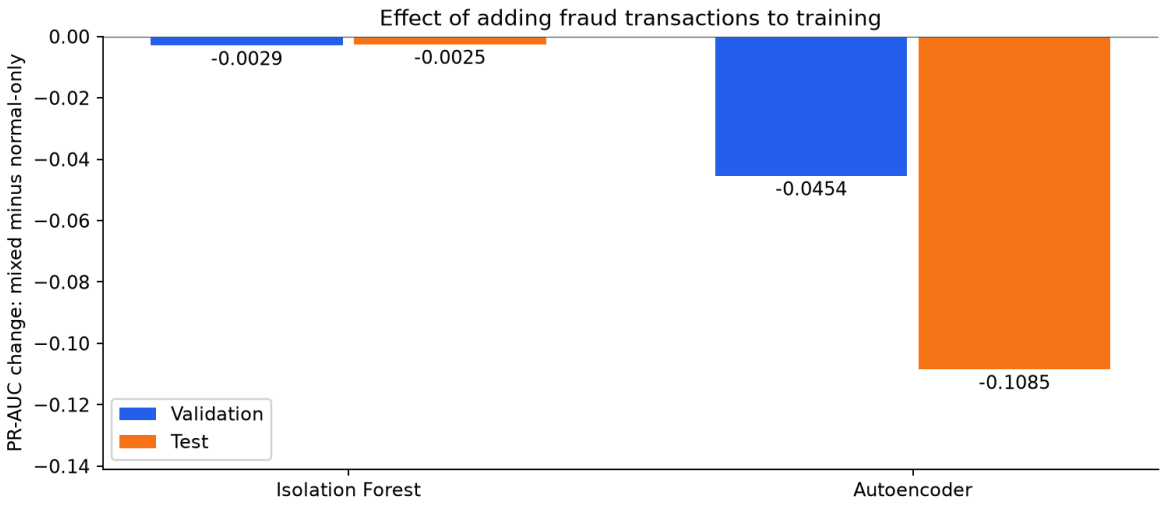
6. Precision-Recall 곡선 해석



- 가로축: Recall
- 세로축: Precision
- 점선: 각 평가 구간의 실제 사기 거래 비율
- 정상 단독 Autoencoder가 여러 Recall 구간에서 가장 높은 Precision을 보였다.

- One-Class SVM은 Autoencoder보다는 낮지만 Isolation Forest보다 안정적으로 높은 곡선을 보였다.
- 곡선 전체가 높은 Precision에 머물지는 않기 때문에, 실제 적용 시 임계값 설정이 중요하다.

7. 혼합 학습 효과



- Isolation Forest는 혼합 학습 시 테스트 PR-AUC가 감소하였다.
  - 0.031472 → 0.028946
- Autoencoder도 혼합 학습 시 테스트 PR-AUC가 크게 감소하였다.
  - 0.128372 → 0.019898
- 이번 표본 구성에서는 사기 거래를 학습 데이터에 포함하는 것이 성능 개선으로 이어지지 않았다.
- 이상치 탐지에서는 정상 패턴을 명확하게 학습하는 것이 중요하다.
- 사기 거래가 학습 데이터에 섞이면 이상 거래의 특성이 정상 패턴처럼 반영될 수 있다.

8. 종합 해석

- One-Class SVM은 최고 성능 모델은 아니었다.
- 하지만 정상 단독 Isolation Forest보다 높은 PR-AUC를 기록하였다.
- 따라서 One-Class SVM은 클래스 불균형 데이터에서 이상치 탐지 모델로 활용 가능성이 있다.
- Autoencoder는 가장 높은 PR-AUC를 보였지만, 수렴 경고가 있어 추가 튜닝이 필요하다.
- 혼합 학습은 이번 실험에서 오히려 성능을 낮추었다.
- 정상 데이터 중심 학습이 이상치 탐지 문제에서 더 적절할 수 있다.

9. 결론

- One-Class SVM은 신용카드 사기 거래 데이터에서 일정한 이상치 탐지 성능을 보였다.
- 테스트 PR-AUC 기준으로 Autoencoder보다는 낮고 Isolation Forest보다는 높았다.

- 정상 데이터만 학습하는 방식은 이상치 탐지 문제에서 의미 있는 접근이었다.
- 본 실험의 결론은 One-Class SVM이 클래스 불균형 데이터에서 사용할 수 있는 모델로 확인되었다.