8주차 _ SVM 분석

상태	완료
날짜	2026년 9월 11일
유형	분석

Social Media Sentiments Analysis Dataset

1. 분석 목적 및 문제 정의

▼ 배경

최근 소셜미디어(SNS) 사용이 일상화되면서, 사용자들이 게시하는 짧은 텍스트에는 개인의 감정 상태와 사회적 반응이 실시간으로 축적되고 있다. 이러한 게시물은 텍스트 자체뿐 아니라 플랫폼 종류, 국가, 해시태그, 좋아요·리트윗 수, 게시 시간대 등 다양한 메타데이터와 결합되어 나타나는데, 이를 자동으로 분류·분석할 수 있다면 여론 동향 파악, 마케팅 전략 수립, 사용자 정서 모니터링 등 다양한 분야에 활용할 수 있어 중요한 연구 과제로 대두되고 있다.

▼ 분석 목적

본 분석은 SNS 게시물 데이터를 활용하여, 텍스트 내용(TF-IDF 기반 어휘·n-gram)과 메타데이터(플랫폼·국가·해시태그·참여도·게시 시간)가 게시물의 감성(`Sentiment_grouped`: `Negative` / `Neutral` / `Positive`)에 어떤 영향을 미치는지 파악하고, 이를 기반으로 감성을 예측하는 분류 모델을 구축하는 것을 목적으로 한다.

▼ 연구 문제

- 어떤 텍스트적 특성(단어·n-gram) 및 메타데이터적 요인(플랫폼, 국가, 해시태그, 참여도, 요일·시간대)이 감성 수준(Negative/Neutral/Positive)과 유의한 관련이 있는가?
- 위 요인들을 feature로 활용하여 게시물의 감성 수준을 얼마나 정확하게 예측할 수 있는가?
- 예측에 상대적으로 크게 기여하는 변수(군)은 무엇인가?

---

2. 개요

N: 732

Features

Feature	Description
`Text`	User-generated content showcasing sentiments
`Sentiment`	Categorized emotions
`Timestamp`	Date and time information
`User`	Unique identifiers of users contributing
`Platform`	Social media platform where the content originated
`Hashtags`	Identifies trending topics and themes
`Likes`	Quantifies user engagement (likes)
`Retweets`	Reflects content popularity (retweets)
`Country`	Geographical origin of each post
`Year`	Year of the post
`Month`	Month of the post
`Day`	Day of the post
`Hour`	Hour of the post

3. 감성 레이블 재매핑

▼ 재매핑 목적

- 원본 `Sentiment_original` 컬럼은 `Joy`, `Excitement`, `Contentment`, `Gratitude`, `Anger`, `Sadness`, `Fear` 등 **매우 세분화된 다수의 감정 레이블**
  → 클래스 수가 지나치게 많고 클래스 별 표본 수가 적어 다중 분류 모델 학습에 부적합
- 감성 분석의 실질적 활용 목적(브랜드 모니터링, 여론 분석 등)에 맞게 **Positive / Negative / Neutral 3-class**로 단순화
  → 클래스 불균형 완화 및 모델 학습 효율성 확보

▼ 재매핑 과정

단계	핵심 키워드	내용
1	**NRC Emotion Lexicon**	NRCLex.__lexicon__ 활용, 단어별 positive/negative + 8개 감정 카테고리 태그 확인
2	**Fallback 규칙**	positive/negative 태그 없는 단어 대비, joy/trust/anticipation→positive, anger/disgust/fear/sadness→negative 보조 매핑
3	**CamelCase 토큰 분리**	정규식으로 복합 레이블(예: Bittersweet)을 단어 단위로 분리 후 사전 조회
4	**NRC 우선 + SentiWordNet 보조**	NRC 미탐지 레이블에 한해 SentiWordNet 점수로 보완
5	**점수 비교 매핑**	pos_score vs neg_score 비교 → 큰 쪽 극성 할당, 동점/0점은 Neutral(수동검토)
6	**수동 검토(Manual Review)**	두 사전 모두 미탐지 레이블 별도 추출
7	**Override 딕셔너리**	Empowerment/Resilience/Iconic/Engagement→Positive, Nostalgia/Confusion/Solitude 등→Neutral 수동 지정
8	**Sanity Check**	Anger/Joy/Sadness 등 핵심 레이블 매핑 정확성 재검증
9	**최종 적용 및 검증**	final_mapping 적용 → 누락 건수 확인 → 재매핑 전/후 분포 비교(표+그래프)

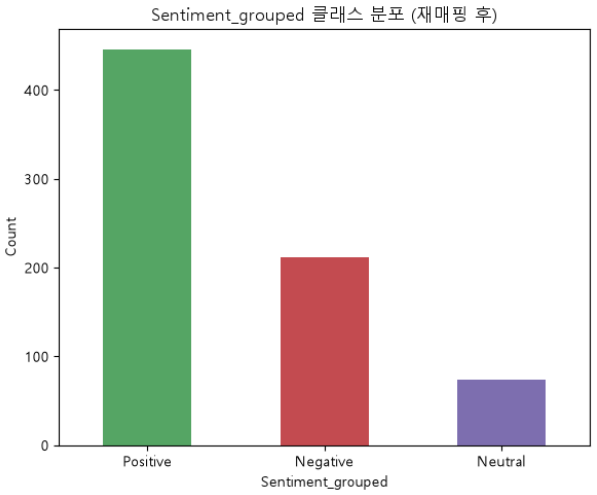
▼ 재매핑 결과

- 재매핑 결과

	Sentiment_original	Sentiment_grouped
0	Intrigue	Negative
1	Pensive	Negative
2	Pressure	Negative
3	Ruins	Negative
4	Despair	Negative
...	...	...
186	Wonderment	Positive
187	Optimism	Positive
188	Enchantment	Positive
189	Free-spirited	Positive
190	Happy	Positive

- 매핑 누락 건수: 0건
- 재매핑 후 클래스 분포

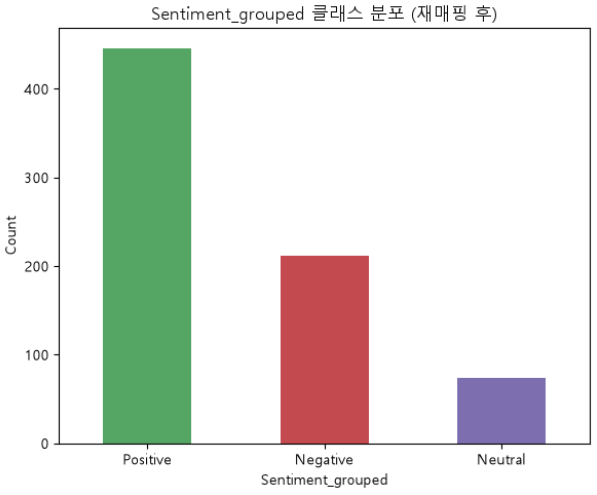
Sentiment_grouped	count	ratio
Positive	446	0.609
Negative	212	0.290
Neutral	74	0.101



4. EDA 분석

▼ 1) 전체 감성 분포

Sentiment_grouped	count	ratio
Positive	446	0.609
Negative	212	0.290
Neutral	74	0.101

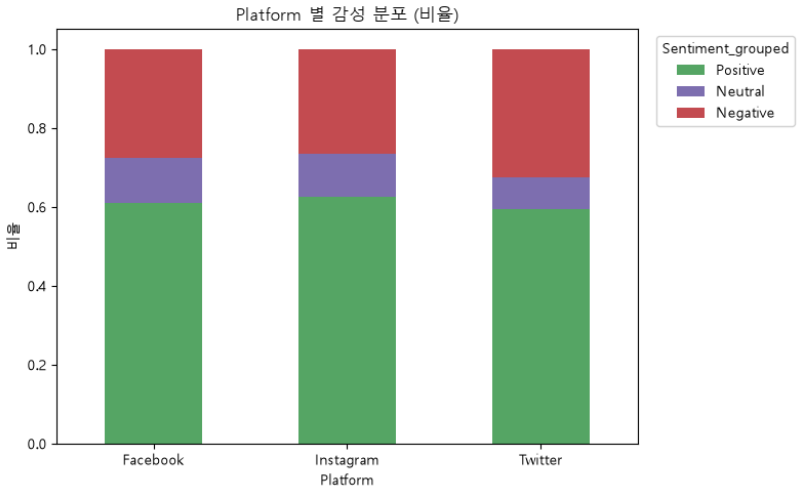


- **Positive > Negative > Neutral**
- SNS 게시물 특성상 긍정 어조 다수, 중립적 표현 상대적 희소

- `class_weight='balanced'` 적용 → 불균형 대응
- Accuracy 보다 **Macro F1** 중심 평가 타당성 뒷받침
- `stratify` 옵션으로 Train/Test split

▼ 2) Platform 별 감성 분포

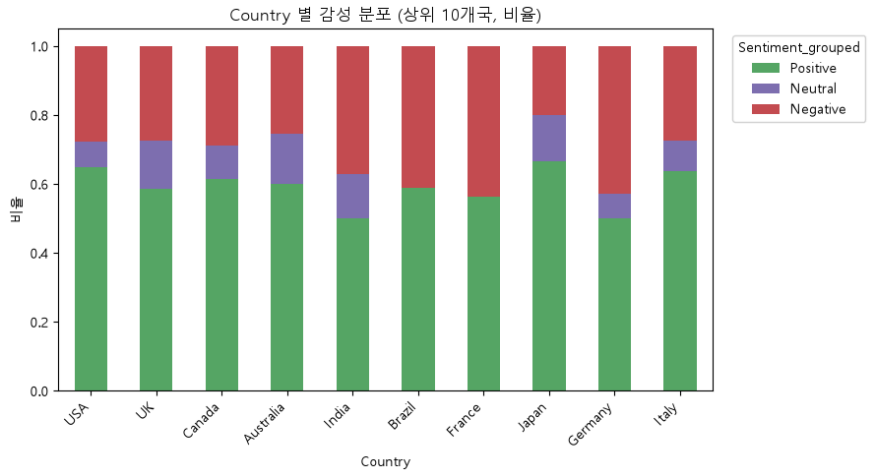
Sentiment_grouped	Negative	Neutral	Positive
Platform			
Facebook	0.277	0.113	0.610
Instagram	0.267	0.109	0.624
Twitter	0.325	0.082	0.593



▼ 3) Counrtry 별 감성 분포

가장 많은 상위 10개의 국가에 대한 감성 분포

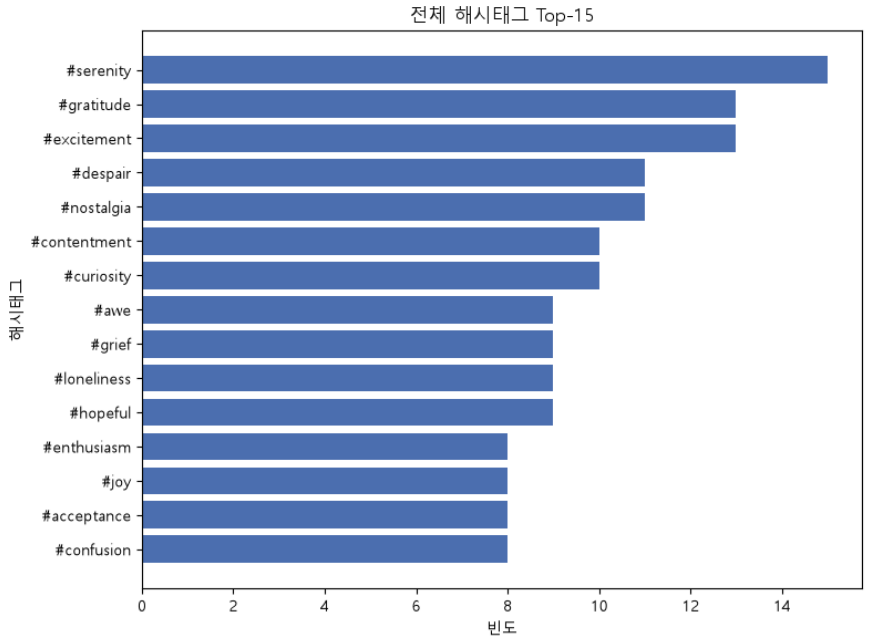
Sentiment_grouped	Negative	Neutral	Positive
Country			
USA	0.277	0.074	0.649
UK	0.273	0.140	0.587
Canada	0.289	0.096	0.615
Australia	0.253	0.147	0.600
India	0.371	0.129	0.500
Brazil	0.412	0.000	0.588
France	0.438	0.000	0.562
Japan	0.200	0.133	0.667
Germany	0.429	0.071	0.500
Italy	0.273	0.091	0.636



▼ 4) Hashtags 빈도 분석

a. **전체 Top-15**

	hashtag	count
0	#serenity	15
1	#gratitude	13
2	#excitement	13
3	#despair	11
4	#nostalgia	11
5	#contentment	10
6	#curiosity	10
7	#awe	9
8	#grief	9
9	#loneliness	9
10	#hopeful	9
11	#enthusiasm	8
12	#joy	8
13	#acceptance	8
14	#confusion	8



b. **Sentiment_gruped 별 Top-15**

a. **Positive**

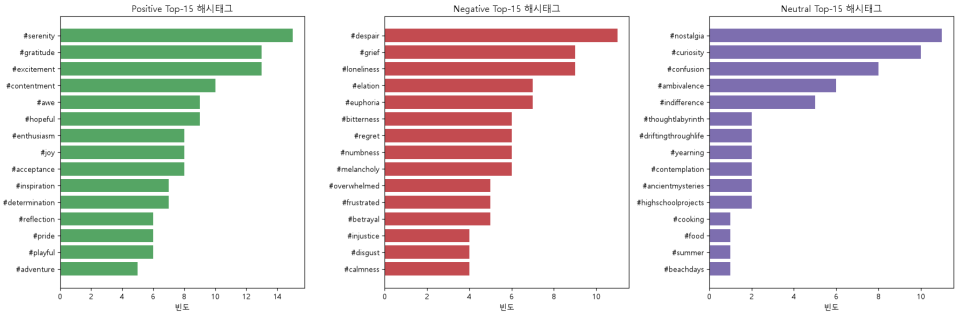
	hashtag	count_Positive
0	#serenity	15
1	#gratitude	13
2	#excitement	13
3	#contentment	10
4	#awe	9
5	#hopeful	9
6	#enthusiasm	8
7	#joy	8
8	#acceptance	8
9	#inspiration	7
10	#determination	7
11	#reflection	6
12	#pride	6
13	#playful	6
14	#adventure	5

b. **Negative**

	hashtag	count_Negative
0	#despair	11
1	#grief	9
2	#loneliness	9
3	#elation	7
4	#euphoria	7
5	#bitterness	6
6	#regret	6
7	#numbness	6
8	#melancholy	6
9	#overwhelmed	5
10	#frustrated	5
11	#betrayal	5
12	#injustice	4
13	#disgust	4
14	#calmness	4

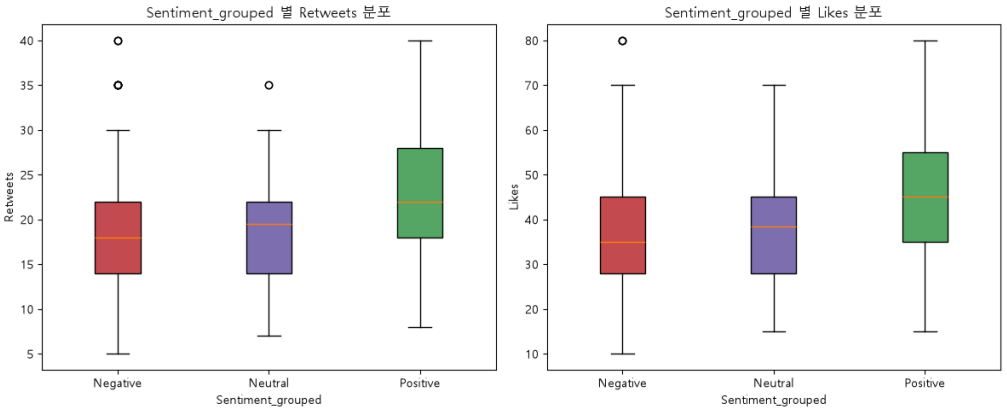
c. **Neutral**

	hashtag	count_Neutral
0	#nostalgia	11
1	#curiosity	10
2	#confusion	8
3	#ambivalence	6
4	#indifference	5
5	#thoughtlabyrinth	2
6	#driftingthroughlife	2
7	#yearning	2
8	#contemplation	2
9	#ancientmysteries	2
10	#highschoolprojects	2
11	#cooking	1
12	#food	1
13	#summer	1
14	#beachdays	1

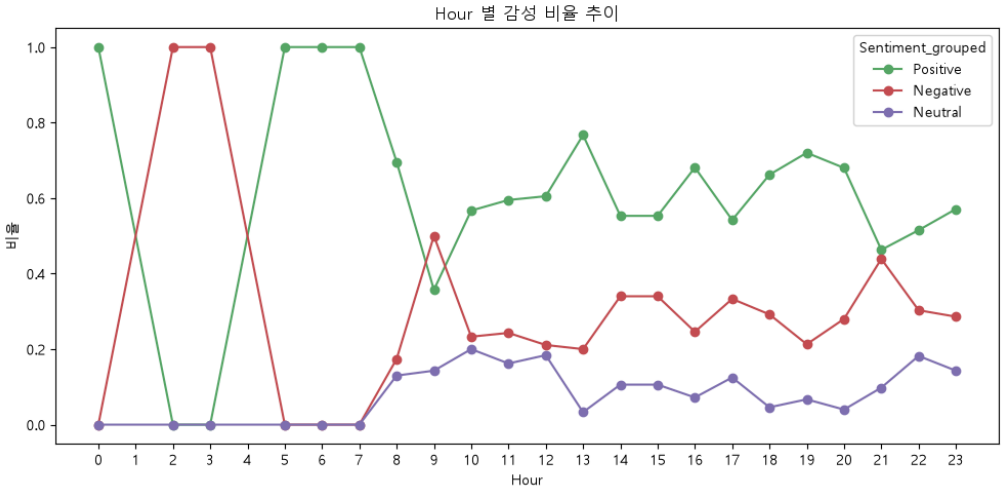


▼ 5) Retweets/Likes 와 감성 관계

	Retweets				Likes			
	mean	median	std	count	mean	median	std	count
Sentiment_grouped								
Negative	18.78	18.0	7.27	212	37.45	35.0	14.49	212
Neutral	19.04	19.5	6.52	74	38.01	38.5	12.88	74
Positive	23.22	22.0	6.51	446	46.30	45.0	13.03	446



▼ 6) Hour 별 감성 패턴



---

5. Text 전처리

▼ 1) 사전 진단

항목	키워드
URL 탐지	정규식(http\S+, www.\S+) 기반 카운트
멘션(@) 탐지	@\w+ 패턴 카운트
이모지 탐지	유니코드 범위 기반(\U0001F300~) 카운트
목적	전처리 방식 결정 전 **Text 컬럼 특성 파악**

▼ 2) 전처리 파이프라인 구성

a. 이모지 → 텍스트 변환

`emoji.demojize()` , 제거 대신 의미 보존

	Text	Text_clean
2	Just finished an amazing workout! 💪	finished amazing workout flexed biceps
13	New year, new fitness goals! 💪	new year new fitness goal flexed biceps
16	Just adopted a cute furry friend! 🐾	adopted cute furry friend paw print
24	Celebrating a milestone at work! 🎉	celebrating milestone work party popper
29	New painting in progress! 🎨	new painting progress artist palette
41	Celebrating a friend's birthday tonight! 🎂	celebrating friend birthday tonight birthday cake
50	Starting a new fitness challenge tomorrow! 💪	starting new fitness challenge tomorrow flexed...
58	Sharing love and positive vibes with everyone! ❤️	sharing love positive vibe everyone red heart
67	Overflowing with adoration for my adorable pet! 🐾	overflowing adoration adorable pet paw print
82	Sending love to all my followers on this beaut...	sending love follower beautiful day red heart
91	Overflowing adoration for a cute rescue puppy! 🐶	overflowing adoration cute rescue puppy dog face

b. 소문자화

`.lower()`

c. 특수문자/숫자 제거

정규식으로 알파벳+공백만 유지

d. 공백 정리

연속 공백 → 단일 공백

e. 토큰화

`word_tokenize()`

f. 불용어 제거 + 표제어 추출

`stopwords` , `WordNetLemmatizer` , 2글자 이하 토큰 제거

	Text	Text_clean
0	Enjoying a beautiful day at the park!	enjoying beautiful day park
1	Traffic was terrible this morning.	traffic terrible morning
2	Just finished an amazing workout! 💪	finished amazing workout flexed biceps
3	Excited about the upcoming weekend getaway!	excited upcoming weekend getaway
4	Trying out a new recipe for dinner tonight.	trying new recipe dinner tonight

전처리 후 평균 토큰 수 : 8.15개

---

5. Feature Engineering

▼ 1) 텍스트 벡터화 (TF-IDF, 1-2 gram)

a. 벡터화 방식

`TfidfVectorizer` , **Unigram+Bigram**(`ngram_range=(1,2)`)

b. 차원 제어

`max_features=3000` (폭증 방지), `min_df=2` (희귀 토큰 제거), `max_df=0.95` (과빈도 제거)

c. 검증

피처명 샘플 확인, **Unigram/Bigram 비율** 검증

▼ 2) Platform / Country 원-핫

a. Platform

카디널리티 확인 → 충분한 비중 → **그룹화 없이 원형 유지**

b. Country

비율 **3% 미만** → **'Other' 통합**(저빈도 그룹화, 차원 폭증 방지)

c. 인코딩

`pd.get_dummies`, `drop_first=True`

▼ 3) Hashtags

a. 개수 피처

`hashtag_count` (리스트 길이)

b. 키워드 이진화

EDA 기반 **Top-10 해시태그** 등장 여부(0/1)

c. 결합

`hashtag_count` + 이진화 피처 concat

▼ 4) Likes/Retweets 정규화

- 정규화 방식: `StandardScaler`
- 검증: 정규화 후 **평균 0, 표준편차 1** 확인

▼ 5) 시간 파생 변수

a. 요일 파생

`Year` / `Month` / `Day` → `Date` → `day_of_week`

b. 시간대 파생

Hour → **Night/Morning/Afternoon/Evening** 4구간

c. 인코딩 판단

명목형(비선형 관계) + **낮은 카디널리티**(7개, 4개) → One-Hot 적용

▼ 6) 최종 결합 (scipy.sparse.hstack)

항목	키워드
변환	각 피처 블록 → csr_matrix
결합	hstack으로 **TF-IDF + Platform/Country + Hashtags + Likes/Retweets + Time** 통합
검증	X_combined.shape vs 피처명 개수 **일치 assert**
요약	블록별 차원 요약표(block_summary)
Target 준비	y_combined = Sentiment_grouped

---

6. 모델링

▼ 데이터 분할

a. Train/Test 분할 결과

X_train shape: (585, 1570)
X_test shape : (147, 1570)

b. Train/Test 분포

Sentiment_grouped	ratio
Positive	0.610
Negative	0.289
Neutral	0.101

Sentiment_grouped	ratio
Positive	0.605
Negative	0.293
Neutral	0.102

▼ 모델링

a. SVM Linear

최적 파라미터: C = 1, CV Macro F1 = 0.7233

	precision	recall	f1-score	support
Negative	0.87	0.79	0.83	43
Neutral	0.89	0.53	0.67	15
Positive	0.85	0.94	0.89	89
accuracy			0.86	147
macro avg	0.87	0.76	0.80	147
weighted avg	0.86	0.86	0.85	147

	Negative	Neutral	Positive
Negative	34	0	9
Neutral	1	8	6
Positive	4	1	84

b. rbf - GridSearchCV(C, Gamma)

최적 파라미터: C = 10, Gamma = 0.01

	precision	recall	f1-score	support
Negative	0.84	0.72	0.78	43
Neutral	0.89	0.53	0.67	15
Positive	0.83	0.94	0.88	89
accuracy			0.84	147
macro avg	0.85	0.73	0.78	147
weighted avg	0.84	0.84	0.83	147

▼ 모델 평가 및 비교

a. 최종 성능 비교

	kernel	best_params	cv_macro_f1	test_macro_f1
0	linear	{'C': 1}	0.7233	0.7965
1	rbf	{'C': 10, 'gamma': 0.01}	0.7271	0.7753

b. 최종 선택 모델

SVM (linear kernel)

7. 종합 결론

▼ SVM 계수(coef_) 기반 핵심 단어 분석

a. 결과

3-class → OvO 방식으로 **3개 이진분류기**(Neg vs Neu, Neg vs Pos, Neu vs Pos) 학습, coef_ shape (3, 1570)

비교 쌍	Negative 방향 핵심어	Positive/Neutral 방향 핵심어
Neg vs Neu	bad, personal, whisper, regret	hashtag_has_nostalgia, confusion, attending
Neg vs Pos	elation, bad, euphoria, snack	pride, determination, championship
Neu vs Pos	new recipe, nostalgia, enhance	virtual reality, inspired, empowered

	Top_Negative	coef_Negative	Top_Neutral	coef_Neutral
0	bad	0.442	hashtag_has_nostalgia	-0.697
1	personal	0.417	confusion	-0.638
2	whisper	0.415	attending	-0.633
3	regret	0.406	exploring	-0.615
4	dealing	0.396	oops	-0.603
5	feeling	0.331	hashtag_has_curiosity	-0.592
6	wall	0.326	indifference	-0.541
7	hashtag_has_loneliness	0.316	new	-0.533
8	like	0.311	club	-0.518
9	society	0.310	community	-0.517
10	Country_grouped_India	0.306	teamwork	-0.506
11	longing	0.303	collaborating	-0.506
12	wrong	0.273	cherished	-0.500
13	teenlife	0.273	changing	-0.499
14	hashtag_has_grief	0.266	curiosity	-0.475

	Top_Negative	coef_Negative	Top_Positive	coef_Positive
0	elation	1.131	pride	-0.783
1	bad	1.011	determination	-0.761
2	euphoria	0.991	tonight	-0.676
3	snack	0.987	embracing	-0.668
4	morning	0.787	championship	-0.623
5	jealousy	0.758	delight	-0.604
6	dealing	0.725	week	-0.583
7	frustration	0.719	perfect	-0.574
8	hold	0.701	hashtag_has_awe	-0.558
9	without	0.666	reflecting	-0.547
10	lost	0.654	waiting	-0.546
11	satisfaction	0.651	devastated	-0.541
12	hateful	0.630	acceptance	-0.526
13	learn	0.620	new	-0.520
14	unknown	0.611	exploring	-0.508

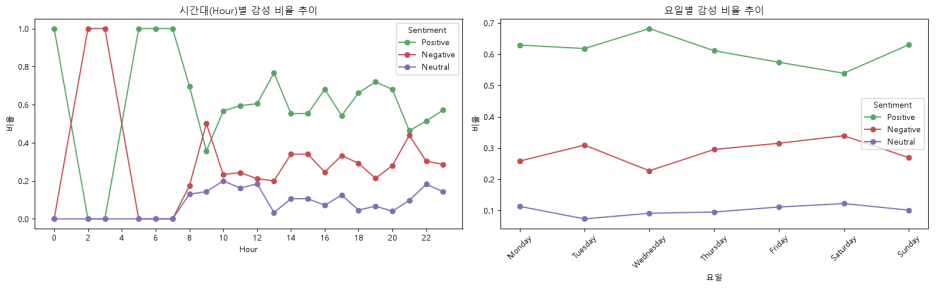
	Top_Neutral	coef_Neutral	Top_Positive	coef_Positive
0	new recipe	0.887	virtual reality	-0.634
1	hashtag_has_nostalgia	0.862	inspired	-0.546
2	enhance	0.828	reality	-0.541
3	indifference	0.700	acceptance	-0.493
4	attending virtual	0.686	feeling	-0.463
5	oops	0.674	empowered	-0.404
6	saturday	0.674	compassion	-0.376
7	hashtag_has_curiosity	0.665	coding	-0.366
8	neighborhood	0.652	enthusiasm	-0.363
9	attending	0.651	joy	-0.356
10	teamwork	0.647	weekend	-0.356
11	event	0.645	new skill	-0.327
12	confusion	0.641	started	-0.319
13	cause	0.640	tranquility	-0.319
14	missing	0.623	story	-0.318

b. 해석

- bad, regret, frustration 등 **직관적인 부정 감성 단어**가 Negative 판별에 강하게 기여 → 모델이 합리적인 언어 패턴을 학습함
- Neutral은 hashtag_has_nostalgia, confusion, attending 등 **일상적·이벤트성 어휘**가 특징적 → 뚜렷한 감정 표현보다는 서술적 텍스트 패턴과 연관

▼ 시간대(Hour)/요일별 감성 비율

a. 결과

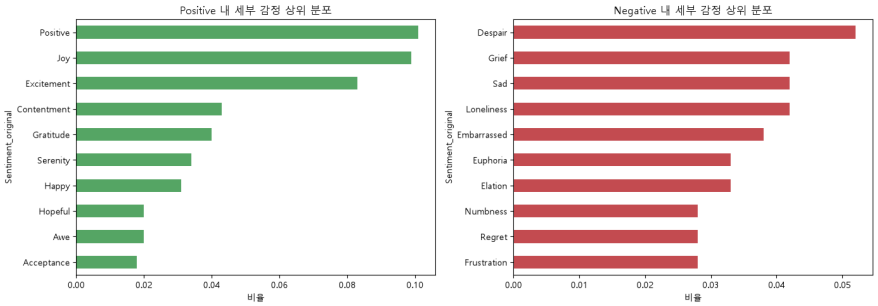


b. 해석

- 새벽 시간대(0, 2, 3, 5~7시)는 **표본 수가 극히 적어** 0 또는 1로 극단적 비율이 나타남(과적합 해석 주의 필요) → 신뢰구간이 좁은 시간대는 해석에서 제외 권장
- 표본이 충분한 8~23시대에서는 **Positive가 전반적으로 우세**하되, 9시·21시경 Negative 비율이 상대적으로 상승하는 패턴
- 요일별로는 **Wednesday가 Positive 비율 최고(0.682)**, **Saturday가 Positive 최저(0.539)이자 Negative 최고(0.339)** → 주말 후반 감성이 다소 부정적으로 기울어지는 경향

▼ Positive/Negative 내 세부 감정(Sentiment_original) 분포

a. 결과



b. 해석

- **Positive 내부**: Positive(0.101), Joy(0.099), Excitement(0.083) 순으로 상위권 형성 → 활기차고 즉각적인 긍정 감정이 주를 이룸
- **Negative 내부**: Despair(0.052), Grief(0.042), Loneliness(0.042), Sad(0.042) 순 → 분노형보다는 **우울·상실 계열 감정**이 두드러짐
- 두 그룹 모두 **최상위 세부감정 비율이 5~10% 수준**으로 특정 감정에 심하게 쏠리지 않고 **다양한 세부 감정이 고르게 분산**되어 있음을 보여줌

→ 재매핑(Sentiment_grouped)이 다양한 세부 감정을 3개 그룹으로 잘 포괄하고 있음을 뒷받침

---

8. 비교 모델

▼ 모델링

a. **로지스틱 회귀 (Logistic Regression)**

정확도 (Accuracy) : 0.86

	precision	recall	f1-score	support
Negative	0.850	0.791	0.819	43.000
Neutral	0.889	0.533	0.667	15.000
Positive	0.857	0.944	0.898	89.000
accuracy	0.857	0.857	0.857	0.857
macro avg	0.865	0.756	0.795	147.000
weighted avg	0.858	0.857	0.852	147.000

	예측_Negative	예측_Neutral	예측_Positive
실제_Negative	34	0	9
실제_Neutral	2	8	5
실제_Positive	4	1	84

b. **BERT 계열 (DistilBERT Fine-tuning)**

정확도 (Accuracy) : 0.84

Epoch	Training Loss	Validation Loss	Accuracy	Macro F1	Weighted F1
1	0.874699	0.710422	0.748299	0.487118	0.693532
2	0.558575	0.503808	0.829932	0.570018	0.784998
3	0.382102	0.460040	0.843537	0.582902	0.799079
4	0.317197	0.450242	0.843537	0.581958	0.798522

	precision	recall	f1-score	support
Negative	0.776	0.884	0.826	43.000
Neutral	0.000	0.000	0.000	15.000
Positive	0.878	0.966	0.920	89.000
accuracy	0.844	0.844	0.844	0.844
macro avg	0.551	0.617	0.582	147.000
weighted avg	0.758	0.844	0.799	147.000

	예측_Negative	예측_Neutral	예측_Positive
실제_Negative	38	0	5
실제_Neutral	8	0	7
실제_Positive	3	0	86

▼ 모델링

a. **로지스틱 회귀 (Logistic Regression)**

정확도 (Accuracy) : 0.86

	precision	recall	f1-score	support
Negative	0.850	0.791	0.819	43.000
Neutral	0.889	0.533	0.667	15.000
Positive	0.857	0.944	0.898	89.000
accuracy	0.857	0.857	0.857	0.857
macro avg	0.865	0.756	0.795	147.000
weighted avg	0.858	0.857	0.852	147.000

	예측_Negative	예측_Neutral	예측_Positive
실제_Negative	34	0	9
실제_Neutral	2	8	5
실제_Positive	4	1	84

b. **BERT 계열 (DistilBERT Fine-tuning)**

정확도 (Accuracy) : 0.84

Epoch	Training Loss	Validation Loss	Accuracy	Macro F1	Weighted F1
1	0.874699	0.710422	0.748299	0.487118	0.693532
2	0.558575	0.503808	0.829932	0.570018	0.784998
3	0.382102	0.460040	0.843537	0.582902	0.799079
4	0.317197	0.450242	0.843537	0.581958	0.798522

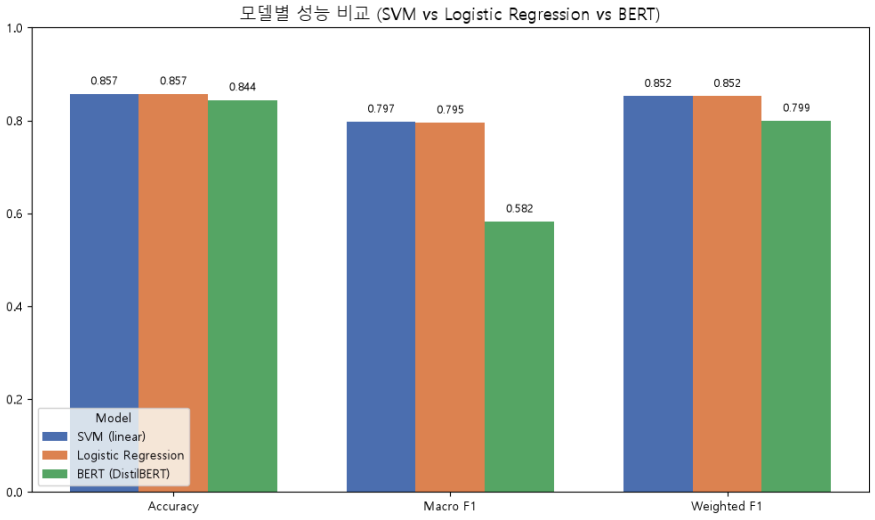
	precision	recall	f1-score	support
Negative	0.776	0.884	0.826	43.000
Neutral	0.000	0.000	0.000	15.000
Positive	0.878	0.966	0.920	89.000
accuracy	0.844	0.844	0.844	0.844
macro avg	0.551	0.617	0.582	147.000
weighted avg	0.758	0.844	0.799	147.000

	예측_Negative	예측_Neutral	예측_Positive
실제_Negative	38	0	5
실제_Neutral	8	0	7
실제_Positive	3	0	86

▼ 종합 결론

a. **모델 성능**

	Accuracy	Macro F1	Weighted F1
SVM (linear)	0.857	0.797	0.852
Logistic Regression	0.857	0.795	0.852
BERT (DistilBERT)	0.844	0.582	0.799



- Accuracy: SVM(0.857) = Logistic(0.857) > BERT(0.844)
- Macro F1: SVM(0.797) > Logistic(0.795) > BERT(0.582)
- Weighted F1: SVM(0.852) = Logistic(0.852) > BERT(0.799)

→ **SVM(linear)이 Macro F1 기준 근소하게 최고 성능**, Logistic과 사실상 동등 수준, **BERT는 Accuracy는 근접하나 Macro F1에서 큰 폭 하락**

b. **클래스별 특징 (Neutral 중심)**

- BERT는 Macro F1(0.582)이 Accuracy(0.844) 대비 크게 낮음 → **Neutral 클래스 완전 실패(recall 0.000)**로 인한 class collapse가 원인

- SVM은 class_weight='balanced' 적용 및 계수 분석상 hashtag_has_nostalgia, confusion, attending 등 **Neutral 특화 피처가 유의미하게 작동** → Macro F1 1위라는 결과가 이를 뒷받침
- Logistic 역시 Neutral recall 0.533으로 일부 탐지에 성공해 SVM과 유사한 수준의 균형 잡힌 성능 확보
- BERT는 Positive처럼 다수 클래스에서는 문맥 이해력을 바탕으로 우수하나(개별 f1 0.920), 소수 클래스에서 구조적 약점 노출

c. **종합 결론**

- 최종 모델: **SVM (Linear) 채택** (Macro F1·Weighted F1·Accuracy 종합적으로 가장 우수하며, 클래스 불균형 대응력도 확인됨)
- Logistic Regression은 SVM과 거의 동등한 성능(Accuracy·Weighted F1 동일, Macro F1 0.002 차이)으로 **대안 모델(2순위)**로 고려 가능
- 한계: BERT(DistilBERT)는 소규모·불균형 데이터(Neutral 74건)에서 **소수 클래스가 다수 클래스로 흡수되는 현상**이 뚜렷 → 별도의 클래스 가중치 조정이나 오버샘플링 없이는 현재 데이터 규모에 부적합
- **시사점**: 전통적 선형 모델(SVM, Logistic)이 소규모·불균형 텍스트 분류 과제에서 대형 사전학습 모델보다 오히려 안정적이고 우수한 성능을 보일 수 있음을 확인