서포트 벡터 머신은 어떤 경계를 선택하는가?

교재의 핵심 수식은 남기고, 마진 → 쌍대문제 → 커널 → 소프트 마진 → 회귀 흐름으로 정리

발표의 핵심 질문

분리 가능한 경계가 여러 개일 때, SVM은 왜 가장 넓은 마진을 가진 경계를 선택하고 비선형 문제까지 확장할 수 있을까?

1

최대 마진

경계와 가장 가까운
샘플 사이 여유 최대화

2

쌍대문제

해를 내적 형태로 바꿔
서포트 벡터 구조 확인

3

커널

고차원 투영을 직접 하지 않고
내적으로 비선형 분리

4 · 소프트 마진

현실 데이터의 노이즈·오분류를 일부 허용하고 C로 복잡도와 오류를 조절

5 · SVR / 커널 기법

ε-튜브 안 오차는 무시하는 회귀로 확장하고, 같은 커널 원리를 다른 학습법에도 적용

한 문장 결론

SVM의 중심은 “경계 자체”보다 경계 주변의 서포트 벡터와 마진이며, 쌍대형식과 커널을 통해 비선형 문제로 확장된다.

가장 넓은 마진을 만드는 경계를 선택한다

분리 가능한 초평면이 여러 개라면, 훈련 샘플의 변동에 더 견고한 최대 마진 초평면을 선택

분할 초평면

$$w^T x + b = 0$$

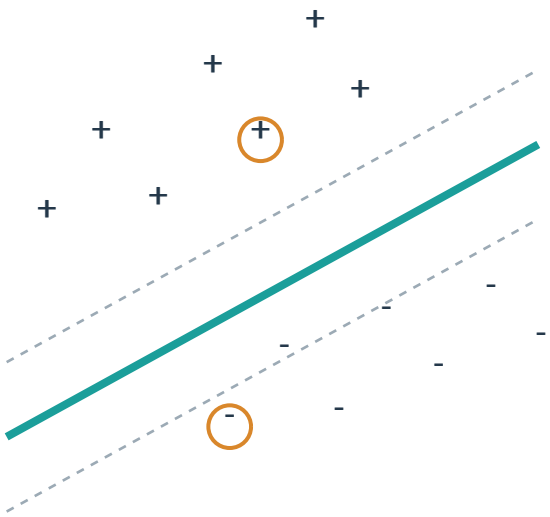
w: 초평면의 법선 벡터
b: 초평면의 위치를 조절하는 편향

점-초평면 거리

$$r = |w^T x + b| / ||w||$$

마진

$$gamma = 2 / ||w||$$



동그라미 친 점 = Support Vector

최대 마진 → 최적화 문제

$$\min \quad 1/2 \, ||w||^2$$

$$s.t. \;\; y_i (w^T x_i + b) >= 1$$

마진 gamma = 2/||w|| 이므로 ||w||을 작게 만들수록 마진이 커진다. 경계에 가장 가까운 샘플이 서포트 벡터가 되어 결정경계를 지탱한다.

왜 원문제를 쌍대문제로 바꾸는가?

라그랑주 승수와 KKT 조건을 이용하면 해가 훈련 샘플의 내적과 α로 표현되고, 이후 커널 사용이 가능해진다

원문제

min 1/2 ||w||^2
s.t. y_i(w^T x_i+b)>=1

→

라그랑주

제약마다 α_i >= 0을 두고
L(w,b,α) 구성

→

쌍대형식

w = Σ α_i y_i x_i
내적 x_i^T x_j만 남음

→

커널 연결

x_i^T x_j를 κ(x_i,x_j)로 대체 가능

핵심 결과 1 · w의 형태

$$w = \Sigma_i \alpha_i y_i x_i$$

핵심 결과 2 · KKT 해석

α_i = 0

해당 샘플은 최종 f(x)에 영향을 주지 않는다.

α_i > 0

y_i f(x_i) = 1인 최대 마진 경계상의 샘플 → 서포트 벡터

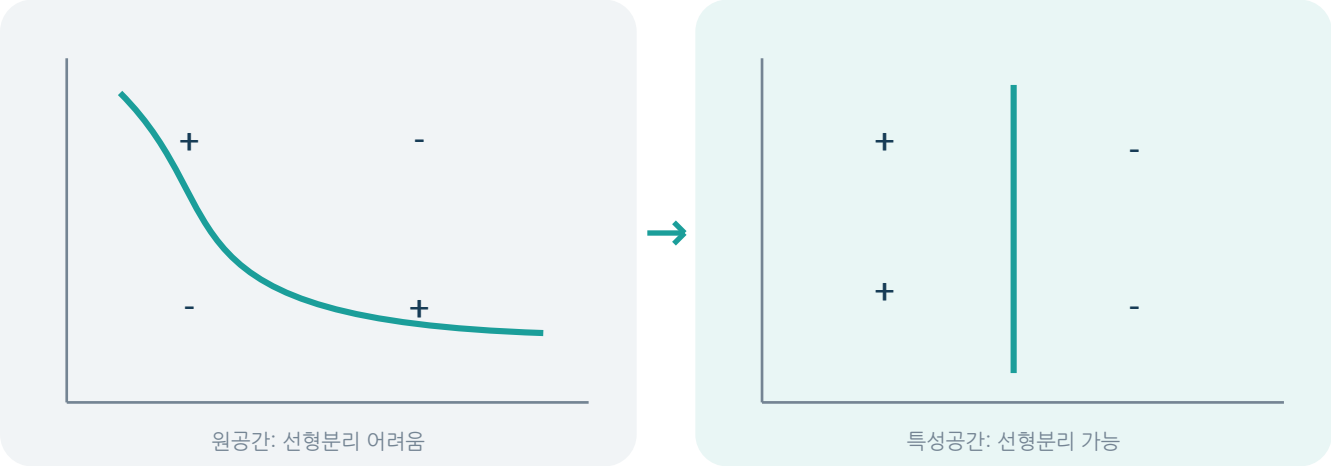
SMO · Sequential Minimal Optimization

전체 α를 한 번에 풀지 않고, 매번 두 개의 α_i와 α_j만 선택해 갱신한다. 제약 Σ α_i y_i = 0 때문에 한 변수만 독립적으로 바꿀 수 없다는 점을 이용한다.

Source: 단단한 머신러닝 Chapter 06 · 교재 사진 p.149-171 기반 요약

비선형 문제를 고차원 특성공간에서 선형 문제로 바꾼다

명시적인 고차원 좌표 ϕ(x)를 계산하지 않고, 커널 함수가 그 공간의 내적을 대신 계산



원공간: 선형분리 어려움

특성공간: 선형분리 가능

$$\kappa(x_i, x_j) = \varphi(x_i)^T \varphi(x_j)$$

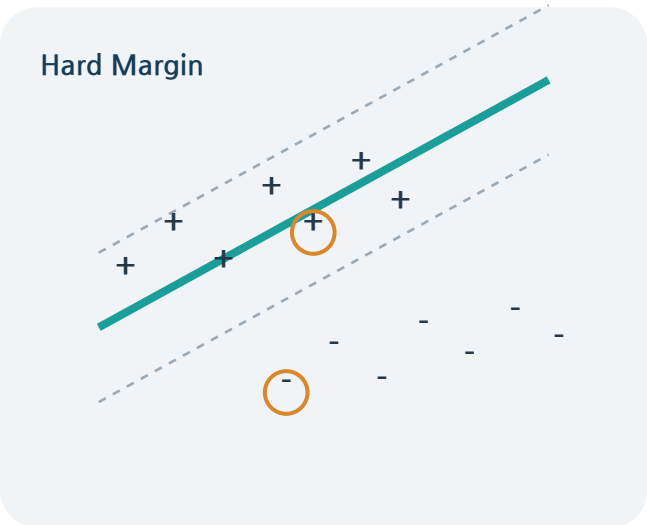
커널 트릭: 특성공간이 매우 높아도 ϕ(x)를 직접 만들 필요 없이 κ(x_i,x_j)만 계산한다.

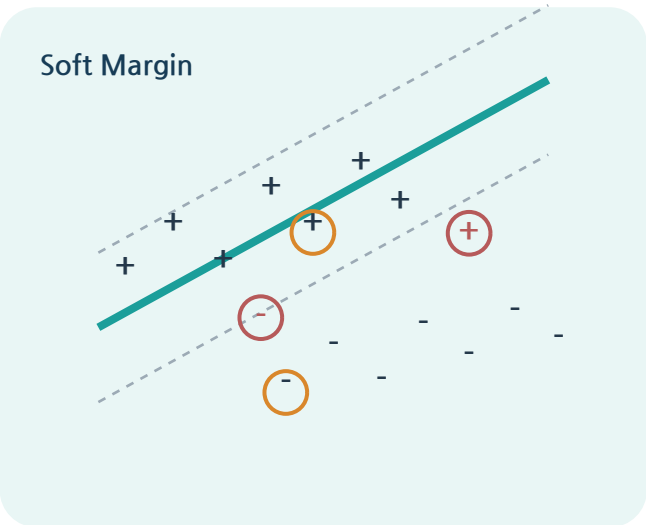
교재에 나온 자주 사용하는 커널

명칭	표현식	파라미터
선형	κ(x_i,x_j) = x_i^T x_j	-
다항식	κ(x_i,x_j) = (x_i^T x_j)^d	d >= 1
가우스	κ(x_i,x_j) = exp(-||x_i-x_j||^2 / (2σ^2))	σ > 0
라플라스	κ(x_i,x_j) = exp(-||x_i-x_j|| / σ)	σ > 0
시그모이드	κ(x_i,x_j) = tanh(β x_i^T x_j + θ)	β > 0, θ > 0

현실 데이터에서는 모든 샘플을 완벽히 분리하지 않아도 된다

하드 마진의 엄격한 제약을 완화하고, 일부 위반을 허용해 마진과 오류 사이의 균형을 조절





$$\min \ \ 1/2 \ ||w||^2 + C \ \Sigma_i \ \xi_i$$

C가 매우 큼

제약 위반에 큰 비용 → 하드 마진에 가까워짐

유한한 C

일부 샘플의 제약 위반을 허용 → 현실의 노이즈를 수용

0/1 손실을 계산하기 쉬운 대리 손실로 바꾼다

Hinge

max(0, 1-z)

Exponential

exp(-z)

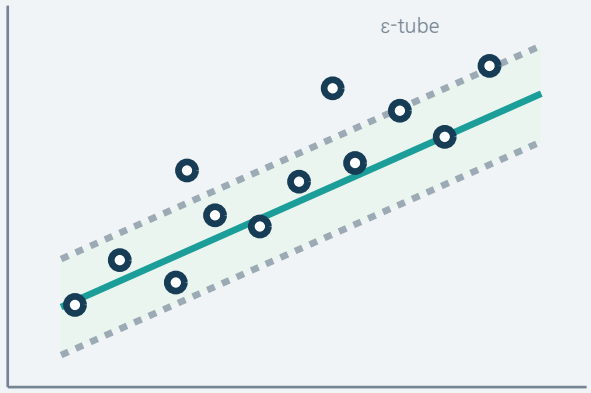
Logistic

log(1+exp(-z))

$$\min_f \ \Omega(f) + C \ \Sigma_i \ \ell(f(x_i), y_i)$$

분류의 마진 개념은 회귀와 다른 학습법으로 확장된다

SVR은 ε-튜브 안의 오차를 무시하고, 표현정리는 해를 커널 선형결합 형태로 표현할 수 있음을 보여준다



Support Vector Regression

예측값 f(x)와 실제값 y의 차이가 ε 이하이면 손실을 계산하지 않는다. ε-튜브 밖의 샘플이 회귀 경계를 결정하는 서포트 벡터가 된다.

$$\ell_\varepsilon(z) = 0 \text{ if } |z| <= \varepsilon, \quad |z|-\varepsilon \text{ otherwise}$$

커널을 적용한 SVR

$$f(x) = \Sigma_i (\alpha\text{hat}_i - \alpha_i)\, \kappa(x, x_i) + b$$

6.6 표현정리와 커널 기법

최적해는 훈련 샘플에 대한 커널 함수의 선형 조합으로 표현할 수 있다. 이 성질을 이용해 선형 학습기를 커널화하여 비선형 문제로 확장할 수 있다.

Chapter 06 핵심 흐름

최대 마진 → 서포트 벡터 → 쌍대문제 → 커널 트릭 → 소프트 마진/정규화 → SVR 및 커널 기법으로 확장