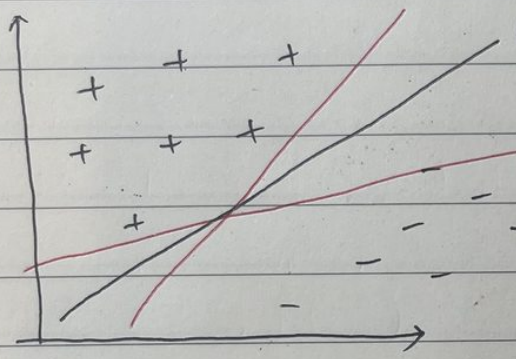
DATE. NO.

Chapter 6. 서포트 벡터 머신 (SVM)

6.1

① 아이디어.

훈련 샘플에 대해 가장 안정적으로 분류하는 분할 초평면 찾기.



노이즈에 대해 가장 안정적으로 분류

훈련세트 $D = \{(x_1, y_1), (x_2, y_2) \cdots\}$

$, y_i \in \{-1, +1\}$

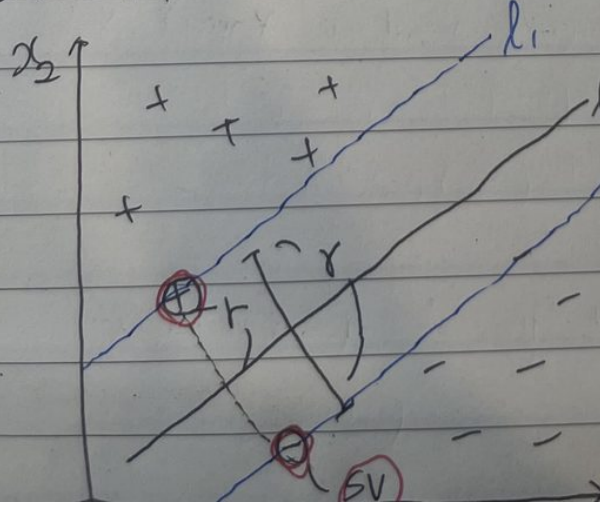
② 분할 초평면의 선형 방정식

분할초평면 $l = w^T x + b = 0$.

$l = f(w, b)$

- w: normal vector (방향)
- b: 변위 (원점에서의 거리)

③ SVM의 기본 모델 및 개념.



$r = \frac{|w^T x + b|}{\|w\|}$ ∴ 거리공식

l_2, $r = \frac{2}{\|w\|}$ (마진)

$l_1 : w^T x + b = 1$

$l_2 : w^T x + b = -1$.

DATE. NO.

- 조건과 해

$$\begin{cases} w^Tx+b \geq +1 & \rightarrow y=+1 \\ w^Tx+b \leq -1 & \rightarrow y=-1 \end{cases}$$

s.t. SVM이 조건식을 모두 정확히 분류.

- 최대 마진의 SVM의 원문제 (primal problem).

$$\max_{w,b} \frac{2}{\|w\|}(\gamma), \quad s.t. \ y_i(w^Tx_i+b) \geq 1$$

→ $\|w\|^{-1}$의 최대화

→ $\|w\|^2$의 최소화

→ $\min_{w,b} \frac{1}{2}\|w\|^2$ s.t $y_i l \geq 1$

* 거리(평면)유도공식, * $r \rightarrow \gamma$의 과정

6.2 쌍대문제 (Primal problem → Dual problem)

w.b → α_i 해

① 아이디어.

: 마진 max의 w,b뿐의 해를 구하기 보다는 제약조건을 라그랑주 승수 α_i로 흡수, w,b 제거후 α_i의 해를 구하는 문제

② 주요 개념.

- QP : 목적함수가 2차식 & 제약조건이 선형
  + Convex QP : QP + 목적함수가 볼록 (min 지역해 = min 전역해)
- 라그랑주 승수법 : 제약조건이 있는 최적화 문제 ⇒ 목적함수와 제약조건을 하나의 함수로 합쳐서 다룸

morning glory

DATE. NO.

- 라그랑주 승수 α_i : 각 제약조건에 있어 최적해 결정의 중요도.
- KKT 조건 : 제약조건의 Convex 최적화 문제에서 최적해가 만족해야 하는 조건 집합

> 미분최대화 → Convex Qp. → 라그랑주 승수법 → 쌍대(Dual) → KKT → SMO → SV.

- 라그랑주 승수법

: 제약조건이 있는 최적화 문제 푸는 방법

for $\min f(x)$, if $g(x)=0$.

→ $L(x,\lambda) = f(x) + \lambda g(x)$ (라그랑지안 함수)

λ = 라그랑주 승수 (α_i)

→ $\frac{\partial L}{\partial x} = 0$ & $\frac{\partial L}{\partial \lambda} = 0$.

: $\min f(x)$를 하면서 동시에 제약조건 $g(x)=0$를 만듦.

③ 쌍대문제로 전환 과정

$$\max_{w,b} \frac{2}{\|w\|} \quad s.t.\ y_i(w^T x_i + b) \geq 1$$

→ Convex quadratic Programming

: 제약조건 있는 최적화 문제

Convex한 2차(볼록) 이므로 전역해 = 지역해

→ $L(w,b,\alpha) = \frac{1}{2}\|w\|^2 + \sum_{i=1}^{m} \alpha_i (1 - y_i(w^T x_i + b))$

(라그랑지안 함수)

DATE. NO.

→ $L'(w,b,\alpha) = 0$. (w, b에 대해) - 최적값 찾기 위해

$L(w,b,\alpha)$에서

w와 b의 편미분, 0 값 찾기

$$\Rightarrow \begin{cases} w = \sum_{i=1}^{m} \alpha_i y_i x_i \\ 0 = \sum_{i=1}^{m} \alpha_i y_i \end{cases}$$

(w와 b에 대해 L을 각각 편미분)

$\frac{\partial L}{\partial w} = 0$, $\frac{\partial L}{\partial b} = 0$.

≒ $L(w,b,\alpha)$ 에 대입, w, b 소거.

$$\rightarrow \max_{\alpha} \sum_{i=1}^{m} \alpha_i - \frac{1}{2} \sum_{i=1}^{m} \sum_{j=1}^{m} \alpha_i \alpha_j y_i y_j x_i^T x_j$$

$$s.t. \sum_{i=1}^{m} \alpha_i y_i = 0,$$

$$\alpha_i \geq 0, \quad i = 1 \sim m.$$

$$f(x) = w^T x + b. = \sum_{i=1}^{m} \alpha_i y_i x_i^T x_i + b.$$

→ kkT조건 만족 (?)

$$\Rightarrow \left\{ \begin{array}{l} \alpha_i \geq 0 \\ y_i f(x_i) - 1 \geq 0. \\ \alpha_i (y_i f(x_i) - 1) = 0. \end{array} \right\}$$

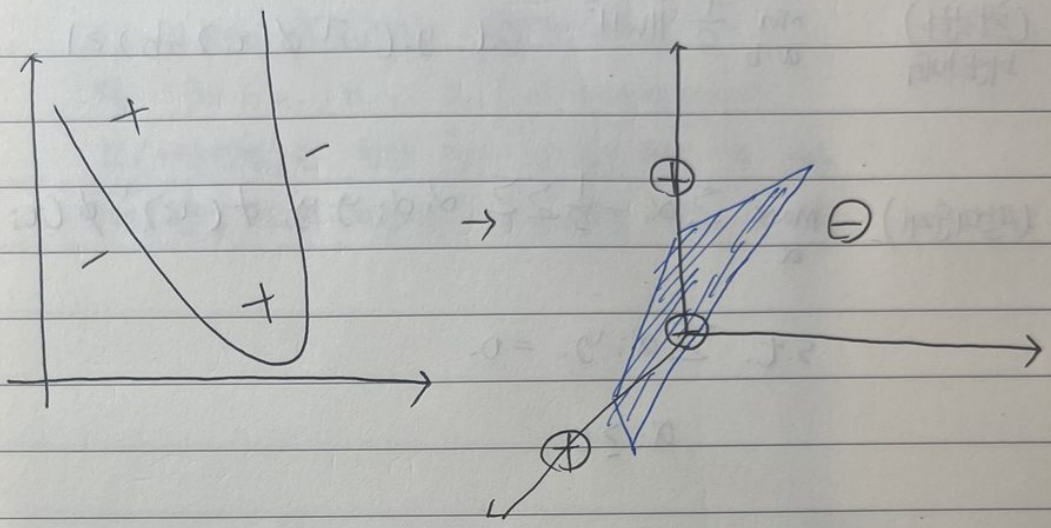
morning glory

DATE. NO.

6.3 커널함수

: 선형분리 불가능 문제 해결

① 아이디어



- 저차원의 선형분리 불가한 입력 데이터에서
  특성 하나를 추가,
  고차원 공간에서 선형분리 가능하게 만듦.

  ex) $(x_i, y_i) \rightarrow (x_i, y_i, x_i^2 + y_i^2)$

  $\phi(x_i)$: x_i를 고차원 공간으로 투영시킨 고유벡터.

  → $x_i^T x_j$ → $\phi(x_i)^T \phi(x_j)$: 복잡한 계산

  SVM 쌍대문제 변수로만 활용

⇒ $\boxed{K(x_i, x_j) = \phi(x_i)^T \phi(x_j)}$

커널함수 (kernel Trick)

: $\phi(x_i)$를 직접 계산 X.

$\phi(x_i)^T \phi(x_j)$만 계산.

Kernel은 고차원 계산 간접수행

morning glory

DATE. NO.

② kernel trick 이용, 고차원 공간 쌍대함수 문제 변환

$\phi(x_i)$: 고차원에서 x_i를 투영시킨 고유 V.

$$f(x) = w^T \phi(x) + b.$$

(최적화 미분최대화) $\min_{w,b} \frac{1}{2}\|w\|^2$ s.t. $y_i(w^T\phi(x_i)+b) \geq 1$

(쌍대문제) $\max_{\alpha} \sum \alpha_i - \frac{1}{2}\sum\sum \alpha_i \alpha_j y_i y_j \phi(x_i)^T \phi(x_j)$

s.t. $\sum \alpha_i y_i = 0.$

$\alpha_i \geq 0$

(커널함수 가정) $k(x_i, x_j) = \langle \phi(x_i), \phi(x_j) \rangle = \phi(x_i)^T \phi(x_j)$

∵ $\phi(x_i)^T \phi(x_j)$를 계산 → 복잡

kernel Trick을 사용, $k(x_i, x_j)$의 해를 구하기

(커널함수 의의) : $\phi(x_i)^T(\phi(x_i)$ 의 고차원 특징공간 내적해를 $k(x_i, x_j)$에서 원시공간 해로 전환

(커널함수 도입) $\max_{\alpha} \sum \alpha_i - \frac{1}{2}\sum\sum \alpha_i \alpha_j y_i y_j k(x_i, x_j)$

s.t. $\sum \alpha_i y_i = 0.$

$\alpha_i \geq 0.$

(서포트벡터 전개) $f(x) = w^T \phi(x) + b.$

$= \sum \alpha_i y_i k(x_i, x_1) + b.$

선형분리 불가능 문제는 모델 최적해 문제에서 커널함수를 전개하여 얻을 수 있다.

DATE. NO.

③ 재생 커널 힐베르트 공간에 관한 정리.

(Reproducing kernel Hilbert Space) RKHS.

: 모든 커널 함수가 은연 중에 정의하고 있는 특성공간.

: $\phi(x)$의 형식을 몰라 $k(\cdot,\cdot)$를 알 수 없을 때

$K(\cdot,\cdot)$가 $X \times X$에 대칭함수라면

K는 $D=\{x_1, x_2, \cdots x_n\}$ 꼴의 커널함수이므로

K(커널행렬)은 항상 양의 준정부호 행렬 임을 이용

커널 행렬 K에 대응하는 투영 ϕ를 찾을 수 있음.

morning glory

DATE. NO.

6.4 소프트 마진과 정규화

① 소프트 마진 ⟷ 하드 마진.

하드 마진 : 오류 허용 ×

훈련 샘플이 특성 공간에서 분리가능 가정

소프트 마진 : 일부 허용.

소수의 샘플이 특성공간에서 초평면에 의해 분리불가능 가정

제약조건 : $y_i(w^T x_i + b) \geq 0.1$

② 최적화 목표 함수

$$\min_{w,b} \frac{1}{2}\|w\|^2 + C\sum_{i=1}^{m} l_{0/1}\left(y_i(w^T x_i + b) - 1\right)$$

C : 상수, 조건 만족 제약 상수

(무한히 커질 수록 하드마진,

크기 작아질수록 조건제약정도 줄어듦)

$l_{0/1}$: 손실함수 $\begin{cases} 1, & \text{if } z > 0 \\ 0, & \text{otherwise} \end{cases}$

$$\min_{w,b} \frac{1}{2}\|w\|^2 \quad s.t.\ y_i(w^T x_i + b) \geq 1$$

③ 손실함수의 대리함수

- $l_{0/1}$: 좋은 이론 불규칙 손실함수 → 불연속적

→ '대리함수'로 ★연속적 성질 !

- 대리손실
  - 힌지손실 $l_{hinge}(z) = \max(0, 1-z)$
  - 지수손실 $l_{exp}(z) = \exp(-z)$
  - 조지틱 손실 $l_{log}(z) = \log(1+\exp(-z))$

DATE. NO.

* 추가노트) **쌍대성** — 라그랑주 쌍대함수 / 라그랑주 쌍대성 / SVM by 「머신러닝을 위한 수학」

① 쌍대성

: 최적화 문제에서 최적해의 범위 구하기
상한/하한 추측
쌍대관계로 변환, 해를 구하기 용이

ex) 제약조건 有 볼록최적화 문제

$$\begin{aligned} &\min f(x) \\ &\text{s.t.} \quad f_i(x) \le 0 \quad i = 1 \sim m \\ &\qquad h_i(x) = 0 \quad i = 1 \sim p. \end{aligned} \qquad \cdots\cdots (1)$$

- if 지시함수(indicator function) 일 때,

$I_-: \mathbb{R} \to \mathbb{R}$, $I_0 : \mathbb{R} \to \mathbb{R}$

$$I_-(x) \begin{cases} 0, & x \le 0 \\ \infty & x > 0 \end{cases} \qquad I_0(x) \begin{cases} 0 & x = 0 \\ \infty & x \neq 0 \end{cases}$$

- 지시함수를 (1)에 적용,

$$\min f(x) + \sum I_-(f_i(x)) + \sum I_0(h_i(x))$$

⇒ 제약조건 없는 식으로 나타낼 수 있음.

morning glory

4.1 라그랑주 쌍대함수

DATE. NO.

4.1.1 라그랑주 함수

① 정의

벡터 $\lambda = (\lambda_1 \sim \lambda_m)$, $v = (v_1 \sim v_p)$ 라

샘플 $x = (x_1 \sim x_n)$ 에 대해 $(\lambda \in \mathbb{R}^m, v \in \mathbb{R}^p, x = \mathbb{R}^n)$

(볼록) 최적화 문제의 라그랑주 함수 $(L: \mathbb{R}^n \times \mathbb{R}^m \times \mathbb{R}^p \to \mathbb{R})$

의 정의는

$$L(x, \lambda, v) = f(x) + \sum \lambda f(x) + \sum v h(x) \text{ 로 근사} \quad - ②$$

벡터 λ, v : 라그랑주 승수, 쌍대변수

4.1.2 라그랑주 쌍대함수

① 정리

제약조건 有 볼록 최적화 문제

$\min f(x)$ s.t $f_i(x) \le 0$ & $h_i(x) = 0$.

→ 라그랑주 함수로 근사 (제약조건 없는 문제로 근사)

$$\min L(x, \lambda, v) = f(x) + \sum \lambda f(x) + \sum v h(x)$$

라그랑주 함수 $L(x, \lambda, v)$ 의 최솟값

⇒ 라그랑주 쌍대함수 (Lagrangian dual function)

: 라그랑주 함수 최솟값을 라그랑주 승수 (λ, v) 에 대한 함수로 표현

DATE. NO.

② 라그랑주 쌍대함수 정의

: 제약조건 有 문제 → (라그랑주) 無 문제로 근사 후
해당 라그랑주 함수를 라그랑주 승수 λ, ν에 대한 함수로 변환후
최적화 문제 구하기 (라그랑주 쌍대함수)

라그랑주 함수 ② $L: \mathbb{R}^n \times \mathbb{R}^m \times \mathbb{R}^p \to \mathbb{R}$에 대하여
라그랑주 쌍대함수 $g: \mathbb{R}^m \times \mathbb{R}^p \to \mathbb{R}$은 $x \in \mathbb{R}^n$에 대한
라그랑주 함수 L의 하한으로 정의

$$g(\lambda, \nu) = \inf_{x \in \mathbb{R}^n} L(x, \lambda, \nu) = \inf_{x \in \mathbb{R}^n} \left(f(x) + \sum \lambda_i f_i(x) + \sum \nu_j h_j(x) \right)$$

morning glory

DATE. NO.

추가노트) KKT-조건

① 정의.

: 제약조건 최적 해 문제에서

최적해가 반드시 "만족해야 할 조건"

② 일반적인 KKT-조건

$$\begin{aligned} \min\ & f(x) \\ \text{s.t.}\ & g_i(x) \le 0 \quad i = 1 \sim m \\ & h_j(x) = 0 \quad j = 1 \sim p \end{aligned}$$

↓ 라그랑주 함수로 구함

$$L(x, \lambda, \nu) = f(x) + \sum \lambda_i g_i(x) + \sum \nu_j h_j(x)$$

단, $\lambda_i \ge 0$

⇓

위의 KKT-조건은 아래와 같음

① 원문제 가능성

$g_i(x^*) \le 0$, $h_j(x^*) = 0$

② 쌍대 가능성

$\lambda^* \ge 0$

③ 정지조건

$\nabla_x L(x^*, \lambda^*, \nu^*) = 0$

④ 상보성 조건

$\lambda_i^* g_i(x^*) = 0$

DATE. NO.

- 설명

원문제 가능성 : 최적해 x^*가 원래 제약조건 만족

쌍대가능성 : 라그랑주 승수 λ는 음수 X

정지조건 : 목적함수와 제약조건의 기울기는 최적점에서 0 (균형)

상보성 조건 : $\lambda_i^* \times g_i^*(x^*) = 0$

$\lambda_i^* = 0$ 이거나 $g_i(x^*) = 0$

~~$\lambda_i = 0$~~

$g_i(x^*) = 0 \rightarrow \lambda_i = 0$ 이 아닐 가능성

$g_i(x^*) < 0 \rightarrow \lambda_i = 0$ 에 여야 함.

↳ SVM에서는 결정경계를 결정하는 벡터는 서포트벡터임을 의미

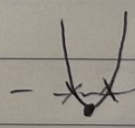
- 정리

일반적인 (제약조건 없는) 최적화 문제

: $\nabla f(x^*) = 0$: 최적점 후보

제약조건 있는 최적화문제

$\nabla f(x) = 0$ 이 아니어도 최적해 ㅁ

∵ 제약조건으로 인해  이보다 큰 지점이 최적 ㅁ.

따라서 제약조건 최적해는 '목적함수'와 '제약조건' 기울기가 서로 "균형"을 이루는 점이 "최적해" 이며

KKT-조건은 이 균형의 조건을 말함.

morning glory

DATE. NO.

③ SVM의 KKT-조건

① 원문제 가능성

$$y_i(w^T x_i + b) \geq 1$$

② 쌍대 가능성

$$\alpha_i \geq 0$$

③ 정지조건

$$\frac{\partial L}{\partial w} = 0$$

④ 상보성 조건

$$\alpha_i \{1 - y_i(w^T x_i + b)\} = 0$$

④ 상보성 조건과 서포트 벡터

$$\alpha_i \{1 - y_i(w^T x_i + b)\} = 0$$

$\alpha_i = 0 \Rightarrow$ 샘플 x_i는 결정경계 영향 X

$\alpha_i > 0 \Rightarrow 1 - y_i(w^T x_i + b) = 0$

$y_i(w^T x_i + b) = 1$

: 의결경계 위 $\Rightarrow$ Support Vector!

