6주차_ SVM 이론

상태	진행 중
날짜	2026년 8월 22일
유형	이론

SVM

SVM

- 6.1 마진과 서포트 벡터
- 6.2 쌍대문제 (Dual Problem)
- 6.3 커널 함수
- 6.4 소프트 마진과 정규화
- 6.5 SVR 이어서
- 6.6 커널 기법 (Kernel Methods)

6.1 마진과 서포트 벡터

왜 이 얘기부터 시작하나?

데이터를 두 클래스(+, -)로 나누는 직선(또는 초평면)을 그으려고 할 때, 사실 그런 직선은 무수히 많이 그을 수 있다 (그림 6.1 참고: +, - 데이터를 나누는 선이 여러 개 그려져 있음). 그럼 그 많은 선 중에 뭘 골라야 가장 좋은 분류기인가?

직관적 답: 두 그룹의 '한가운데'를 지나가는 선을 고르는 게 안전. 나중에 새로운 데이터가 조금 애매한 위치(경계 근처)에 나타나도, 한가운데 선이면 실수할 확률이 가장 적기 때문. 반대로 한쪽에 치우친 선이라면, 그 치우친 쪽 데이터에 조금만 노이즈가 껴도 바로 잘못 분류하게 됨.

초평면을 수식으로 표현하기

직선(초평면)은 다음처럼 씀(식 6.1):

$$wTx + b = 0$$

- **w**: 이 선이 "어느 방향을 보고 있는지"를 정하는 벡터 (기울기 같은 역할)
- **b**: 이 선을 원점에서 얼마나 밀어낼지 정하는 값 (절편 같은 역할)

점에서 이 선까지의 거리 (식 6.2):

$$r = | wTx + b | \ \|w\| r = \frac{|w^T x + b|}{\|w\|}$$

$$r = \|w\| \ | wTx + b |$$

→ 그냥 "이 점이 선에서 얼마나 떨어져 있나"를 계산하는 공식.

분류가 잘 됐다는 뜻: +인 데이터는 선의 한쪽(양수 방향), -인 데이터는 반대쪽(음수 방향)에 있어야 합니다. 이를 살짝 더 엄격하게 만들어서(스케일을 조정해서) 식 6.3처럼 씁니다:

$$wTxi + b \geq +1 \ (yi = +1\text{일 때}), wTxi + b \leq -1 \ (yi = -1\text{일 때})$$

서포트 벡터란?

위 식에서 딱 "=1" 또는 "=-1"이 되는, 즉 선에 가장 가깝게 붙어있는 데이터 포인트들을 **서포트 벡터**라고 부릅니다. 이 친구들이 선의 위치를 사실상 결정짓는 핵심 포인트예요.

마진(margin): 양쪽 클래스의 서포트 벡터 사이 폭 (그림 6.2에서 두 점선 사이 간격)

$$\gamma = \|w\|2$$

→ 이 폭이 넓을수록 "여유 공간"이 넓다는 뜻 = 더 안전한 분류기.

최종 목표: 이 마진 폭 γ를 최대한 넓게 만들고 싶다 (식 6.5):

$$\max_{w,b} \frac{2}{\|w\|} \quad \text{단, } y_i(w^T x_i + b) \geq 1 \text{ (모든 } i\text{에 대해)}$$

γ를 최대화 = ‖ w ‖ 를 최소화 하는 것과 같은 말이므로, 계산하기 편한 형태로 바꿔서 (식 6.6):

$$\min_{w,b} \frac{1}{2}\|w\|^2 \quad \text{단, } y_i(w^T x_i + b) \geq 1$$

→ 이게 **SVM의 기본 형태**입니다. "마진을 넓게" = " ‖ w ‖ 를 작게" 라는 관계만 기억하면 됩니다.

6.2 쌍대문제 (Dual Problem)

왜 필요한가?

식 6.6은 그 자체로도 풀 수 있는 문제(컨벡스 이차계획법)지만, 계산이 더 쉬운 "다른 버전(쌍대문제)"으로 바꿔서 푸는 게 실전에서 훨씬 효율적입니다.

결정함수 (식 6.7): 학습이 끝나면 이 함수로 새로운 데이터를 분류합니다.

$$f(x) = wTx + b$$

라그랑주 승수법 적용식 6.6의 제약조건(부등식)마다 $\alpha_i \geq 0$이라는 새로운 변수(라그랑주 승수)를 하나씩 붙여서 아래처럼 하나의 식으로 합칩니다 (식 6.8):

$$L(w, b, \alpha) = \frac{1}{2}\|w\|^2 + \sum_{i=1}^{m} \alpha_i \big(1 - y_i(w^T x_i + b)\big)$$

w와 b를 없애기: 이 L을 w, b로 각각 미분해서 0으로 놓으면 (식 6.9, 6.10):

$$w = \sum_{i=1}^{m} \alpha_i y_i x_i, \qquad 0 = \sum_{i=1}^{m} \alpha_i y_i$$

이걸 다시 식 6.8에 넣으면 w, b가 사라지고 오직 α만 남은 문제가 됩니다 → **쌍대문제** (식 6.11):

$$\max_{\alpha} \sum_{i=1}^{m} \alpha_i - \frac{1}{2} \sum_{i=1}^{m} \sum_{j=1}^{m} \alpha_i \alpha_j y_i y_j x_i^T x_j$$

$$\text{단, } \sum_{i=1}^{m} \alpha_i y_i = 0, \quad \alpha_i \geq 0$$

→ 이제 원래 문제(w, b 구하기)가 α라는 숫자들만 구하는 문제로 바뀌었습니다.

α를 구하고 나면 w와 b를 역산해서 최종 분류 모델을 얻습니다 (식 6.12):

$$f(x) = w^T x + b = \sum_{i=1}^{m} \alpha_i y_i x_i^T x + b$$

KKT 조건 (식 6.13) — 이 최적화가 성립하려면 아래 3가지가 항상 지켜져야 함:

$$\alpha_i \geq 0, \qquad y_i f(x_i) - 1 \geq 0, \qquad \alpha_i (y_i f(x_i) - 1) = 0$$

세 번째 식이 핵심 포인트: **α_i=0 이거나, $y_i f(x_i)$=1 이거나 둘 중 하나**여야 합니다.

- α_i=0인 샘플 → 식 6.12에서 그 항이 사라짐 → 이 데이터는 최종 모델에 아무 영향 안 줌
- α_i>0인 샘플 → 반드시 $y_i f(x_i)$=1, 즉 마진 경계선 위에 딱 붙어있는 서포트 벡터

결론: 학습이 끝나면 대부분의 데이터는 버려도 되고, 오직 서포트 벡터(경계에 붙은 소수의 점들)만 모델에 남는다는 것 — 이게 SVM의 가장 중요한 특징입니다.

SMO (Sequential Minimal Optimization) — α를 실제로 구하는 방법

식 6.11은 이차계획법 문제라 풀 수는 있지만, 데이터 수가 많아지면 계산량이 폭발적으로 늘어납니다. 그래서 나온 실용적 해법이 **SMO**(Platt, 1998)입니다.

핵심 아이디어: "α가 m개나 있는데, 한꺼번에 다 최적화하지 말고 **딱 2개씩만** 골라서 최적화하자."

- 왜 1개가 아니라 2개씩? → 제약조건 $\Sigma \alpha_i y_i$=0 때문에 α 하나만 바꾸면 이 조건이 깨져버림. 최소 2개는 같이 움직여야 조건을 유지하면서 값을 바꿀 수 있음.

반복 절차:

1. 업데이트할 α_i, α_j 한 쌍을 고른다
   - 첫 번째: KKT 조건을 가장 많이 위반한(가장 "잘못된") 변수를 선택 → 이걸 고쳐야 개선 효과가 가장 크기 때문
   - 두 번째: 첫 번째와 "차이가 큰" 변수를 휴리스틱하게 선택 (계산을 간단히 하기 위한 실용적 선택)
2. 나머지 α는 모두 고정한 채, α_i와 α_j 두 개만 최적화 → 이 부분은 계산식으로 바로 답이 나오는(closed-form) 간단한 문제가 됨
3. 이 과정을 KKT 조건을 모두 만족할 때까지 반복

두 변수만 남았을 때의 계산 (식 6.14~6.16)

나머지 α들을 다 고정하면 제약식이 이렇게 단순해집니다:

$$\alpha_i y_i + \alpha_j y_j = c, \quad \alpha_i \geq 0,\ \alpha_j \geq 0$$

여기서 c는 고정된 나머지 항들의 합 (식 6.15):

$$c = -\sum_{k \neq i,j} \alpha_k y_k$$

(즉, c는 원래 조건 $\Sigma \alpha_i y_i$=0을 성립시키기 위한 상수)

이 식(6.16: $\alpha_i y_i + \alpha_j y_j$=c)을 이용해서 α_j를 α_i로 표현해 없애버리면, **α_i 하나짜리 간단한 문제**가 되고 제약도 $\alpha_i \geq 0$ 뿐이라 손으로 풀 수 있는 수준의 닫힌 형태 해가 나옵니다.

b(절편) 구하기 (식 6.17, 6.18)

서포트 벡터 (x_s, y_s)에서는 항상 $y_s f(x_s)$=1이 성립하므로:

$$y_s\Big(\sum_{i\in S}\alpha_i y_i x_i^T x_s + b\Big) = 1$$

여기서 S는 $\alpha_i>0$인 서포트 벡터들의 인덱스 모음. 이론적으로는 서포트 벡터 하나만 써도 b를 구할 수 있지만, 노이즈에 덜 민감하도록 **모든 서포트 벡터로 구한 b의 평균**을 사용합니다

$$b = \frac{1}{|S|}\sum_{s\in S}\Big(1/y_s - \sum_{i\in S}\alpha_i y_i x_i^T x_s\Big)$$

6.3 커널 함수

왜 필요한가:
지금까지는 데이터가 "선 하나로 나눠지는" 상황(선형 분리 가능)만 다뤘습니다. 그런데 현실에는 그렇지 않은 경우도 많습니다. 대표적인 예가 **XOR 문제** (그림 6.3): +와 -가 뒤섞여 있어서 직선 하나로는 도저히 나눌 수 없는 배치입니다.

해결 아이디어:
원래 공간(예: 2차원)에서는 못 나누더라도, 이 데이터를 **더 높은 차원**(예: 3차원)으로 옮겨 놓으면 그 안에서는 평면 하나로 깔끔하게 나눠질 수 있습니다. 그림 6.3의 오른쪽처럼 2차원을 3차원으로 투영($x \mapsto \varphi(x)$)시키면 초록색 평면 하나로 +와 -를 분리할 수 있게 되는 것을 보여줍니다.

다행인 점: 원래 속성(feature)의 개수가 유한하기만 하면, 반드시 어떤 고차원 공간으로 보내서 선형 분리가 가능하게 만들 수 있다는 사실이 알려져 있습니다.

$\varphi(x)$를 x를 고차원으로 옮긴 후의 벡터라고 하면, 모델은 이렇게 쓴다 (식 6.19):

$$f(x) = wT\phi(x) + b$$

식 6.6과 똑같은 형태로 최적화 문제를 세울 수 있다 (식 6.20):

$$\min_{w,b}\frac{1}{2}\|w\|^2 \quad \text{s.t. } y_i(w^T\phi(x_i)+b)\geq 1$$

이것의 쌍대문제는 (식 6.21):

$$\max_{\alpha}\sum_{i=1}^{m}\alpha_i - \frac{1}{2}\sum_{i=1}^{m}\sum_{j=1}^{m}\alpha_i\alpha_j y_i y_j \phi(x_i)^T\phi(x_j) \quad \text{s.t. } \sum\alpha_i y_i = 0,\ \alpha_i\geq 0$$

문제 발생: 이걸 풀려면 $\varphi(x_i)^T\varphi(x_j)$, 즉 "고차원으로 옮긴 뒤 내적"을 계산해야 하는데, 고차원 공간의 차원이 어마어마하게 커질 수 있어서 직접 계산하기가 매우 힘들다(심지어 무한 차원인 경우도 있다).

커널 트릭(kernel trick): 그래서 다음과 같은 함수를 가정한다 (식 6.22):

$$\kappa(x_i, x_j) = \langle\phi(x_i),\phi(x_j)\rangle = \phi(x_i)^T\phi(x_j)$$

즉, "고차원에서의 내적 결과"를 원래(저차원) 공간에서 x_i, x_j만 가지고 바로 계산해내는 지름길 함수 κ가 있다는 것이다. 이것이 있으면 φ가 정확히 어떤 형태인지 몰라도, 심지어 고차원 계산을 전혀 하지 않고도 결과를 얻을 수 있다. 이를 **커널 트릭**이라 부른다.

이 κ를 이용해 쌍대문제를 다시 쓰면 (식 6.23):

$$\max_{\alpha}\sum_{i=1}^{m}\alpha_i - \frac{1}{2}\sum_{i=1}^{m}\sum_{j=1}^{m}\alpha_i\alpha_j y_i y_j \kappa(x_i, x_j) \quad \text{s.t. } \sum\alpha_i y_i = 0,\ \alpha_i\geq 0$$

해를 구하면 최종 모델은 (식 6.24):

$$f(x) = w^T\phi(x) + b = \sum_{i=1}^{m} \alpha_i y_i \phi(x_i)^T \phi(x) + b = \sum_{i=1}^{m} \alpha_i y_i \kappa(x, x_i) + b$$

이 κ(·,·)를 **커널 함수**라 부르고, 이렇게 훈련 샘플들의 커널 함수 값을 전개해서 최적해를 얻는 방식을 **서포트 벡터 전개**라고 부른다.

어떤 함수가 커널 함수가 될 수 있나 (정리 6.1):

- κ가 대칭 함수이고, 그 함수로 만든 커널 행렬 K(모든 데이터쌍에 대해 κ값을 계산해 채운 m×m 행렬)가 항상 **양의 준정부호 (positive semi-definite)** 행렬이면, 그 κ는 유효한 커널 함수다.
- 즉, 이 조건만 만족하면 φ가 구체적으로 어떤 모양인지 몰라도 그 커널을 안심하고 사용할 수 있다.
- 사실 모든 커널 함수는 은연중에 **재생 커널 힐베르트 공간(RKHS)**이라는 특성 공간을 하나씩 정의하고 있다고 볼 수 있다.

주의할 점: φ가 무엇인지 모르는 상태에서 어떤 커널이 가장 적합한지도 알기 어렵다. 그래서 "커널 함수 선택"이 SVM 성능을 좌우하는 가장 중요한 변수가 된다. 잘못된 커널을 고르면 데이터를 엉뚱한 특성 공간에 투영한 셈이 되어 성능이 크게 나빠질 수 있다.

자주 쓰는 커널 함수들 (표 6.1)

이름	수식	파라미터
선형 커널	$\kappa(x_i,x_j) = x_i^T x_j$	없음
다항식 커널	$\kappa(x_i,x_j) = (x_i^T x_j)^d$	d≥1 (d=1이면 선형 커널과 동일)
가우스 커널 (RBF)	$\kappa(x_i,x_j) = \exp(-\lVert x_i-x_j \rVert^2/2\sigma^2)$	σ>0
라플라스 커널	$\kappa(x_i,x_j) = \exp(-\lVert x_i-x_j \rVert/\sigma)$	σ>0
시그모이드 커널	$\kappa(x_i,x_j) = \tanh(\beta x_i^T x_j+\theta)$	β>0, θ>0

(참고 팁: 텍스트 데이터는 보통 선형 커널이 잘 맞고, 뭘 골라야 할지 모르겠으면 가우스 커널부터 시도해보는 것이 경험적으로 무난하다.)

커널 조합해서 새 커널 만들기

- κ_1, κ_2가 커널이면, 이들의 선형결합도 커널이다 (식 6.25): $\gamma_1\kappa_1+\gamma_2\kappa_2$
- κ_1, κ_2가 커널이면, 직접곱도 커널이다 (식 6.26): $\kappa_1 \otimes \kappa_2(x,z)=\kappa_1(x,z)\kappa_2(x,z)$
- κ_1이 커널이면, 아무 함수 g(x)에 대해서도 커널이 성립한다 (식 6.27): $\kappa(x,z)=g(x)\kappa_1(x,z)g(z)$

6.4 소프트 마진과 정규화

문제의식: 지금까지는 "선형 분리가 (특성 공간에서라도) 가능하다"고 가정했지만, 현실에서는 ① 적절한 커널을 못 찾을 수도 있고 ② 설령 분리가 됐다 해도 그게 과적합 때문인지 구별하기 어렵다.

해결책: SVM에게 약간의 오류를 허용해준다 → **소프트 마진**(그림 6.4에서 초록색 원으로 표시된, 조건을 만족 못 한 샘플들이 존재해도 괜찮게 함)이라 부른다.

기존의 엄격한 조건 (식 6.28, 모든 샘플이 반드시 지켜야 함):

$$yi(wTxi + b) \geq 1$$

최적화 목표 재구성: 마진은 최대화하되, 조건을 못 지키는 샘플은 최대한 적게 만드는 쪽으로 재구성한다 (식 6.29):

$$\min_{w,b} \frac{1}{2}\|w\|^2 + C\sum_{i=1}^{m} \ell_{0/1}\big(y_i(w^T x_i + b) - 1\big)$$

여기서 C>0은 상수이고, $\ell_{0/1}$은 **0/1 손실 함수**다 (식 6.30):

$$\ell_{0/1}(z) = \begin{cases} 1, & z < 0 \\ 0, & \text{otherwise} \end{cases}$$

→ 조건을 어기면(z<0) 벌점 1점, 어기지 않으면 벌점 0점을 주는 매우 단순한 함수다.

- C가 무한히 커지면 → 오류를 절대 허용 안 함 → 식 6.29는 원래의 하드 마진(식 6.6)과 같아진다.
- C가 적당한 유한값이면 → 일부 샘플이 조건을 못 지켜도 봐준다(오류 허용).

문제: $\ell_{0/1}$은 불연속(계단 모양)이라 수학적으로 다루기 매우 어렵다(넌컨벡스). 그래서 최적화하기 힘들다. 이에 사람들은 이 $\ell_{0/1}$을 비슷하지만 다루기 쉬운 함수로 대체해서 쓴다. 이를 **대리 손실(surrogate loss)**이라 부른다.

자주 쓰는 대리 손실 3가지 (그림 6.5)

- **힌지 손실** (식 6.31):

$$\ell_{hinge}(z) = max(0, 1 - z)$$

- **지수 손실** (식 6.32):

$$\ell_{exp}(z) = exp(-z)$$

- **로지스틱 손실** (식 6.33):

$$\ell_{log}(z) = log(1 + exp(-z))$$

힌지 손실을 쓰면 식 6.29는 이렇게 바뀐다 (식 6.34):

$$\min_{w,b} \frac{1}{2}\|w\|^2 + C\sum_{i=1}^{m} \max\left(0, 1 - y_i(w^T x_i + b)\right)$$

여유 변수(slack variable) ξ_i 도입: max(0, ...) 형태는 다루기 번거로우니, 각 샘플마다 "얼마나 어겼는지"를 나타내는 여유 변수 $\xi_i \geq 0$을 만들어 식을 더 다루기 쉽게 바꾼다 (식 6.35):

$$\min_{w,b,\xi_i} \frac{1}{2}\|w\|^2 + C\sum_{i=1}^{m} \xi_i$$

$$s.t. yi(wTxi + b) \geq 1 - \xi i, \xi i \geq 0, i = 1, ..., m$$

→ 원래는 1 이상이어야 했던 조건을, ξ_i만큼 느슨하게 풀어주는 것이다. ξ_i가 클수록 그 샘플은 조건을 많이 어긴 것(=페널티도 큼)이다.

라그랑주 함수로 풀기 (식 6.36):

$$L(w, b, \alpha, \xi, \mu) = \frac{1}{2}\|w\|^2 + C\sum_{i=1}^{m} \xi_i + \sum_{i=1}^{m} \alpha_i\left(1 - \xi_i - y_i(w^T x_i + b)\right) - \sum_{i=1}^{m} \mu_i \xi_i$$

($\alpha_i \geq 0$, $\mu_i \geq 0$은 라그랑주 승수다.)

w, b, ξ_i로 각각 미분해서 0으로 놓으면 다음을 얻는다 (식 6.37~6.39):

$$w = \sum_{i=1}^{m} \alpha_i y_i x_i, \qquad 0 = \sum_{i=1}^{m} \alpha_i y_i, \qquad C = \alpha_i + \mu_i$$

이를 대입해 정리하면 **소프트 마진의 쌍대문제**를 얻는다 (식 6.40):

$$\max_{\alpha} \sum_{i=1}^{m} \alpha_i - \frac{1}{2} \sum_{i=1}^{m} \sum_{j=1}^{m} \alpha_i \alpha_j y_i y_j x_i^T x_j$$

$$\text{s.t.} \sum_{i=1}^{m} \alpha_i y_i = 0, \quad 0 \leq \alpha_i \leq C$$

→ 하드 마진(식 6.11)과 거의 똑같은데, 제약이 **0≤α_i≤C**로 상한이 하나 추가된 것뿐이다(하드 마진은 상한 없이 0≤α_i다). 그래서 앞서 배운 SMO를 그대로 적용해서 풀 수 있고, 커널까지 적용하면 식 6.24와 같은 서포트 벡터 전개식을 그대로 쓴다.

소프트 마진 KKT 조건 (식 6.41):

$$\alpha_i \geq 0,\ \mu_i \geq 0, \qquad y_i f(x_i) - 1 + \xi_i \geq 0, \qquad \alpha_i (y_i f(x_i) - 1 + \xi_i) = 0, \qquad \xi_i \geq 0,\ \mu_i \xi_i = 0$$

해석:

- α_i=0 → 그 샘플은 모델에 영향을 주지 않는다.
- α_i>0 → $y_i f(x_i)$=1-ξ_i가 되며, 그 샘플은 서포트 벡터가 된다.
  - 이때 α_i<C이면 → μ_i>0 → ξ_i=0 → 딱 마진 경계선 위에 위치한다.
  - α_i=C이면 → μ_i=0 → ξ_i가 있을 수 있다:
    - 0<ξ_i≤1 → 마진 안쪽(경계와 초평면 사이)에 있지만 분류는 맞게 된다.
    - ξ_i>1 → 아예 잘못 분류된 샘플이 된다.

→ 결론적으로 소프트 마진 SVM도 최종 모델은 **서포트 벡터에만 의존**한다(힌지 손실 덕분에 "희소성"이 유지된다).

다른 손실 함수를 쓴다면

- 로지스틱 손실 ℓ_{log}를 대신 쓰면 → **로지스틱 회귀와 매우 비슷한 모델**이 된다. 실제로 SVM과 로지스틱 회귀는 최적화 목표가 비슷하고 성능도 비슷하다고 알려져 있다.
  - 로지스틱 회귀의 장점: 결과값에 확률적 의미가 자연스럽게 담긴다(SVM은 별도 처리가 필요하다[Platt, 2000]). 다중 클래스 분류에도 바로 쓸 수 있다(SVM은 확장 과정이 필요하다).
  - 힌지 손실의 장점: 그림 6.5에서 보듯 힌지 손실은 어느 지점 이후로 완전히 평탄한(=0) 구간이 있다. 이것이 SVM 해에 **희소성**(서포트 벡터만 남는 성질)을 부여한다. 반면 로지스틱 손실은 계속 감소하기만 하는 함수라 이런 서포트 벡터 개념이 생기지 않는다. 따라서 로지스틱 회귀는 더 많은 훈련 샘플에 의존하게 되고 계산량도 늘어난다.

일반화된 형태 — 정규화 관점: 0/1 손실 대신 다른 대리 손실을 쓰면 다른 모델을 얻게 되는데, 이들은 공통적으로 아래와 같은 형태를 가진다 (식 6.42):

$$\min_{f} \Omega(f) + C \sum_{i=1}^{m} \ell(f(x_i), y_i)$$

- **Ω(f)**: **구조적 위험(structural risk)**이라 부르며, 모델 f가 가진 어떤 성질(예: 복잡도가 낮음)을 나타낸다.
- **Σℓ(f(x_i),y_i)**: **경험적 위험(empirical risk)**이라 부르며, 모델이 훈련 데이터에 얼마나 잘 맞는지를 나타낸다.
- **C**: 이 둘 사이의 절충(trade-off)을 조절하는 값이다.

이런 관점에서 식 6.42는 **정규화(regularization)** 문제로도 볼 수 있다. Ω(f)를 정규화 항, C를 정규화 상수라 부른다.

- L_2 노름 $\|w\|_2$ → w의 가중치를 골고루 균형 있게 만드는 경향을 보인다.
- L_0 노름 $\|w\|_0$, L_1 노름 $\|w\|_1$ → w의 가중치를 희소하게(대부분 0으로) 만드는 경향을 보인다.

6.5 SVR 이어서

핵심 아이디어: f(x)와 실제 값 y 사이에 **최대 ε만큼의 오차는 봐주자**는 것입니다. 즉, |f(x)-y|가 ε보다 작으면 손실 0으로 치고, ε보다 클 때만 그 초과분만큼 손실로 계산합니다. 그림 6.6에서 보듯 f(x)를 중심으로 위아래로 폭 2ε짜리 "관(tube)" 같은 마진을 만

들어서, 그 안에 들어온 점들은 전부 정확히 예측한 것으로 봐줍니다.

SVR 최적화 문제 (식 6.43):

$$\min_{w,b} \frac{1}{2}\|w\|^2 + C\sum_{i=1}^{m} \ell_\epsilon(f(x_i) - y_i)$$

- C는 정규화 상수
- ℓ_ε은 **ε-둔감 손실 함수**다.

ε-둔감 손실 (식 6.44):

$$\ell_\epsilon(z) = \begin{cases} 0, & |z| \le \epsilon \\ |z| - \epsilon, & \text{otherwise} \end{cases}$$

→ 오차가 ε 이내면 손실 0(그림 6.7에서 가운데 평평한 구간), ε을 넘으면 그 초과분만 손실로 잡음. 참고로 그림 6.7에는 일반 제곱 손실 ℓ(z)=z²도 같이 그려져 있는데, ε-둔감 손실은 그것과 달리 가운데 평평한 구간이 있다는 게 특징입니다.

여유 변수 도입: 마진 위쪽으로 넘친 정도와 아래쪽으로 넘친 정도가 다를 수 있으므로, 두 개의 여유 변수 ξ_i(위쪽 초과분), $\hat{\xi}_i$(아래쪽 초과분)을 둡니다. 그러면 식 6.43은 (식 6.45):

$$\min_{w,b,\xi_i,\hat{\xi}_i} \frac{1}{2}\|w\|^2 + C\sum_{i=1}^{m}(\xi_i + \hat{\xi}_i)$$

제약조건:

$$\text{s.t. } f(x_i) - y_i \le \epsilon + \xi_i, \;\; y_i - f(x_i) \le \epsilon + \hat{\xi}_i, \;\; \xi_i, \hat{\xi}_i \ge 0$$

→ 위로 초과한 만큼은 ξ_i, 아래로 초과한 만큼은 $\hat{\xi}_i$가 흡수해주는 구조입니다.

라그랑주 함수 구성: 이전과 같은 방식으로 4종류의 라그랑주 승수(μ_i, $\hat{\mu}_i$, α_i, $\hat{\alpha}_i$, 모두 ≥0)를 붙여서 (식 6.46):

$$L = \frac{1}{2}\|w\|^2 + C\sum(\xi_i + \hat{\xi}_i) - \sum \mu_i\xi_i - \sum \hat{\mu}_i\hat{\xi}_i + \sum \alpha_i(f(x_i) - y_i - \epsilon - \xi_i) + \sum \hat{\alpha}_i(y_i - f(x_i) - \epsilon - \hat{\xi}_i)$$

w, b, ξ_i, $\hat{\xi}_i$로 미분해서 0으로 놓으면 (식 6.47~6.50):

$$w = \sum_{i=1}^{m}(\hat{\alpha}_i - \alpha_i)x_i, \qquad 0 = \sum_{i=1}^{m}(\hat{\alpha}_i - \alpha_i)$$

$$C = \alpha_i + \mu_i, \qquad C = \hat{\alpha}_i + \hat{\mu}_i$$

이를 대입하면 **SVR의 쌍대문제**를 얻습니다 (식 6.51):

$$\max_{\alpha,\hat{\alpha}} \sum_{i=1}^{m} y_i(\hat{\alpha}_i - \alpha_i) - \epsilon(\hat{\alpha}_i + \alpha_i) - \frac{1}{2}\sum_{i=1}^{m}\sum_{j=1}^{m}(\hat{\alpha}_i - \alpha_i)(\hat{\alpha}_j - \alpha_j)x_i^T x_j$$

$$\text{s.t. } \sum(\hat{\alpha}_i - \alpha_i) = 0, \quad 0 \le \alpha_i, \hat{\alpha}_i \le C$$

KKT 조건 (식 6.52):

$$\alpha_i(f(x_i) - y_i - \epsilon - \xi_i) = 0, \quad \hat{\alpha}_i(y_i - f(x_i) - \epsilon - \hat{\xi}_i) = 0$$

$$\alpha_i\hat{\alpha}_i = 0, \quad \xi_i\hat{\xi}_i = 0, \quad (C - \alpha_i)\xi_i = 0, \quad (C - \hat{\alpha}_i)\hat{\xi}_i = 0$$

의미: $f(x_i)-y_i-\epsilon-\xi_i=0$일 때만 α_i가 0이 아닌 값을 가질 수 있고, 마찬가지로 $y_i-f(x_i)-\epsilon-\hat{\xi}_i=0$일 때만 $\hat{\alpha}_i$가 0이 아닐 수 있습니다. 즉 **샘플이 ε-마진(관) 안에 들어가지 못하고 밖으로 삐져나온 경우에만** α_i, $\hat{\alpha}_i$가 0이 아닌 값을 가질 수 있습니다. 또한 두 조건이 동시에 성립할 수 없으므로(f(x)가 y보다 위이면서 동시에 아래일 수는 없으니) α_i와 $\hat{\alpha}_i$ 중 반드시 하나는 0이어야 합니다.

최종 모델: 식 6.47을 대입하면 (식 6.53):

$$f(x) = \sum_{i=1}^{m}(\hat{\alpha}_i - \alpha_i)x_i^T x + b$$

여기서 $(\hat{\alpha}_i-\alpha_i)\neq 0$인 샘플들이 바로 **SVR의 서포트 벡터**이고, 이들은 반드시 ε-마진 밖(관 바깥)에 위치합니다. 즉 SVR의 서포트 벡터도 전체 훈련 샘플의 일부일 뿐이며, 해가 희소성을 갖습니다.

b 구하기: KKT 조건에 의해 각 샘플은 $(C-\alpha_i)\xi_i=0$과 $\alpha_i(f(x_i)-y_i-\epsilon-\xi_i)=0$을 만족합니다. 따라서 α_i를 얻은 후 만약 $0<\alpha_i<C$라면 반드시 $\xi_i=0$이 되고, 이 경우 식 6.54를 통해 b를 구할 수 있습니다:

$$b = y_i + \epsilon - \sum_{j=1}^{m}(\hat{\alpha}_j - \alpha_j)x_j^T x_i \quad (\text{식 } 6.54)$$

이론적으로는 $0<\alpha_i<C$를 만족하는 아무 샘플이나 하나 골라서 b를 구할 수 있지만, 실전에서는 이 조건을 만족하는 여러 샘플로 각각 b를 구한 후 **평균값**을 취하는 것이 더 로버스트한 방법입니다.

특성 공간(커널) 버전: φ(x)로 고차원 투영을 한 경우, 식 6.47은 (식 6.55):

$$w = \sum_{i=1}^{m}(\hat{\alpha}_i - \alpha_i)\phi(x_i)$$

이를 대입하면 SVR은 (식 6.56):

$$f(x) = \sum_{i=1}^{m}(\hat{\alpha}_i - \alpha_i)\kappa(x, x_i) + b$$

여기서 $\kappa(x_i,x_j)=\varphi(x_i)^T\varphi(x_j)$는 커널 함수입니다.

6.6 커널 기법 (Kernel Methods)

관찰: 식 6.24(SVM)와 식 6.56(SVR)을 다시 보면, 편향 b를 빼고 생각했을 때 SVM이나 SVR이 학습한 모델은 모두 **커널 함수 $\kappa(x,x_i)$들의 선형 조합**으로 표현된다는 공통점이 있습니다. 이걸 더 일반화한 결론이 바로 **표현정리(representer theorem)**입니다.

표현정리 (정리 6.1): $\mathbb{H}$를 커널 함수 κ에 대응하는 재생 커널 힐베르트 공간(RKHS)이라 하면, 임의의 **단조 증가** 함수 $\Omega:[0,\infty]\to\mathbb{R}$와 임의의 **비음수** 손실 함수 $\ell:\mathbb{R}^m\to[0,\infty]$에 대해, 다음 최적화 문제 (식 6.57):

$$\min_{h\in\mathbb{H}} F(h) = \Omega(\|h\|_{\mathbb{H}}) + \ell(h(x_1), h(x_2), ..., h(x_m))$$

의 해는 항상 다음 형태로 나타낼 수 있습니다 (식 6.58):

$$h^*(x) = \sum_{i=1}^{m}\alpha_i\kappa(x, x_i)$$

왜 대단한가: 이 정리는 손실 함수 ℓ에 대해서는 **아무 제약이 없고**, 정규화 항 Ω는 그저 **단조 증가**이기만 하면 됩니다(심지어 Ω가 컨벡스가 아니어도 상관없습니다). 그런데도 어떤 손실 함수와 정규화 항을 조합하든, 이 최적화 문제의 최적해 h*(x)는 항상 커널 함수의 선형 조합으로 표현할 수 있다는 것입니다. 이것이 바로 **커널 함수의 위력**입니다.

커널 기법(kernel methods): 사람들은 이 성질을 이용해서 커널 함수에 기반한 학습법들을 여러 가지 발전시켰습니다. 즉, 원래 선형인 학습기에 커널 함수를 도입("커널화")해서 비선형 학습기로 확장시키는 것입니다. 아래에서는 **선형 판별분석(LDA)**을 예로, 커널화를 통해 **커널 선형 판별분석(KLDA)**을 얻는 과정을 살펴봅니다.

KLDA 유도 과정

먼저, 매핑 $\varphi: \mathcal{X} \to \mathbb{F}$를 통해 샘플을 특성 공간 $\mathbb{F}$로 옮긴다고 가정하고, $\mathbb{F}$에서 선형 판별분석을 하면 (식 6.59):

$$h(x) = w^T \phi(x)$$

KLDA의 학습 목표 (식 6.60, 원래 LDA의 식 3.35와 유사한 형태):

$$\max_w J(w) = \frac{w^T S_b^\phi w}{w^T S_w^\phi w}$$

- $S_b\phi$: 특성 공간에서 클래스 간 산점도 행렬 (between-class scatter matrix)
- $S_w\phi$ S_w^\phi
  $S_w\phi$: 특성 공간에서 클래스 내 산점도 행렬 (within-class scatter matrix)

X_i ($i \in \{0,1\}$)를 각 클래스의 샘플 집합, m_i를 각 클래스 샘플 수, $m = m_0 + m_1$이라 하면, 클래스 i 샘플의 특성 공간에서의 평균은 (식 6.61):

$$\mu_i^\phi = \frac{1}{m_i} \sum_{x \in X_i} \phi(x)$$

두 산점도 행렬은 (식 6.62, 6.63):

$$S_b^\phi = (\mu_1^\phi - \mu_0^\phi)(\mu_1^\phi - \mu_0^\phi)^T$$

$$S_w^\phi = \sum_{i=0}^{1} \sum_{x \in X_i} (\phi(x) - \mu_i^\phi)(\phi(x) - \mu_i^\phi)^T$$

문제: φ가 구체적으로 어떤 형태인지 모르기 때문에, 이 산점도 행렬들을 직접 계산할 수 없습니다.

해결 — 표현정리 적용: J(w)를 표현정리의 손실 함수 ℓ로 놓고 $\Omega \equiv 0$이라 하면, 표현정리에 의해 h(x)는 다음처럼 쓸 수 있습니다 (식 6.64):

$$h(x) = \sum_{i=1}^{m} \alpha_i \kappa(x, x_i)$$

이를 식 6.59와 연결하면 (식 6.65):

$$w = \sum_{i=1}^{m} \alpha_i \phi(x_i)$$

이제 커널 행렬 $\mathbf{K} \in \mathbb{R}^{m \times m}$ ($K_{ij} = \kappa(x_i, x_j)$)를 정의하고, i번째 클래스 샘플을 가리키는 지시 벡터 $\mathbf{1}_i \in \{1,0\}^{m \times 1}$($x_j \in X_i$이면 j번째 성분이 1, 아니면 0)를 정의합니다. 이를 이용해 다음을 설정합니다 (식 6.66~6.69):

$$\hat{\mu}_0 = \frac{1}{m_0} K 1_0, \qquad \hat{\mu}_1 = \frac{1}{m_1} K 1_1$$

$$M = (\hat{\mu}_0 - \hat{\mu}_1)(\hat{\mu}_0 - \hat{\mu}_1)^T, \qquad N = KK^T - \sum_{i=0}^{1} m_i \hat{\mu}_i \hat{\mu}_i^T$$

그러면 식 6.60은 (식 6.70):

$$\max_{\alpha} J(\alpha) = \frac{\alpha^T M \alpha}{\alpha^T N \alpha}$$

즉, 원래 w에 대한 최적화 문제가 이제 **α에 대한 최적화 문제**로 완전히 바뀌었습니다. 이 형태는 원래의 (커널화 이전) 선형 판별분석과 같은 형태이므로, LDA를 풀 때 쓰던 방법을 그대로 적용해서 α를 구할 수 있고, 이를 식 6.64에 대입하면 최종적으로 투영 함수 h(x)를 얻을 수 있습니다.