7주차 _ SVM 논문

상태	완료
날짜	2026년 8월 29일
유형	논문
파일	Sentiment Analysis for IMDb Movie Review Using SVM Method.pdf

Sentiment Analysis for IMDb Movie Review Using SVM Method

▼ 논문 요약

연구 배경 및 목적

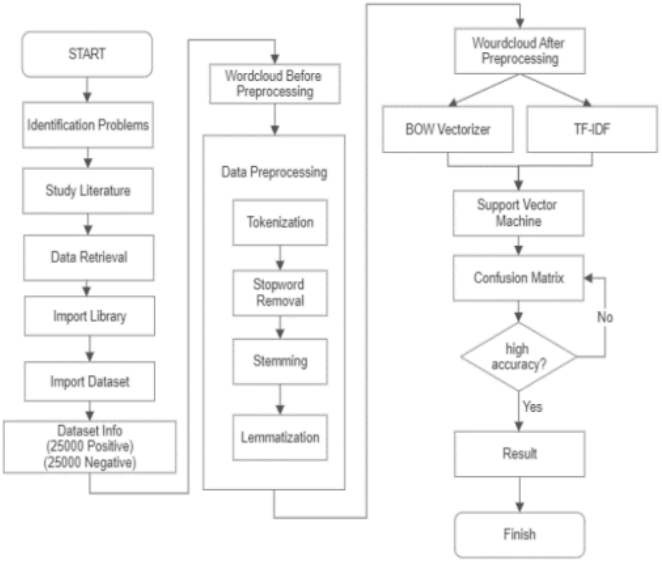
문제 제기

- IMDb는 대표적인 영화 리뷰 플랫폼이지만, 별점(star rating) 기능 위주로 리뷰가 노출되어 사용자가 다른 이용자들의 리뷰 내용을 파악하기 어려움
- 기존 감성 분석(Sentiment Analysis) 연구는 대부분 분류(classification) 문제로 접근 (SVM, Naive Bayes, 편향 영향 분석 등)
- 최근에는 BERT 기반 딥러닝 모델, RNN-LSTM+GloVe 기반 문맥 인식 모델, SEM 기반 전자상거래 만족도 연구, KoBERT 등 다양한 접근법이 시도되고 있으나 전통적 NLP 모델(TF-IDF, BOW)의 성능 개선 여지는 여전히 존재
- **연구 목적**
  - IMDb 영화 리뷰 데이터를 대상으로 **SVM(Support Vector Machine)**을 활용한 감성 분류(긍정/부정) 모델을 구현
  - 특성 추출(feature extraction) 방식(BoW vs TF-IDF)에 따른 분류 성능 차이를 비교·검증

데이터

- **출처**: Kaggle 공개 데이터셋 (IMDb Movie Review)
- **규모**: 총 50,000개 리뷰
  - 긍정(positive) 25,000개 / 부정(negative) 25,000개
- **분할**
  - 학습(Training) 데이터: 40,000개 (80%)
  - 테스트(Test) 데이터: 10,000개 (20%)
- **라벨**: positive / negative (이진 분류)

방법론



1단계: 전처리 (Data Preprocessing)

- **문제점**: 원본 텍스트 데이터에는 불필요한 기호, HTML 태그, 대소문자 불일치, 조사·접속사 등 분류에 방해가 되는 요소가 다량 포함됨
- **대응 방안**
  - **Tokenization**: 구두점 분리, HTML 태그 제거, 소문자화 등 정규화
  - **Stop Word Removal**: 주어·전치사·접속사 등 고빈도 기능어 제거
  - **Stemming**: 접두사·접미사를 제거해 어근(root)만 추출
  - **Lemmatization**: 사전에 존재하는 올바른 원형 단어로 환원 (사람이 읽기엔 자연스럽지만 계산 비용이 큼)
- 전처리 전 단어 수: **65,521,550개** → 전처리 후: **41,346,691개**로 축소
- 전처리 전



- 전처리 후



2단계: 특성 추출 (Feature Extraction)

- **문제점**: 텍스트 데이터를 SVM이 학습할 수 있는 수치형 벡터(행렬)로 변환해야 함
- **대응 방안**: 두 가지 벡터화 기법을 각각 적용해 성능 비교
  - **BoW (Bag of Words)**: 단어 순서를 무시하고 각 단어의 등장 횟수만 카운트

- **TF-IDF**: 단어 빈도(TF)와 역문서빈도(IDF)를 결합 → 여러 문서에 공통적으로 자주 등장하는 단어의 가중치는 낮추고, 특정 문서에서 두드러지는 단어의 가중치는 높임

3단계: 모델 학습 및 하이퍼파라미터 최적화

- **문제점**: SVM은 커널·C값 등 하이퍼파라미터 설정에 따라 성능 편차가 크며, 무작위 설정으로는 일관된 결과 보장 불가
- **대응 방안**: **Grid-Search**를 이용해 다양한 하이퍼파라미터 조합을 체계적으로 탐색, 각 조합에 대해 SVM을 평가하여 최적 조합 선정

4단계: 평가 (Evaluation)

- Confusion Matrix 기반으로 Precision, Recall, F1-Score, Accuracy 산출
- **BoW**

TABLE II
RESULT BOW

	Precision	Recall	F1-Score
Negative	0.87	0.90	0.88
Positive	0.90	0.88	0.89
Accuracy	0.90	0.89	**0.89**

- **TF-IDF**

TABEL III
RESULT TF-IDF

	Precision	Recall	F1-Score
Negative	0.90	0.92	0.91
Positive	0.92	0.91	0.91
Accuracy	0.91	0.92	**0.91**

▼ 주요 모델 — SVM (Support Vector Machine)

1. SVM의 정의 및 원리

- **정의**: 두 개의 데이터 클래스(긍정/부정)를 구분하는 **이진 분류(binary classification)** 알고리즘
- **핵심 아이디어**: 두 클래스를 나누는 **초평면(hyperplane)**을 찾되, 이 초평면과 가장 가까운 데이터 포인트(서포트 벡터) 간의 거리(마진, margin)를 **최대화**하는 방향으로 결정 경계를 설정
  - 2차원에서는 직선, 고차원 데이터에서는 초평면 형태로 일반화
- **분류 함수**: $f(x) = w^Tx + b$
  - w: 가중치 벡터(결정 경계의 방향을 결정)
  - b: 절편(bias)
  - 서포트 벡터와 결정 경계 간 기하학적 거리

$$r = yr = \frac{\check{r}}{w}$$

- **원리 요약**: 마진이 클수록 새로운 데이터에 대한 일반화 성능이 좋아진다는 가정 하에, 오분류를 최소화하면서 마진을 최대화하는 최적 경계를 탐색

2. 입력 특성(Feature)에 따른 SVM 성능 비교

이 논문의 핵심은 **동일한 SVM 모델에 서로 다른 특성 추출 방식(BoW vs TF-IDF)을 입력했을 때의 성능 차이**를 검증한 것

특성 추출 방식	Accuracy	Precision	Recall	F1-Score
BoW	88.59%	0.90	0.89	0.89
TF-IDF	**91.27%**	0.91	0.92	**0.91**

- Confusion Matrix 상으로도 TF-IDF 적용 시 오분류(FP+FN) 건수가 BoW보다 적게 나타남 (BoW: 872+596=1,468건 오분류 / TF-IDF: 653+492=1,145건 오분류, 테스트 10,000건 기준)
- **해석**: TF-IDF는 단순 등장 횟수(BoW)와 달리 "여러 문서에 공통적으로 등장하는 단어의 중요도를 낮추는" 가중치 구조를 가지므로, SVM이 클래스를 구분하는 데 더 유의미한 단어(=서포트 벡터 결정에 기여하는 특성)를 학습하는 데 유리했던 것으로 해석됨

3. 하이퍼파라미터 튜닝 (Grid-Search)

- **정의**: 학습 이전에 미리 설정해야 하는 파라미터(하이퍼파라미터)를 다양한 후보 조합으로 대입해가며, SVM이 각 조합에서 얼마나 잘 분류하는지를 평가한 뒤 최적 조합을 채택하는 방식
- **필요성**: 무작위로 하이퍼파라미터를 설정할 경우 일관되고 신뢰할 수 있는 결과를 얻기 어려움
- 본 연구에서는 Grid-Search를 SVM 파라미터 최적화에 적용하여 최고 성능(TF-IDF 91.27%)을 달성

4. SVM 선택의 의의와 한계

항목	내용
장점	고차원 텍스트 데이터에서도 안정적인 이진 분류 성능, 마진 최대화를 통한 일반화 성능 확보
한계	대용량 데이터(50,000건)에서는 학습 시간이 상대적으로 오래 걸릴 수 있음; 문맥/순서 정보를 반영하지 못하는 BoW·TF-IDF 특성에 의존하므로 RNN-LSTM·BERT 계열 모델 대비 문맥 이해력은 낮음

▼ 추가 설명 (보충)

1. BoW vs TF-IDF — 왜 성능 차이가 나는가

- BoW는 "이 단어가 몇 번 등장했는가"만 보기 때문에, 모든 리뷰에 공통적으로 자주 등장하는 단어(movie, film, character 등, Figure 3·5의 워드클라우드에서 확인됨)가 지나치게 큰 비중을 차지할 수 있음
- TF-IDF는 이런 "흔한 단어"의 가중치를 IDF 항으로 낮춰주기 때문에, 긍정/부정을 가르는 데 실제로 더 변별력 있는 단어에 상대적으로 높은 가중치가 부여됨 → SVM의 결정 경계 학습에 더 유리한 입력 구성

2. 평가지표 해석 시 유의점

- 이 논문은 Accuracy 외에도 Precision·Recall·F1-Score를 함께 제시했는데, 이는 긍정/부정 데이터가 50:50으로 균형 잡혀 있어 Accuracy만으로도 어느 정도 신뢰할 수 있는 상황이지만, 클래스별(Positive/Negative) 성능 편차까지 확인하기 위한 것으로 볼 수 있음
- BoW·TF-IDF 모두 Negative보다 Positive의 Recall이 근소하게 높거나 유사한 수준으로 나타나 큰 클래스 불균형 문제는 없는 것으로 보임

3. 향후 연구 방향 (논문 제언)

- 완전한 불용어 사전(library stop word) 및 언어학 전문가 활용을 통한 전처리 정교화
- 특정 감성 분석 사례에 특화된 고정확도 모델·알고리즘 분석
- 다양한 소셜미디어 플랫폼 대상 사례 연구 및 타 모델(RNN, BERT, KoBERT 등)과의 비교 확장 연구