w9_bayes_paper_review

박중현

주제

나이브 베이즈 기반 소셜 미디어 상의 신조어 감성 판별 기법

내용

나이브 베이즈가 신조어 분류에 도움이 되는가
아이디어
신조어에 대해 주제별 감성 확률 도축
기존 신조어로 활용하지 않았던 모델에 비해 감성 정도를 상대적으로 민감하게 판별
문제정의
빈번하게 사용되고 생성되는 신조어의 사전적 의미 없음으로 인한 텍스트 마이너, 빅데이터 알고리즘 성능 저하 문제
텍스트 마이닝

- 비정형 데이터, 특징 추출 및 키워드화, 단어 간 유사도 기반 벡터화(군집화), 정형화 후 패턴 및 키워드 분석

오피니언 마이닝

- 단순히 키워드 등장 빈도 분석 x, 긍정/부정/중립 인식 > 핵심 의견을 분석할 수 있는 고도화된 기법

감정 판별 시스템
포털사이트(카페/블로그) 텍스트 수집 > 한나눔 패키지 라이브러리 > 신조어 위주 감성 분석(긍/부정) 실행 > 신조어 사전: 위키피디아 소셜미디어 신조어 목록 사용
신조어 감성 분석(긍/부정)
토크나이징 적용 > 분석 가능한 단위로 분리 > 코퍼스: 불용어 리스트 구축 (품사/고빈도 불용어 제거) > 키워드 추출 및 빈도수 기반 신조어 리스트 구축 > 신조어 사전(정답)을 통해 감성 분류 후 학습
표준어 감성 분석
뉴스 텍스트 데이터 스크래핑(일반어 주로 사용) > 형태소 분석 > 명사 추출 > 불용어 제거 > TF-IDF 계산 > NB 긍부정분류
실험 진행 및 평가
신조어 학습 분류기 + 일반어
기존 분류 vs 혼합 분류 성능 비교
신조어 감성 정도를 더 높게 반영한 것을 볼 수 있음
감성에 정확성이라는 표현 자체가 성립한다고 보기 어려움, 외부 시선에서 판단하기 어려움
감성 정도를 민감하게 잡아내거나 다양한 양상을 볼 수 있음

Q&A

Q(정윤). 혼합 모델은 신조어와 표준어 각각을 훈련한 모델을 결합한 것인가?
A(중현). 논문에서 상세히 제시된 바는 없으나 각각 훈련한 모델을 결합한 것으로 보인다.

강재성

주제

cycle time key factor identification ~

내용

cycle time은 생산 효율과 연결되는 중요한 지표
영향을 주는 공정 요인이 너무 많으면 -> 실제 중요 요인 파악 x, 모델 해석 복잡 증가
과정
182개 후보 요인 - CMIM 1차 - SNB - 20개 핵심 요인 발견 - CT 관련 분류
CMIM
변수를 새로 알게 되었을 때 예측 대상에 대한 정보를 얼마나 더 얻을 수 있는가?

- 단순히 관련성이 높은 변수만 반복해서 선택 x, 이미 선택된 변수와 겹치지 않는 새로운 정보를 주는 변수를 우선적으로 찾음
- 중요한 후보를 1차적으로 압축

SNB Classifier
사전 확률 x 각 변수의 조건부 확률을 이용해 가장 가능성이 높은 클래스를 선택
예측에 도움이 되는 변수만 선택해서 사용
NB + feature selection
실험결과
182개 후보 요인 > 20개 핵심 요인으로 압축
DT, NN, MLR과 비교 했을 때 비교 가능한 정확도를 보임, 단순성과 해석 가능성 장점
나이브 베이즈의 중요성
예측을 잘하는 모델을 만드는 목적 x
CT와 관련된 핵심 요인, 요인만 이용해 분류, 결과를 현장에서 해석하기 쉬움
한계점

1. simulated fab 데이터
   모의 데이터이므로 실제 생산 환경에서 같은 결과가 나오는지 검증 필요
2. 조건부 독립 가정
   변수들이 서로 독립이라는 가정 > 실제 공정 변수는 서로 영향을 주므로 해당 가정이 완벽히 성립 x

결론
CMIM으로 변수 후보를 먼저 줄이고, SNB로 핵심 요인 추가 선택, 반도체 CT 관련 예측을 수행한 연구

Q&A

Q1(중현). SNB에서 핵심 변수를 선정하는 원리? 나이브 베이즈를 분류가 아닌 핵심 변수를 선정하는 도구로 사용하므로 궁금함
A. 정보가 겹치지 않는 변수로 155개 전처리 > CMIM을 통해 50개로 필터링 > SNBC가 0개부터 변수를 하나씩 추가하면서 성능이 가장 높아지는 변수의 개수에서 훈련을 멈춤 (중현님: 50개 중 20개를 임의로 선택 하여 훈련을 거치면서 가장 성능이 높아지는 20개의 조합을 최종 변수로 선택)
A. SNBC는 최종 분류기 이면서 핵심 변수를 선택하는 분류기이므로 단순히 정확도 및 성능을 평가하는 도구로 사용됐다고 할 수 없다.

신정윤

주제

베이지안 네트워크 기반 결측 정보 활용 논문

내용

1. **연구 목적**
    - 의료 데이터에서 결측값을 단순히 채우는 것이 아니라, 결측이 발생했다는 사실 자체가 정보가 될 수 있는지 확인
    - 병명을 직접 확정하는 진단보다는 POMR 기반으로 문제 목록의 완전성과 시의성을 높이는 의사결정지원 도구가 목적
    - 예: 의사가 특정 검사를 처방하지 않았다는 사실 자체도 하나의 정보로 활용
2. **결측값 처리 방식**
    - A: 결측 그대로 유지
    - B: 평균/최빈값으로 대체
    - C: missing 상태를 하나의 값으로 추가
    - D: 결측 여부를 나타내는 지시 변수를 추가
    - 핵심은 C, D처럼 결측 자체를 명시적으로 표현했을 때 성능이 좋아지는지 비교하는 것
3. **베이지안 네트워크 적용**
    - 질병 유무를 종속변수로 두고 여러 임상 변수와의 관계를 베이지안 네트워크로 학습
    - 나이브 베이즈 구조, WinMine이 구조를 학습하는 방식, 연구자가 인과 구조를 설계하는 방식 등 여러 모델을 비교
4. **평가 방법**
    - AUC를 이용해 성능 평가
    - 부트스트랩 500회 반복
    - 순열검정으로 결측을 명시적으로 표현한 방식이 실제로 더 좋은지 확인
5. **주요 결과**
    - 결측을 명시적으로 표현한 C, D 방식이 A, B보다 전반적으로 성능이 좋았음
    - 이를 통해 의료 데이터에서는 일부 결측이 단순한 누락이 아니라 정보일 수 있다고 해석
6. **한계**
    - 모든 변수에 결측 정보를 일괄적으로 적용함
    - 실제로는 일부 변수의 결측 정보만 성능 향상에 기여했을 가능성이 있음
    - ICD9 주진단만 사용해서 다중질환 환자의 상황을 충분히 반영

Q&A

Q&A 정리
Q1(중현) 이 연구에서 확률을 사용하는 목적이 결측값을 대체하는 데 있는지, 아니면 병명을 진단하는 데 있는지 궁금함.
A. 결측값 자체를 다른 값으로 채우는 것이 핵심 목적은 아님. 연구는 POMR 기반으로 환자의 임상 정보와 유사한 문제를 참고해 문제 목록을 제안하는 의사결정지원 도구를 만드는 데 초점이 있음. 직접 병명을 확정하는 진단 시스템이라기보다, 의사가 놓칠 수 있는 문제를 보완해 문제 목록의 완전성과 시의성을 높이는 것이 목적임. 또한 결측은 단순히 대체하지 않고, 예를 들어 “의사가 해당 검사를 처방하지 않았다”는 사실 자체를 하나의 정보로 활용함.
Q2(중현). 베이지안 네트워크는 나이브 베이즈와 어떻게 다른가?
A. 나이브 베이즈는 변수들이 조건부로 서로 독립이라고 가정하는 단순한 구조를 사용하지만, 베이지안 네트워크는 변수 간 의존관계를 그래프 구조로 표현할 수 있음. 이 논문에서는 구조와 확률표를 모두 사람이 직접 작성하는 방식만 사용한 것이 아니라, WinMine이 구조를 학습하는 방법, 기계가 학습한 구조에 Netica로 확률표를 적용하는 방법, 그리고 연구자가 인과 구조를 설계하고 확률표는 도구를 활용하는 방법 등을 비교했음. 즉 사람과 기계의 역할을 다르게 나눈 여러 형태의 베이지안 네트워크를 사용한 연구임.